МАТЕРИАЛЫ КУРСА

ТЕОРИЯ ВЕРОЯТНОСТЕЙ И МАТЕМАТИЧЕСКАЯ СТАТИСТИКА

ДЛЯ ЗАДАЧ РОБОТОТЕХНИКИ

УЧЕБНЫЙ КОНСПЕКТ

Оглавление

Вероятностные модели 3

Лекция 1. Классическое определение вероятности 3

Лекция 2. Общее определение вероятности 19

Практическое задание 1. Моделирование вероятности 37

Вопросы для подготовки 41

Байес и статистика 44

Лекция 3. Формула Байеса и обновление вероятностей 44

Лекция 4. Статистика и бутстрэп 51

Практическое задание 2. Байесовский классификатор 73

Вопросы для подготовки 77

Дискретные случайные величины 80

Лекция 5. Дискретные случайные величины 80

Лекция 6. Моделирование и приближение Пуассона 92

Практическое задание 3. Бутстрэп 99

Вопросы для подготовки 100

Вероятностные модели и события

Лекция 1. Классическое определение вероятности

Классическая вероятностная модель — это один из самых базовых и простых способов описания случайности, которая тем не менее достаточно нетривиальна, чтобы давать как полезные теоретические, так и практические результаты. Эта лекция посвящена последовательному введению трёх основных "ингредиентов" так называемой классической вероятностной модели:

- *Множество элементарных исходов*, необходимое для описания неопределённости опыта;
- Понятие *события*, на языке которого мы будем делать почти все утверждения о случайных исходах;
- *Вероятность* (в её простейшей формулировке), позволяющая нам задавать численные значения для правдоподобности этих событий.

Затем на нескольких примерах разберём, как применять эту модель к задачам.

Множество элементарных исходов Ω

Изучение вероятностей случайных событий или характеристик случайных величин с математической точки зрения невозможно без описания *множества* всех возможных исходов наблюдаемого случайного опыта. В этом курсе мы всегда будем обозначать его Ω и называть его *множеством элементарных исходов*. Мы всегда будем предполагать его существование, даже когда мы не будем его явно вводить, потому что на нём будут основаны абсолютно все объекты теории вероятностей, которые мы будем изучать.

Его природа может быть произвольной, т. е. это может быть множество чисел, векторов, символов, слов, функций, цветов, других множеств или вообще смешивать в себе объекты разных типов. При построении мы будем выбирать то множество, которое будет для нас удобным. В любом случае его элементы $\omega \in \Omega$ мы будем называть *элементарными исходами* и требовать от них, чтобы каждый такой исход соответствовал ровно одному возможному исходу случайного опыта.

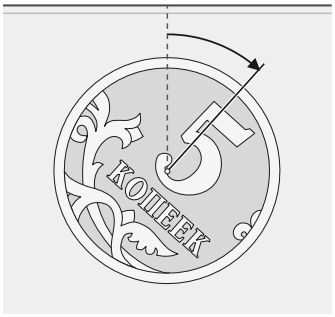


Рис. 1: Угол поворота относительно края стола.
Основа: Юкатан, “5 копеек”, Wikimedia Commons, CC BY-SA 3.0; изображение изменено.

Пример 1 (Бросок монетки). *Рассмотрим случайный опыт, состоящий в броске монетки. Каковы его элементарные исходы? В учебных задачах по теории вероятностей обычно интересуются, выпал “орёл” или же “решка”. В таком случае мы можем просто взять множество из двух слов* $\Omega = \{$*орёл*, *решка*$\}$.

Но сам физический бросок — это гораздо более сложное явление, и мы можем наблюдать гораздо больше. Например, мы можем полностью игнорировать выпавшую сторону, интересуясь вместо неё временем падения: $\Omega = \mathbb{R}_+ = (0; +\infty)$ *(в каких угодно единицах измерения). А может быть, нас интересует угол её поворота после падения? Тогда разумнее взять* $\Omega = [0; 2\pi)$. [1] *Сила удара об стол? Подойдёт тот же* $\Omega = \mathbb{R}_+$*, просто теперь его элементы будут иметь другой смысл.*

Если же нас интересует всё вместе, то придётся взять что-то вроде

$$\Omega = \{\text{орёл}, \text{решка}\} \times \mathbb{R}_+ \times [0; 2\pi) \times \mathbb{R}_+,$$

содержащее элементы вида (*решка*, 2.14, 5.73, 10.44). *И это ещё не всё, что можно измерить. Но мы не стремимся получить как можно более полное описание опыта. Нам нужна лишь упрощённая модель, достаточная для ответа на интересующие нас вопросы. В этом курсе нас будет интересовать лишь выпавшая сторона монетки, а значит, нам будет достаточно* $\Omega = \{$*орёл*, *решка*$\}$.

[1] При измерении угла в радианах полный оборот равен 2π. Это значит, что после поворота на угол 2π мы возвращаемся в исходное положение, т. е. углы 0 и 2π задают одно и то же положение. Чтобы не учитывать одно положение дважды, точку 2π обычно “выкалывают”, получая полуинтервал $[0; 2\pi)$.

Пример 2 (Вытягивание карты из колоды). *Допустим, у вас есть обычная колода из 52 игральных карт. Каждая карта в такой колоде соответствует комбинации одной из четырёх мастей* $S = \{$*червы*, *бубны*, *трефы*, *пики*$\}$ *и одного из тринадцати достоинств* $R = \{2, 3, \ldots, 10,$ *валет*, *дама*, *король*, *туз*$\}$.

Даже в простейшем опыте по выбору карты, если вас интересует лишь масть карты, то вы можете взять $\Omega = S$*. А если только достоинство, то* $\Omega = R$*. Обычно же нас будет интересовать, какая именно конкретная карта была выбрана. Для их описания мы можем либо перечислить все карты, т. е.* $\Omega = \{2$*червей*, 3*червей*, $\ldots$, *туз пик*$\}$*, либо напрямую задать их комбинацией масти и достоинства:*

$$\Omega = S \times R = \{(\text{масть}, \text{достоинство}) : \text{масть} \in S, \text{достоинство} \in R\}. \quad (1)$$

Оба варианта “легальны”.

Когда выше мы говорили о всех возможных случайных исходах опыта, мы неявно предполагали, что речь идёт о взаимно исключающих исходах. Монетка не может одновременно выпасть орлом и решкой, а выбранная карта быть одновременно червовой тройкой и тузом пик.

> Наша математическая модель случайного опыта предполагает, что в результате проведения этого опыта будет *реализован* ровно один элементарный исход $\omega^* \in \Omega$, соответствующий произошедшему исходу опыта. Мы не можем знать его заранее, но мы всегда знаем, что он есть, и он такой ровно один. Вообще вся случайность и неопределённость в теории вероятностей заключены в том, что мы не знаем, какой именно $\omega \in \Omega$ будет реализован.

Под конец чётко сформулируем определения, о которых здесь шла речь.

Определение 1. *Множество всех возможных исходов опыта будем называть* пространством элементарных исходов (sample space) *и обозначать всюду как* Ω. *Его элементы* $\omega \in \Omega$ *будем называть, соответственно,* элементарными исходами (outcomes). *Элемент, соответствующий единственному произошедшему исходу, будем называть* реализовавшимся исходом (occurred outcome).

События

Обычно нас интересует не один конкретный исход, а условие, которому удовлетворяют сразу несколько исходов. Например, бубновой картой старше валета могут оказаться дама, король или туз. Можно оставить в модели только ответы “да” и “нет”, но это само по себе не поможет найти их вероятности. Удобнее сохранить все 52 карты как элементарные исходы и объединить подходящие карты в отдельное множество. В пространстве Ω из (1) это множество имеет вид:

$$A = \{\text{выбрана бубновая карта старше валета}\} =$$

$$\{(\text{бубны}, \text{Дама}), (\text{бубны}, \text{Король}), (\text{бубны}, \text{Туз})\}.$$

Это приводит нас к следующему определению.

Определение 2. *Событием (event) будем называть любое подмножество* Ω. *Будем говорить, что событие* $A \subset \Omega$ *произошло, если был реализован один из его элементарных исходов* $\omega^* \in A$.

Пример 3 (Бросок игральной кости). *Пусть наш случайный опыт состоит в броске одной шестигранной игральной кости и пусть нас интересует количество выпавших очков. Тогда самым естественным пространством элементарных исходов является* $\Omega = \{1, 2, 3, 4, 5, 6\}$. *Тогда событие, состоящее в выпадении чётного числа, мы можем записать как* $A = \{2, 4, 6\}$. *Выпадение именно четвёрки задаётся как множество из одного элементарного исхода* $B = \{4\}$. *Выпадение числа, большего трёх, можно представить как* $C = \{4, 5, 6\}$ *и т. д.*

Интересно здесь то, что само Ω — это своё собственное подмножество, т. е. оно также является событием. У него есть своё собственное название.

Определение 3. *Событие Ω, состоящее из всех элементарных исходов, называется достоверным событием (certain event).*

Другой специальный случай — это пустое подмножество $\varnothing \subset \Omega$, которое также по определению является событием.

Определение 4. *Событие $\varnothing$ называется невозможным событием (impossible event).*

Раз события — это просто подмножества Ω, то к ним применимы и обычные операции на множествах. Более того, у основных операций есть очень простая и понятная интерпретация, которую необходимо знать. Действительно, событие $A \cup B$ произошло, если реализованный элементарный исход ω^* принадлежит этому объединению:

$$\omega^* \in A \cup B \iff \underbrace{(\omega^* \in A)}_{\text{произошло}A} \vee \underbrace{(\omega^* \in B)}_{\text{произошло}B}.$$

Получается, это эквивалентно тому, что произошло хотя бы одно из них: событие A, событие B или оба события.

Аналогично, событие $A \cap B$ происходит, когда

$$\omega^* \in A \cap B \iff \underbrace{(\omega^* \in A)}_{\text{произошло}A} \wedge \underbrace{(\omega^* \in B)}_{\text{произошло}B},$$

т. е. только когда произошли оба события A и B. Наконец, $\omega^* \in \bar{A}$ тогда и только тогда, когда $\omega^* \notin A$. Поэтому событие $\bar{A}$ состоит в том, что A не произошло.

Таблица 1: Операции над событиями

Событие	Как читать
$A \cup B$	произошло хотя бы одно
$A \cap B$	произошли оба
$\bar{A}$	A не произошло
$A \setminus B$	A произошло, B нет
$A \triangle B$	произошло ровно одно

Этих трёх операций уже достаточно, чтобы задавать и более сложные сочетания событий. Так, разность

$$A \setminus B = A \cap \bar{B}$$

состоит из исходов, принадлежащих A, но не B:

$$\omega^* \in A \setminus B \iff \underbrace{(\omega^* \in A)}_{\text{произошло}A} \wedge \underbrace{(\omega^* \notin B)}_{\text{не произошло}B}.$$

Поэтому разность происходит, когда событие A произошло, а B нет. Симметрическая разность

$$A \triangle B = (A \cap \bar{B}) \cup (B \cap \bar{A})$$

содержит исходы, принадлежащие ровно одному из событий A и B:

$$\omega^* \in A \triangle B \iff \underbrace{(\omega^* \in A) \wedge (\omega^* \notin B)}_{\text{произошло } A\text{, но не } B} \vee \underbrace{(\omega^* \in B) \wedge (\omega^* \notin A)}_{\text{произошло } B\text{, но не } A}.$$

То есть симметрическая разность происходит, когда произошло ровно одно из событий A и B.

Это не просто забавные интерпретации — это конкретные правила того, как формально следует интерпретировать разговорные фразы типа “найдите вероятность того, что оба события произойдут”.

Классическое определение вероятности

Наконец, у нас есть достаточно математического "словаря", чтобы задать вероятность в нашем первом, простейшем случае.

Определение 5 (классическое определение вероятности (classical definition of probability)). *Классической моделью на конечном пространстве элементарных исходов Ω будем называть модель, в которой все элементарные исходы равновозможны.*

Если A — событие для такого пространства элементарных исходов, то вероятность события A обозначается через $\mathbb{P}(A)$ и определяется как

$$\mathbb{P}(A) = \frac{|A|}{|\Omega|} = \frac{\textit{количество исходов, благоприятствующих } A}{\textit{количество исходов в } \Omega}.$$

Количество элементов конечного множества A обозначают через $|A|$ или $\#A$.

В некоторых англоязычных учебниках это определение называют *naive definition of probability*. Это связано с тем, что оно одновременно и естественно, и подразумевает пару ограничительных предположений о модели нашего эксперимента, из-за чего с лёгкостью может быть некорректно применено:

1. Пространство элементарных исходов Ω *конечно*;
2. Все элементарные исходы *равновозможны*.

С необходимостью конечности Ω трудно промахнуться, но соблюдение равновозможности требует особого внимания. Равновозможность может быть явно задана условием задачи либо принята как разумная модель эксперимента. Например, симметрия игральной кости или достаточно хорошее перемешивание колоды дают основания моделировать соответствующие исходы как равновозможные. Стороны монеты и игральной кости достаточно одинаковы, чтобы не вызывать существенных перевесов какой-либо из их сторон. Вытаскивание карты наугад из достаточно качественно перетасованной колоды также не должно давать никакой карте "преимущества".

Пример 4 (ошибка Д'Аламбера). *Д'Аламбер — известный французский учёный, широко известный как философ, математик и механик. Из его достижений вы, вероятнее всего, знакомы с признаком сходимости числовых рядов Д'Аламбера.* [2]

Рассмотрим вместе с ним следующую задачу: после двух бросков монеты какова вероятность того, что решка появится хотя бы раз? *Множество элементарных исходов здесь можно записать как $\Omega = \{PP, PO, OP, OO\}$.* [3] *Событие, чью вероятность от нас требуют найти, состоит из всех элементарных исходов с решкой: $A = \{PP, PO, OP\}$. Применяя классическую модель здесь, имеем, что*

$$\mathbb{P}(A) = \frac{|\{PP, PO, OP\}|}{|\{PP, PO, OP, OO\}|} = \frac{3}{4}.$$

[2] Если для числового ряда $\sum_{n=0}^{\infty} a_n$ существует такое число $0 < q < 1$, что, начиная с некоторого номера, выполняется неравенство $|a_{n+1}/a_n| < q$, то данный ряд абсолютно сходится; если же, начиная с некоторого номера, $|a_{n+1}/a_n| \geqslant 1$, то ряд расходится.

[3] Это определение короче, чем использованное нами до этого, но абсолютно ему эквивалентно.

Но Д'Аламбер рассуждал иначе — он спрашивал, зачем бросать вторую монетку после первого выпадения решки? Ведь действительно, после решки нет смысла бросать монетку второй раз, а значит, и вместо PP и PO мы будем наблюдать лишь P. Но тогда получается, что верным пространством элементарных исходов должно было быть сокращённое $\Omega' = \{P, OP, OO\}$, а исследуемым событием будет $A' = \{P, OP\}$. Применяя классическую модель уже к этому пространству, получаем другой ответ:

$$\mathbb{P}(A) = \frac{|\{P, OP\}|}{|\{P, OP, OO\}|} = \frac{2}{3}.$$

Но этот ответ неверен. Вы можете убедиться в этом сами, повторяя эксперимент, скажем, тысячу раз. Как именно — научим в конце этой темы.

Основная ошибка Д'Аламбера здесь в попытке применить классическую модель там, где она неприменима. Нет никаких причин предполагать, что исходы Ω' равновероятны. И это очевидно не так — вероятность выпадения решки на первом броске — $1/2$, и она не может измениться от того, что мы планируем делать после первого броска.

Для Ω равновозможность элементарных исходов следует из принятой нами модели бросков: монета симметрична, а второй бросок проводится тем же способом независимо от результата первого. Иными словами, после любого результата первого броска на втором снова одинаково возможны решка и орёл. [4] *Здесь действительно остаётся проблема, подмеченная Д'Аламбером — Ω не соответствует разумному проведению эксперимента, где мы останавливаемся после первой решки. Но её легко обойти, заметив, что неэффективная версия эксперимента, когда мы* всегда *бросаем вторую монету, должна давать нам ровно тот же ответ, что и эффективная версия. Если решка уже выпала на первом броске, дополнительный второй бросок никак не может изменить ответ на вопрос "выпала ли решка хотя бы раз". Если же первым выпал орёл, второй бросок проводится в обеих версиях эксперимента одинаково.*

[4] Это не математическое доказательство — равновозможность исходов нельзя строго вывести из одной только постановки задачи, сформулированной на обыденном языке. По сути наше решение "по соображениям симметрии" является частью *формализации* этой задачи: мы принимаем равновозможность исходов как разумную модель реального эксперимента. Сама теория вероятностей не может обосновать этот выбор модели — она описывает его последствия.

> Важным руководством к действию при применении классической модели является также то, что следует сначала считать все объекты различимыми. [5] Если подбрасываются две монеты и мы не различаем их, то получаем лишь три результата:
>
> $$\Omega = \{\text{решка–решка},\ \text{решка–орёл и орёл–орёл}\}.$$
>
> Однако для различимых монет равновозможных исходов четыре:
>
> $$\Omega = \{(\text{решка, решка}),\ (\text{решка, орёл}),\ (\text{орёл, решка}),\ (\text{орёл, орёл})\}.$$
>
> Результат "одна решка и один герб" соответствует сразу двум из них. Поэтому три первоначальных результата не равновозможны и приписать каждому вероятность 1/3 нельзя.

[5] Это правило относится к рассматриваемым здесь классическим моделям. Для тождественных квантовых частиц различимость вообще перестаёт быть допустимым предположением: перестановка двух одинаковых частиц не создаёт нового физически различимого состояния. Это приводит, в частности, к статистике Бозе—Эйнштейна и статистике Ферми—Дирака, отличным от классической статистики Максвелла—Больцмана.

Для успешного применения определения классической модели нам необходимо:

1. Выбрать правильное и удобное пространство элементарных исходов Ω;
2. Описать искомое событие A через элементы Ω;
3. Посчитать $|A|$ и $|\Omega|$;
4. Поделить одно на другое: $|A|/|\Omega|$.

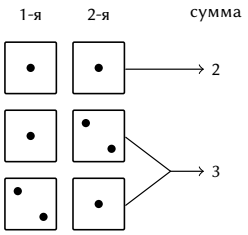
Проиллюстрируем это на решении задачи.

Задача 1. Эксперимент состоит в подбрасывании пары игральных костей. Результаты бросков независимы, а все грани каждой кости равновероятны. Найдите вероятность того, что

1. Сумма выпавших очков окажется равна трём;
2. Сумма выпавших очков окажется не меньше пяти.

Решение. Начнём с построения пространства элементарных исходов. Так как оба вопроса задачи зависят лишь от суммы очков на игральных костях, то может возникнуть желание взять в качестве набора исходов $\{2, 3, \dots, 12\}$ (наименьшее количество очков мы получаем при выпадении двух единиц). Однако тогда мы не сможем применить классическую вероятностную модель, так как представленные 11 исходов не будут равновероятны.

Действительно, представьте, что кости различимы: будем называть их первой и второй. Тогда два можно получить лишь одним способом, когда на каждой кости выпадает одна фиксированная грань, в то время как три очка можно получить двумя способами.



В качестве пространства элементарных исходов будем брать все возможные пары фиксированных граней, так как нет причин полагать, что одна из пар будет вероятнее другой:

$$\Omega = \{(i, j) \,:\, i, j \in \{1, 2, 3, 4, 5, 6\}\}.$$

Очевидно, что $|\Omega| = 36$.

Как мы уже указали выше, три очка можно получить двумя способами, что даёт нам событие

$$A := \{\text{на двух костях в сумме выпало три очка}\} = \{(1, 2), (2, 1)\},$$

откуда $\mathbb{P}(A) := |A|/|\Omega| = 1/18$. Заметим, что вероятность двух очков в два раза меньше:

$$\mathbb{P}(\{\text{на двух костях в сумме выпало два очка}\}) = \mathbb{P}(\{(1, 1)\}) = 1/36.$$

Для нахождения вероятности события

$$B = \{\text{на двух костях в сумме выпало не меньше пяти очков}\}$$

проще, наоборот, посчитать количество пар, дающих в сумме менее пяти очков, составив соответствующее событие:

$$\begin{aligned}\overline{B} = \Omega \backslash B &= \{\text{на двух костях выпало менее пяти очков}\} \\ &= \{(1, 1), (1, 2), (2, 1), (2, 2), (3, 1), (1, 3)\}.\end{aligned}$$

$$\mathbb{P}(B) = \frac{|\Omega| - |\overline{B}|}{|\Omega|} = \frac{36 - 6}{36} = \frac{5}{6}.$$

Комбинаторные принципы

Классическое определение сводит нахождение вероятности событий к подсчёту всевозможных комбинаций объектов. Это делает необходимым повторить основные комбинаторные понятия.

Принцип сложения применяется, когда интересующие нас объекты можно разбить на несколько непересекающихся случаев. Если объектов первого вида существует a_1, второго — a_2 и так далее до k-го вида, то общее количество объектов равно

$$a_1 + a_2 + \ldots + a_k.$$

Действительно, если каждый интересующий нас объект относится в точности к одному из этих случаев, то, складывая количества объектов в каждом случае, мы посчитаем каждый объект ровно один раз.

Например, если на полке стоит 7 учебников по математике, 5 по физике и 3 по программированию, то выбрать одну книгу одного из этих трёх видов можно

$$7 + 5 + 3 = 15$$

способами.

Принцип умножения проще всего понимать, представляя, что некоторый объект строится как последовательность шагов. У нас есть a_1 разных способов завершить первый шаг, и, какой бы способ мы ни выбрали, у нас будет a_2 способов завершить второй шаг, и так далее до k-го шага. Тогда количество способов завершить все шаги равно

$$a_1 a_2 \ldots a_k.$$

Действительно, предположим, что после $i - 1$ шагов есть N_{i-1} частичных завершений нашего процесса. Каждое имеет в точности a_i возможных продолжений на i-м шаге, поэтому $N_i = N_{i-1} a_i$. Начиная с $N_0 = 1$, имеем

$$N_k = a_1 a_2 \ldots a_k.$$

Из этого принципа без труда получается, что количество перестановок n объектов равно $n!$. И правда, если мы хотим расставить n объектов в каком-либо порядке, то на первое место мы можем выбрать один объект n способами, на второе — $n - 1$ способами, на третье — $n - 2$ способами и так далее, вплоть до последнего шага, когда у нас остаётся лишь один способ разместить последний объект на последнем месте:

$$n(n-1)(n-2)\ldots 3 \cdot 2 \cdot 1 = n!.$$

Обозначим через $S^{(n)}$ множество всех перестановок $1, 2, \ldots, n$, $|S^{(n)}| = n!$.

Задача 2. n книг случайным образом расставляются на книжной полке, причём все их перестановки равновероятны. Две из них составляют двухтомное произведение. Какова вероятность, что его тома окажутся стоящими рядом?

Решение. Понятно, что все перестановки книг считаются равновероятными. Если мы перенумеруем все книги, присвоив интересующим нас томам номера 1 и 2, то в качестве пространства всех элементарных исходов мы можем взять $\Omega = S^{(n)}$, $|\Omega| = n!$.



Рис. 2: $n = 10$ книг

Чтобы посчитать количество перестановок всех книг, оставляющих наши тома рядом, объединим двухтомник в один объект. Например, представьте, что вы поместили их вместе в коробку. Количество перестановок оставшихся $n - 2$ книг и коробки равно $|S^{(n-1)}| = (n-1)!$.



Рис. 3: $n - 1 = 9$ объектов

Если мы также учтём, что тома могут быть расположены в коробке двумя разными способами, то получим как раз все перестановки, оставляющие их рядом. Таким образом, ответ равен

$$\frac{2(n-1)!}{|\Omega|} = \frac{2}{n}.$$

Подумайте, как изменится ответ, если нас интересует, что рядом будут стоять книги k-томника ($1 \leq k \leq n$). Ответ: $\dfrac{k!(n-k+1)!}{n!}$.

Принцип деления. Иногда удобнее сначала посчитать один и тот же объект несколько раз. Если при таком подсчёте каждый объект учтён ровно r раз, то для получения настоящего количества объектов достаточно разделить результат на r. Если мы считали разные представления одних и тех же объектов, то

$$\#\{\text{объекты}\} = \frac{\#\{\text{представления}\}}{r}.$$

Например, пусть в группе n человек и каждый должен один раз пожать руку каждому другому человеку. Посчитаем сначала не сами рукопожатия, а более подробные записи вида “кто пожал руку кому”. Первого человека можно выбрать n способами, а второго — $n - 1$ способами, поэтому таких записей

$$n(n-1).$$

Но каждое настоящее рукопожатие представлено среди них ровно дважды: рукопожатие Ани и Бориса записано один раз как “Аня пожала руку Борису” и ещё один раз как “Борис пожал руку Ане”. Следовательно, количество различных рукопожатий равно

$$\frac{n(n-1)}{2}.$$

Способы выбрать k объектов из n

Наиболее частый подсчёт, который нам пригодится в комбинаторных задачах, — это нахождение количества способов выбрать k объектов из совокупности n объектов.

Представьте, что у вас есть урна с n хорошо перемешанными шарами, пронумерованными от 1 до n. Самая простая постановка вопроса здесь такая: “Вы вытаскиваете шары из урны k раз подряд и записываете вытянутый номер, каждый раз кладя шар назад и снова хорошенько перемешивая шары. Сколько всего есть разных возможных числовых последовательностей?” Такой выбор k из n объектов называется выбором *с учётом порядка и с возвращением*, так как мы каждый раз возвращаем шары назад в урну и учитываем порядок, в котором записываем их номера. [6]

[6] Способ выбора определяется ответами на два независимых вопроса: можно ли выбирать один объект несколько раз и важен ли порядок выбора.

Количество таких способов посчитать нетрудно. На каждом из k извлечений у нас есть n разных способов сделать следующий выбор, поэтому, согласно принципу умножения, всего получаем

$$n \cdot n \cdot \ldots \cdot n = n^k$$

возможных последовательностей.

Пример 5 (Выбор двух чисел из трёх). *Выберем два числа из* $\{1, 2, 3\}$ *всеми четырьмя способами. В случаях без учёта порядка будем для определённости записывать меньшее число первым.*

1. *без возвращения и без учёта порядка:* $(1, 2), (1, 3), (2, 3)$*;*
2. *без возвращения и с учётом порядка:* $(1, 2), (2, 1), (1, 3), (3, 1), (2, 3), (3, 2)$*;*
3. *с возвращением и без учёта порядка:* $(1, 1), (1, 2), (1, 3), (2, 2), (2, 3), (3, 3)$*;*
4. *с возвращением и с учётом порядка:* $(1, 1), (1, 2), (2, 1), (1, 3), (3, 1), (2, 2), (2, 3), (3, 2), (3, 3)$.

В ситуации, когда мы каждый раз вытаскиваем шар, но никогда не возвращаем его назад, то есть каждый раз достаём шар с новым номером, мы также можем применить принцип умножения. Но тут, подобно случаю с перестановками, на каждом последующем шаге у нас будет на одну опцию меньше. [7]

[7] Без возвращения можно выбрать не больше n объектов: $k \leqslant n$. Если $k > n$, способов нет. При $k = 0$ есть ровно один способ — ничего не выбрать. По соглашению $0! = 1$, поэтому приведённые ниже факториальные формулы для A_n^k и C_n^k применимы при $0 \leqslant k \leqslant n$. Чтобы понять, почему последний множитель имеет вид $n - (k - 1)$, подумайте, сколько шаров уже извлечено перед k-м шагом.

$$n \cdot (n-1) \cdot (n-2) \cdot (n-3) \cdot \ldots \cdot (n-(k-1)) = \frac{n!}{(n-k)!}.$$

Эта величина соответствует количеству способов выбрать k из n объектов *с учётом порядка и без возвращения*. По аналогии с биномиальным коэффициентом будем обозначать её через

$$A_n^k := \frac{n!}{(n-k)!}.$$

Кстати о биномиальном коэффициенте. Что, если нам не важно, в каком порядке мы выбирали шары, а важно только, какие в итоге выбрали? Для этого нам нужно “забыть порядок”. Каждому множеству из k шаров соответствует ровно $k!$ различных перестановок. Так как мы уже знаем общее количество перестановок, то из принципа деления получаем, что количество множеств из k шаров равно

$$\frac{A_n^k}{k!} = \frac{n!}{(n-k)!k!} = C_n^k,$$

то есть биномиальному коэффициенту[8].

[8] обычно обозначаемому в англоязычной литературе как $\binom{n}{k}$.

Задача 3. Из колоды, насчитывающей 36 карт, наугад извлекаются 6 карт. Какова вероятность того, что

1. среди них окажется туз пик;
2. среди них окажется ровно один туз;
3. среди них окажутся ровно две бубновые карты;
4. среди них окажется хотя бы одна бубновая карта?

План решения. Во всех пунктах этой задачи нас интересует итоговый набор карт, а не порядок, в котором мы их получали. В такой ситуации в качестве пространства элементарных исходов Ω мы можем взять все возможные способы выбрать 6 карт из 36 без учёта порядка и без возвращения (почему без возвращения?), то есть $|\Omega| = C_{36}^6$.

Чтобы найти вероятность вытащить туз пик, нам необходимо посчитать количество способов выбрать 5 карт (одно место уже занял туз пик) из 35 (мы не можем вытащить ещё один туз пик): C_{35}^5. Поделив это на всё количество элементарных исходов, получим

$$\mathbb{P}(\text{среди них окажется туз пик}) = \frac{C_{35}^5}{C_{36}^6}.$$

Для подсчёта количества способов выбрать ровно один туз разделим все карты на две группы — тузы (4 карты) и не тузы (32 карты), а затем выберем из них одну и пять карт соответственно:

$$\mathbb{P}(\text{среди них окажется ровно один туз}) = \frac{C_4^1 C_{32}^5}{C_{36}^6}.$$

Самостоятельно сделайте третий пункт с двумя бубновыми картами по аналогии со вторым. Ответ к третьему пункту: $\dfrac{C_9^2 C_{27}^4}{C_{36}^6}$.

В последнем пункте проще всего перейти к обратному событию, когда мы не вытащили ни одной бубновой карты, вероятность чего равна

$$\frac{C_{27}^6}{C_{36}^6}$$

(почему?). Тогда вероятность вытащить хотя бы одну бубновую карту равна

$$1 - \frac{C_{27}^6}{C_{36}^6}.$$

Задача 4. У человека в кармане n ключей, из которых только один подходит к его двери. Ключи последовательно извлекаются до тех пор, пока не появится нужный ключ. При каждой попытке ключ выбирают с равными шансами среди ключей, находящихся в кармане. Найти вероятность, что нужный ключ появится при k-м извлечении, если

Таблица 2: Четыре способа выбора

	с возвращением	без возвращения
с учётом порядка	n^k	$A_n^k = \frac{n!}{(n-k)!}$
без учёта порядка	C_{n+k-1}^k	$C_n^k = \frac{n!}{k!(n-k)!}$

Формулы в правом столбце применимы при $0 \leqslant k \leqslant n$. При $k > n$ выбор без возвращения невозможен.

Вывод формулы C_{n+k-1}^k для выбора с возвращением без учёта порядка мы опускаем. Его можно найти по запросу “Метод шаров и перегородок”: Википедия на русском и на английском.

1. он пробует каждый ключ лишь раз и после перекладывает его в другой карман;
2. он каждый раз кладёт ключ обратно в общую кучу и каждый раз может вытащить любой из ключей.

В первом случае $1 \leq k \leq n$, а при $k > n$ вероятность равна нулю. Во втором случае $k \geq 1$.

План решения. В данной задаче основную сложность составляет построение подходящего пространства элементарных исходов: длина последовательности вытаскиваемых ключей зависит от того, в какой момент человек вытащит нужный ключ. Например, он может сразу вытащить требуемый ключ, а может сначала попробовать три других, и совершенно непонятно, почему такие исходы должны быть равновероятными (и должны ли вообще?).

Один из вариантов решить эту проблему для первого пункта задачи — заставить человека перебирать все ключи даже после того, как он открыл дверь. Такое изменение эксперимента не изменит вероятность вытащить верный ключ именно на k-й попытке, зато в качестве элементарных исходов можно будет взять просто все перестановки ключей, которые уже будут равновероятными. Всего таких перестановок $n!$. Если подходящий ключ стоит на k-м месте, остальные $n - 1$ ключей можно переставить $(n - 1)!$ способами. Значит, при $1 \leqslant k \leqslant n$ искомая вероятность равна $(n - 1)!/n! = 1/n$.

Во втором пункте так сделать не получится, так как при возвращении ключей назад человек может бесконечно долго пытаться открыть дверь. Здесь эксперимент можно переформулировать как совершение человеком ровно k попыток, так как дальнейшие действия также не важны для искомой вероятности. Всего последовательностей из k извлечений n^k. Для первого успеха на k-й попытке каждое из первых $k - 1$ извлечений должно дать один из $n - 1$ неподходящих ключей, а последнее — единственный подходящий. Поэтому благоприятных последовательностей $(n - 1)^{k-1}$.

Ответы: $\dfrac{1}{n}$ и $\dfrac{(n-1)^{k-1}}{n^k}$.

Парадокс дней рождений

Парадокс[9] дней рождений состоит в том, что если мы рассмотрим группу людей в комнате, то шанс у хотя бы двух из них иметь один и тот же день рождения довольно высок. Гораздо выше, чем можно подумать. Этот же вопрос возникает при работе с хэш-таблицами. Хэш-таблица распределяет объекты по бакетам — ячейкам, номер которых вычисляется хэш-функцией по ключу объекта. Если два разных объекта получают один и тот же номер бакета, возникает *коллизия*. Нас интересует, насколько вероятна хотя бы одна такая коллизия.

У дней рождений и хэш-таблиц есть кое-что общее: бакетам соответствуют дни года, а объектам — люди. Совпадение дней рождений тогда соответствует коллизии. Для расчётов будем полагать, что у каждого из нас равные шансы родиться в любой из дней года[10].

[9] Это так называемый “веридический парадокс”, который лишь кажется абсурдным, но на самом деле полностью соответствует логике и в данном случае математике.

[10] В действительности у дней рождений есть достаточно явно выраженная “сезонность”.

Оказывается, что уже среди 23 людей вероятность хоть у какого-то дня рождения совпасть превышает 1/2. У 50 человек шансы на совпадение дней рождений уже достигают 97%, а у ста людей они равны 99.99997%[11].

[11] При этом 100% они достигают только при 366 людях, когда иной вариант просто невозможен.

Давайте поймём, как рассчитать эти вероятности. Пусть у хэш-таблицы есть n бакетов и нам нужно разместить в них k разных объектов. Для задачи о днях рождения $n = 365$, а k — число людей. Через h_i обозначим номер бакета i-го объекта или день рождения i-го человека. В качестве нашего пространства элементарных исходов возьмём все последовательности из k таких номеров:

$$\Omega = \{(h_1, \dots, h_k) \,:\, h_i \in \{1, 2, \dots, n\}\}.$$

В упрощённой модели мы k раз подряд независимо выбираем один из n возможных номеров с равными вероятностями, с возвращением (так как номера могут повторяться) и с учётом порядка (так как нам важно, какой объект попал в какой бакет). То есть $|\Omega| = n^k$.

Нас интересует событие A, состоящее в том, что ни один номер бакета среди k объектов не повторился. В нём лежат все такие распределения объектов, в которых в каждый бакет попало не больше одного объекта. Сначала пусть $1 \leqslant k \leqslant n$. Мы можем их пересчитать, просто найдя количество способов выбрать k номеров бакетов из n возможных без возвращения (так как мы не хотим дать им возможность повториться) и с учётом порядка (так как мы считаем элементы Ω, в которых порядок учитывается). Поэтому, как мы уже знаем, $|A| = A_n^k$, а значит,

$$\begin{aligned}\mathbb{P}(A) &= \frac{A_n^k}{n^k} = \frac{n \cdot (n-1) \cdot \ldots \cdot (n-k+1)}{n^k} \\ &= 1 \cdot \left(1 - \frac{1}{n}\right) \cdot \left(1 - \frac{2}{n}\right) \cdot \ldots \cdot \left(1 - \frac{k-1}{n}\right).\end{aligned}$$

Поэтому вероятность хотя бы одного совпадения равна

$$\mathbb{P}(\overline{A}) = 1 - \frac{A_n^k}{n^k}.$$

Если $k > n$, хотя бы одно совпадение неизбежно: $\mathbb{P}(A) = 0$ и $\mathbb{P}(\overline{A}) = 1$.

Пример 6 (Коллизия в почти пустой хэш-таблице). *Пусть в таблице* 10 000 *бакетов и мы размещаем в ней* 100 *объектов по описанной модели. Тогда вероятность хотя бы одной коллизии равна*

$$\mathbb{P}(\overline{A}) = 1 - \frac{A_{10\,000}^{100}}{10\,000^{100}} \approx 0{,}3914.$$

То есть коллизия возникает примерно в 39% *случаев, хотя число объектов составляет всего* 1% *от числа бакетов.*

Дополнительная оценка. Следующее рассуждение можно пропустить при первом чтении. Для $1 \leqslant k \leqslant n$, используя неравенство $1 - x \leqslant e^{-x}$, получаем

$$\begin{aligned} \mathbb{P}(A) &\leqslant 1 \cdot e^{-\frac{1}{n}} \cdot e^{-\frac{2}{n}} \cdot \ldots \cdot e^{-\frac{k-1}{n}} \\ &= \exp\left(-\frac{1}{n}\sum_{i=1}^{k-1} i\right) \\ &= \exp\left(-\frac{k(k-1)}{2n}\right). \end{aligned}$$

Из этой оценки можно понять, почему порог для дней рождений близок к 23. Для грубой оценки заменим $k(k-1)$ на k^2 и приравняем полученное выражение к $1/2$:

$$e^{-\frac{k^2}{2n}} = \frac{1}{2}, \qquad \frac{k^2}{2n} = \ln 2 \approx 0.69.$$

Отсюда при $n = 365$

$$k^2 \approx 2 \cdot 0.69n = 2 \cdot 0.69 \cdot 365 = 503.7, \qquad k \approx 22.44.$$

Это приближённый расчёт: точное произведение даёт переход вероятности совпадения через $1/2$ при $k = 23$.

Если вы хотите держать вероятность хотя бы одной коллизии в хэш-таблице примерно на одном уровне, то в этой оценке нужно держать величину k^2/n постоянной. То есть количество бакетов n должно расти пропорционально квадрату количества объектов k^2. Это требование относится именно к сохранению вероятности отсутствия коллизий. В обычной хэш-таблице коллизии допускаются и обрабатываются, поэтому само появление коллизии ещё не означает, что таблица работает плохо.

Задачи к лекции

Задача 5. Ребёнок играет с десятью буквами разрезной азбуки: А, А, А, Е, И, К, М, М, Т, Т. Какова вероятность того, что при случайном расположении букв в ряд он получит слово “МАТЕМАТИКА”?

План решения.

1. Задайте пространство элементарных исходов (считайте все карточки, даже те, на которых написаны одинаковые буквы, различными);
2. Рассмотрите конкретную расстановку карточек, соответствующую слову “МАТЕМАТИКА”. Карточки с какими буквами можно переставить, не изменив слово?
3. Каково общее количество перестановок таких букв?

Ответ: $24/10!$.

Задача 6. Найти вероятность, что в случайной перестановке $1, 2, \dots, n$ числа $1, 2, 3$ находятся в порядке возрастания (но не обязательно рядом). Например, нам подходят $1, 6, 4, 2, 5, 3, 7$ или $7, 4, 1, 2, 5, 3, 6$.

Решение. В качестве пространства элементарных исходов можно взять просто $\Omega = S^{(n)}$.

Пусть A — множество всех таких перестановок $1, 2, \dots, n$, что числа $1, 2, 3$ находятся в них в порядке возрастания. Такие перестановки можно строить, например, следующим образом (пример приводится для $n = 7$):

1. Для построения перестановки будем распределять числа по n упорядоченным “коробкам”:

?	?	?	?	?	?	?

2. Располагаем все числа, кроме $\{1, 2, 3\}$ (всего $n - 3$ чисел), по этим коробкам, выбрав для них $n - 3$ мест. Это требуется делать без возвращения (нельзя положить два числа в одну коробку) и с учётом порядка (важно, что, например, 4 лежит во второй коробке, а 6 — в седьмой, а не наоборот). То есть, выбрав места $(2, 5, 7, 1)$, мы получаем расположение:

7	4	?	?	5	?	6

3. У нас остаётся ровно три пустых коробки, куда и кладём числа $1, 2, 3$ в порядке возрастания:

7	4	1	2	5	3	6

Согласно второму пункту этого алгоритма мы можем так построить A_n^{n-3} различных перестановок.

А значит, ответ равен

$$\mathbb{P}(A) = \frac{A_n^{n-3}}{n!} = \frac{n!}{3!n!} = \frac{1}{6}.$$

Задача 7. В лифт восьмиэтажного дома на первом этаже входят 5 человек. Независимо от других, каждый может выйти с равными шансами на любом этаже, начиная со второго. Какова вероятность того, что

1. все выйдут на четвёртом этаже;
2. все пятеро выйдут на одном и том же этаже;
3. все пятеро выйдут на разных этажах?

План решения. Если считать всех людей разными (что всегда стоит делать), пространство элементарных исходов будет соответствовать способам выбрать пять этажей из доступных семи (с возвращением или без? с учётом порядка или без?). Запишите это пространство. Ответы на первые два пункта должны стать очевидны. Подумайте, как посчитать количество исходов, соответствующих третьему пункту.

Ответы: $\dfrac{1}{7^5}$, $\quad \dfrac{1}{7^4}$, $\quad \dfrac{6!}{7^4 \cdot 2}$.

Задача 8. Из чисел $1, 2, \dots, 49$ наугад выбираются и фиксируются 6 чисел, считающихся выигрышными. Некто, желающий выиграть, наугад называет свои 6 чисел из 49. Какова вероятность, что среди названных им чисел окажется не менее трёх выигрышных?

Решение. Здесь нас снова не интересует порядок, в котором мы выбираем наши шесть чисел, поэтому в качестве пространства элементарных исходов Ω мы возьмём множество всех способов выбрать 6 чисел из 49, $|\Omega| = C_{49}^6$.

Для решения задачи ответим сначала на более простой вопрос: сколько есть способов вытащить эти 6 чисел так, чтобы среди них было ровно k выигрышных?

Для этого, как и прежде, достаточно разбить набор из 49 чисел на две группы: 6 выигрышных и 43 обычных, а затем посчитать количество способов выбрать из первых k, а из вторых — $6 - k$ чисел: $C_6^k C_{43}^{6-k}$.

Чтобы получить ответ, достаточно просуммировать количества способов для $k = 3, 4, 5, 6$ и поделить на $|\Omega|$:

$$\frac{\sum_{k=3}^{6} C_6^k C_{43}^{6-k}}{C_{49}^6}.$$

Задача 9. Каждый из n студентов выбирает одну из k аудиторий с равными шансами, независимо от остальных студентов. Какова вероятность, что в первой аудитории окажется n_1 студентов, во второй — n_2 студентов, ..., в k-й аудитории — n_k студентов, если $n_1 + \dots + n_k = n$?

План решения.

1. Случайное распределение означает, что каждый студент выбирает себе одну из k аудиторий. Таким образом, чтобы выбрать каждому студенту по аудитории, мы можем просто выбрать последовательность n чисел из $\{1, 2, \dots, k\}$ или, что то же самое, выбрать n чисел с возвращением (почему?) и с учётом порядка (почему?).

2. Для распределения студентов по аудиториям так, чтобы в каждой аудитории находилось нужное количество студентов, необходимо сначала выбрать в первую n_1 из всех n студентов ($C_n^{n_1}$ способов), затем n_2 из оставшихся $n - n_1$ студентов ($C_{n-n_1}^{n_2}$ способов), затем n_3 из оставшихся $n - n_1 - n_2$ и т. д. Затем полученная формула должна упрощаться до $\dfrac{n!}{n_1! n_2! \dots n_k!}$.

Ответ: $\dfrac{n!}{k^n n_1! n_2! \dots n_k!}$.

Задача 10. Каждый из n различных шаров помещают в один из n ящиков. Ящик для каждого шара выбирают с равными шансами, независимо от размещения остальных шаров. Какова вероятность, что при этом ровно один ящик окажется пустым?

План решения.

1. Сколько всего есть способов разместить n шаров по n ящикам, если в каждый ящик умещается любое количество шаров?

2. Поймите, что любое расположение шаров, при котором ровно один ящик остаётся пустым, подразумевает, что ровно один ящик пустой, ровно один содержит два шара, а все остальные — по одному.

3. Сколько всего способов выбрать два особых ящика (без шаров и с двумя шарами)? Так как эти особые ящики различны, делать это нужно с учётом порядка.

4. Используйте формулу для размещения студентов по комнатам из предыдущей задачи, но для шаров и ящиков.

Ответ: $\dfrac{C_n^2 n!}{n^n}$.

Задача 11. *Задача повышенной сложности.* Группа, состоящая из $3n$ юношей и трёх девушек, делится произвольным образом на три равные по количеству подгруппы. Все разбиения на три подгруппы одинакового размера считаются равновероятными. Какова вероятность, что все девушки окажутся в разных подгруппах?

План решения.

1. Пропустите в этой задаче явное построение пространства элементарных исходов и просто посчитайте, сколькими способами можно выбрать сначала в первую группу $n+1$ человека из $3n+3$, а затем ещё $n+1$ во вторую из оставшихся $2n+2$. Заметьте, что последняя группа сформируется автоматически.

2. Повторите то же самое, но теперь выбирайте в каждую группу отдельно n юношей и одну девушку.

Ответ:

$$\frac{6C_{3n}^n C_{2n}^n}{C_{3n+3}^{n+1} C_{2n+2}^{n+1}}.$$

Лекция 2. Общее определение вероятности

Геометрическая вероятностная модель

В классической модели мы считали исходы. Но как быть, если опыт состоит в выборе точки на отрезке? Таких исходов бесконечно много, и прежнюю формулу применить нельзя. При равномерном выборе точки естественно сравнивать длины: вероятность попасть в часть отрезка равна отношению её длины к длине всего отрезка. Эту идею можно перенести на площади и объёмы. Так мы приходим к *геометрическому определению вероятности.*

Это определение применимо в тех ситуациях, когда мы равномерно выбираем точку в каком-либо *ограниченном* геометрическом

множестве Ω. В одномерном случае это может быть, например, отрезок прямой или окружность. В двумерном — квадрат или область, ограниченная эллипсом. В трёхмерном — тетраэдр, шар или любое другое тело. Нам нужно, чтобы множество Ω обладало конечным и положительным "объёмом" $\mu(\Omega)$. При этом в курсе мы будем притворяться, что каждому его подмножеству $A \subset \Omega$ можно приписать соответствующий "объём" $\mu(A)$[12]. Тогда событиями будем называть подмножества $A \subset \Omega$, а вероятность определять через

$$\mathbb{P}(A) = \frac{\mu(A)}{\mu(\Omega)}.$$

[12] Здесь "объём" понимается в общем смысле: это длина в одномерном случае, площадь — в двумерном, обычный объём — в трёхмерном и его обобщение — в пространствах большей размерности.

В действительности существуют экзотические множества точек, которым нельзя приписать такой "объём", сохранив все его привычные свойства. На них не так просто "наткнуться", поэтому для задач этого курса принятое упрощение не создаст проблем.

Данное определение напоминает классическое в том, что они оба делят меру части на меру всего. Но особенное отличие этой модели от модели классической вероятности в том, что у отдельных элементарных исходов (т. е. точек) всегда нулевая мера, независимо от того, имеем ли мы дело с объёмом или длиной. На первый взгляд абсурдное следствие здесь в том, что вероятность быть выбранной для каждой точки равна нулю. Но иначе и быть не могло, ведь все точки должны быть равновероятны, но при этом их бесконечное число. А значит, мы не можем назначить им никакую положительную вероятность.

Это свойство стоит интерпретировать так, что вероятность выбрать заранее помеченную точку равна нулю. То же самое оказывается верным и для любого заранее выбранного конечного набора точек, и даже для счётного набора точек.[13] При этом какая-то точка всё же будет выбрана, но всё, что мы можем оценить, — это вероятность того, попадёт ли она в какое-то заранее выбранное множество или же нет.

[13] Бесконечное множество называют счётным, если его элементы можно перечислить: первый, второй, третий и так далее, причём каждый элемент окажется в этом списке. Например, так устроено множество $\{1, 1/2, 1/3, \ldots\}$. Все точки отрезка $[0, 1]$ перечислить таким способом невозможно: их множество несчётно. Говорят, что отрезок содержит континуум точек.

Правило сложения вероятностей, которое мы сформулируем ниже, относится к конечным и счётным наборам несовместных событий. Поэтому нельзя получить вероятность всего отрезка, просто "сложив нули" для всех его точек.

Задача 1. Отрезок длины l ломается в точке, равномерно выбранной на нём. Какова вероятность, что длина наибольшего обломка превосходит $2l/3$?

Решение. Обозначим через x расстояние от левого конца отрезка до точки разлома. Длины обломков равны x и $l - x$. Один из них длиннее $2l/3$, если $x < l/3$ или $x > 2l/3$. Благоприятные точки занимают два участка общей длиной $2l/3$, поэтому искомая вероятность равна

$$\frac{2l/3}{l} = \frac{2}{3}.$$

Задача 2. Точка равномерно выбирается в квадрате. Найти вероятность того, что точка попадёт в круг, вписанный в этот квадрат.

Решение. Обозначим через a сторону квадрата, а через A — событие попадания в круг. Радиус круга равен $a/2$, поэтому

$$\mathbb{P}(A) = \frac{\pi(a/2)^2}{a^2} = \frac{\pi}{4}.$$

Операции над вероятностями событий

Мы уже ввели два способа задания вероятности. Возникает вопрос — мы всё что угодно можем назвать вероятностью? Если бы это было так, то нам было бы трудно построить общую теорию. Есть несколько общих характеристик, которые математики требуют от функции на событиях (подмножествах Ω), чтобы она имела право называться вероятностью. И они проще, чем может показаться.

Условие нормированности очень просто:

$$\mathbb{P}(\Omega) = 1.$$

Это очень простое и естественное требование, говорящее, что вероятность вообще всех исходов — это именно единица.

Легко видеть, что этому определению удовлетворяют и классическое

$$\mathbb{P}(\Omega) = \frac{|\Omega|}{|\Omega|} = 1,$$

и геометрическое определения

$$\mathbb{P}(\Omega) = \frac{\mu(\Omega)}{\mu(\Omega)} = 1.$$

Определение 1 (Достоверное событие). *Пространство элементарных исходов Ω также называется достоверным событием, т. е. таким, которое обязательно произойдёт.*

Условие неотрицательности также очень естественно — для любого события $A \subset \Omega$

$$\mathbb{P}(A) \geqslant 0.$$

Другими словами, вероятность не может быть отрицательна. Это соответствует любому её разумному толкованию, и, очевидно, оба известных нам определения ему удовлетворяют.

Условие счётной аддитивности требует от нас пары новых определений.

Определение 2 (Несовместные события). *События A и B называются несовместными, если*

$$A \cap B = \varnothing.$$

Определение 3 (Попарно несовместные события). *События $A_1, A_2, \ldots$ называются попарно несовместными, если для любых $i \neq j$ выполняется*

$$A_i \cap A_j = \varnothing.$$

Пример 1. *Пусть $\Omega = \{1, 2, 3\}$ и*

$$A_1 = \{1, 2\}, \qquad A_2 = \{2, 3\}, \qquad A_3 = \{1, 3\}.$$

Тогда

$$A_1 \cap A_2 \cap A_3 = \varnothing,$$

то есть все три события не могут произойти одновременно. Однако пересечение каждой пары непусто:

$$A_1 \cap A_2 = \{2\}, \qquad A_1 \cap A_3 = \{1\}, \qquad A_2 \cap A_3 = \{3\}.$$

Поэтому эти события не являются попарно несовместными.

Для попарно несовместных событий $A_1, A_2, \ldots$ условие счётной аддитивности имеет вид

$$\mathbb{P}\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} \mathbb{P}(A_i).$$

Пример 2. *Равномерно выберем точку из промежутка $\Omega = [0, 1)$ и разобьём его на части*

$$A_1 = \left[0, \frac{1}{2}\right), \qquad A_2 = \left[\frac{1}{2}, \frac{3}{4}\right), \qquad A_3 = \left[\frac{3}{4}, \frac{7}{8}\right), \qquad \ldots$$

Вообще,

$$A_n = \left[1 - \frac{1}{2^{n-1}},\ 1 - \frac{1}{2^n}\right).$$

Эти события попарно несовместны, вместе они составляют всё пространство Ω, а длина A_n равна 2^{-n}. Поэтому

$$\mathbb{P}(A_n) = \frac{1}{2^n}$$

и условие счётной аддитивности даёт

$$\mathbb{P}(\Omega) = \mathbb{P}\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mathbb{P}(A_n) = \frac{1}{2} + \frac{1}{4} + \frac{1}{8} + \ldots = 1.$$

Конечная аддитивность позволила бы складывать вероятности только первых N частей:

$$\mathbb{P}\left(\bigcup_{n=1}^{N} A_n\right) = \sum_{n=1}^{N} \frac{1}{2^n} = 1 - \frac{1}{2^N}.$$

Но из равенств для каждого конечного N само по себе ещё не следует равенство для объединения всех частей. Именно возможность перейти от любого конечного числа частей ко всему счётному разбиению и составляет дополнительное содержание счётной аддитивности.

Классическое определение удовлетворяет этому условию. Действительно, в конечном Ω попарно несовместная семья содержит не более $|\Omega|$ непустых событий, а для любого конечного набора

$$\begin{aligned}\mathbb{P}\left(\bigcup_{i=1}^{n} A_i\right) &= \frac{\left|\bigcup_{i=1}^{n} A_i\right|}{|\Omega|} \\ &= \frac{\sum_{i=1}^{n} |A_i|}{|\Omega|} \\ &= \sum_{i=1}^{n} \mathbb{P}(A_i).\end{aligned}$$

Здесь несовместность гарантирует, что ни один исход не будет посчитан дважды.

Для геометрического определения логика полностью повторяется, но только теперь оно может быть разбито на бесконечно большое (но счётное!) количество кусочков. И эта возможность, как мы увидим, важна. Если бы мы умели складывать только вероятности конечного количества множеств, то решение множества задач стало бы если не невозможным, то уж точно значительно бы затруднилось.

Теперь мы, наконец, рассмотрели все три правила и можем сформулировать

Определение 4 (Аксиомы Колмогорова (упрощённая версия)). *Вероятностью называется правило, которое каждому событию A сопоставляет число $\mathbb{P}(A)$ и удовлетворяет следующим трём аксиомам:*

1. $\mathbb{P}(\Omega) = 1$;
2. *Для любого события A вероятность неотрицательна:* $\mathbb{P}(A) \geq 0$;
3. *Если события $A_1, A_2, \ldots$ таковы, что $A_i \cap A_j = \varnothing$ для $i \neq j$, то*

$$\mathbb{P}\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} \mathbb{P}(A_i).$$

> Для построения вероятностной модели нужны три основных элемента:
>
> 1. пространство элементарных исходов Ω, описывающее все возможные исходы случайного опыта;
> 2. события — подмножества пространства Ω, описывающие интересующие нас условия на исход опыта;
> 3. вероятность $\mathbb{P}$ — правило, которое каждому событию A сопоставляет число $\mathbb{P}(A)$ и удовлетворяет аксиомам Колмогорова.
>
> Выбор пространства Ω, рассматриваемых событий и вероятности $\mathbb{P}$ задаёт вероятностную модель.

Одна из аналогий, которую можно тут использовать, в том, что этот набор аксиом — как API, подходящий к многим разным объектам. И если мы доказываем что-то, основываясь только лишь на этих аксиомах, то доказанное будет автоматически верно для всех определений вероятности. Докажем несколько таких утверждений.

Свойство 1 (Пустое множество).

$$\mathbb{P}(\varnothing) = 0.$$

Доказательство. События $\Omega, \varnothing, \varnothing, \ldots$ попарно несовместны, а их объединение равно Ω. По счётной аддитивности

$$\begin{aligned} 1 = \mathbb{P}(\Omega) &= \mathbb{P}(\Omega) + \mathbb{P}(\varnothing) + \mathbb{P}(\varnothing) + \ldots \\ &= 1 + \mathbb{P}(\varnothing) + \mathbb{P}(\varnothing) + \ldots. \end{aligned}$$

Все слагаемые неотрицательны, поэтому это равенство возможно только при $\mathbb{P}(\varnothing) = 0$. □

Теперь счётную аддитивность можно применять и к конечным наборам попарно несовместных событий.[14]

[14] Конечный набор можно считать бесконечным, положив $A_{n+1} = A_{n+2} = \ldots = \varnothing$. Поскольку $\mathbb{P}(\varnothing) = 0$, добавленные события не меняют ни объединение, ни сумму.

Свойство 2 (Дополнение). *Для любого события A*

$$\mathbb{P}(\overline{A}) = 1 - \mathbb{P}(A).$$

Доказательство. События A и $\overline{A}$ несовместны, причём

$$A \cup \overline{A} = \Omega.$$

Поэтому по аддитивности

$$1 = \mathbb{P}(\Omega) = \mathbb{P}(A \cup \overline{A}) = \mathbb{P}(A) + \mathbb{P}(\overline{A}),$$

откуда и следует требуемое равенство. □

Свойство 3 (Монотонность). *Если $B \subseteq A$, то*

$$\mathbb{P}(B) \leqslant \mathbb{P}(A).$$

Доказательство. При $B \subseteq A$ событие A можно разложить в объединение несовместных событий:

$$A = B \cup (A \setminus B), \qquad B \cap (A \setminus B) = \varnothing.$$

По аддитивности и неотрицательности вероятности

$$\mathbb{P}(A) = \mathbb{P}(B) + \mathbb{P}(A \setminus B) \geqslant \mathbb{P}(B).$$ □

Свойство 4 (Объединение). *Для любых событий A и B*

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B).$$

Доказательство. Представим $A \cup B$ как объединение несовместных событий:

$$A \cup B = B \cup (A \setminus B).$$

Аналогично,

$$A = (A \cap B) \cup (A \setminus B),$$

причём события в каждом из этих объединений несовместны. Поэтому

$$\mathbb{P}(A \cup B) = \mathbb{P}(B) + \mathbb{P}(A \setminus B),$$
$$\mathbb{P}(A) = \mathbb{P}(A \cap B) + \mathbb{P}(A \setminus B).$$

Исключая из этих равенств $\mathbb{P}(A \setminus B)$, получаем

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B).$$ □

Свойство 5 (Оценка вероятности объединения). *Для любых событий A и B*

$$\mathbb{P}(A \cup B) \leqslant \mathbb{P}(A) + \mathbb{P}(B).$$

В общем случае для конечного или счётного набора событий

$$\mathbb{P}\left(\bigcup_{i=1}^{n} A_i\right) \leqslant \sum_{i=1}^{n} \mathbb{P}(A_i),$$

где в счётном случае $n = \infty$.

Доказательство. Для двух событий достаточно заметить, что в формуле вероятности объединения мы вычитаем неотрицательное число $\mathbb{P}(A \cap B)$.

Если событий больше, будем добавлять их по очереди, каждый раз убирая исходы, которые уже встречались в предыдущих событиях:

$$B_1 = A_1, \qquad B_i = A_i \setminus (A_1 \cup \ldots \cup A_{i-1}), \quad i \geqslant 2.$$

Объединение от этого не изменится, но события B_i уже попарно несовместны, причём $B_i \subseteq A_i$. Поэтому по аддитивности и монотонности

$$\mathbb{P}\left(\bigcup_{i=1}^{n} A_i\right) = \sum_{i=1}^{n} \mathbb{P}(B_i) \leqslant \sum_{i=1}^{n} \mathbb{P}(A_i). \qquad \square$$

Условная вероятность

Условная вероятность задаёт вероятность одного события, если точно известно, что некоторое другое событие уже произошло. Такая информация может изменить нашу оценку: теперь нас интересуют только исходы, при которых произошло известное событие.

Определение 5 (Условная вероятность). *Вероятностью события* A *при условии события* B, *где* $\mathbb{P}(B) > 0$, *называют*

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

Здесь мы оставляем только ту часть события A, которая совместима с условием B, и сравниваем её вероятность с вероятностью всего B. В классической модели это означает, что вместо всех исходов из Ω мы считаем только исходы из B. В геометрической модели вместо всей области Ω рассматриваем B.

Пример 3 (Бросок кости). *Бросаем правильную игральную кость. Пусть* $A = \{2, 4, 6\}$ *— выпало чётное число очков, а* $B = \{4, 5, 6\}$ *— выпало больше трёх очков. Без дополнительной информации* $\mathbb{P}(A) = 1/2$. *Но если известно, что произошло* B, *остаются только три равновероятных исхода, из которых два благоприятствуют событию* A:

$$\mathbb{P}(A \mid B) = \frac{|A \cap B|}{|B|} = \frac{2}{3}.$$

Пример 4 (Точка в квадрате). *Равномерно выбираем точку в единичном квадрате. Пусть* A *— точка попала в левую половину квадрата, а* B *— точка попала ниже диагонали, идущей из левого нижнего угла в правый верхний. Обе области занимают половину квадрата, поэтому* $\mathbb{P}(A) = \mathbb{P}(B) = 1/2$.

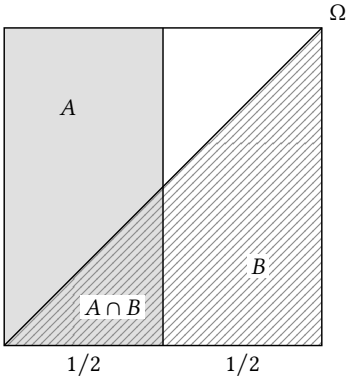


Рис. 4: Событие A выделено серым фоном, событие B — штриховкой. При условии B считаем долю площади пересечения $A \cap B$ только внутри

Пересечение $A \cap B$ — прямоугольный треугольник с катетами $1/2$ и $1/2$. Его площадь равна $1/8$. Если известно, что точка попала в B, её нужно сравнивать уже не с площадью квадрата, а с площадью B:

$$\mathbb{P}(A \mid B) = \frac{\mu(A \cap B)}{\mu(B)} = \frac{1/8}{1/2} = \frac{1}{4}.$$

Условие изменило вероятность попадания в левую половину с $1/2$ до $1/4$.

Вероятность пересечения удобно выразить из определения условной вероятности:

$$\mathbb{P}(A \cap B) = \mathbb{P}(A \mid B)\mathbb{P}(B), \qquad \mathbb{P}(B) > 0.$$

Если поменять события местами, получим

$$\mathbb{P}(A \cap B) = \mathbb{P}(B \mid A)\mathbb{P}(A), \qquad \mathbb{P}(A) > 0.$$

Оба равенства дают вероятность одного и того же пересечения, но условные вероятности в них, вообще говоря, различны.

Независимость событий

Перемножать вероятности событий можно, когда известно, что эти события независимы.

Определение 6 (Независимые события). *События A и B называются независимыми, если*

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B).$$

Если $\mathbb{P}(B) > 0$, это равносильно тому, что

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A)\mathbb{P}(B)}{\mathbb{P}(B)} = \mathbb{P}(A).$$

То есть информация о том, что произошло B, не меняет вероятность A. И наоборот: при $\mathbb{P}(A) > 0$ знание о событии A не меняет вероятность B. Именно в этом смысле события не зависят друг от друга.

Пример 5. *Подбрасываем две правильные монеты независимо друг от друга. Пусть A — на первой выпал герб, а B — на второй выпал герб. Тогда $\mathbb{P}(A) = \mathbb{P}(B) = 1/2$, а из четырёх равновероятных исходов только один входит в $A \cap B$. Поэтому*

$$\mathbb{P}(A \cap B) = \frac{1}{4} = \frac{1}{2} \cdot \frac{1}{2} = \mathbb{P}(A)\mathbb{P}(B).$$

События A и B независимы.

> Несовместность и независимость — очень разные понятия! Несовместные события не могут произойти одновременно. Независимые события могут: знание о том, что одно из них произошло, не меняет вероятность другого. Если оба события имеют положительную вероятность, они не могут быть одновременно несовместными и независимыми.

Действительно, для несовместных событий $\mathbb{P}(A \cap B) = \mathbb{P}(\varnothing) = 0$.

Если они к тому же независимы, то

$$0 = \mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B).$$

Такое возможно, только если хотя бы одна из вероятностей равна нулю.

Для набора из более чем двух событий определение обобщается следующим образом.

Определение 7. *События $A_1, A_2, \dots, A_n$ называются независимыми в совокупности, если для любого подмножества индексов $\{i_1, i_2, \dots, i_k\} \subseteq \{1, 2, \dots, n\}$, где $2 \le k \le n$, выполняется равенство*

$$\mathbb{P}(A_{i_1} \cap \dots \cap A_{i_k}) = \mathbb{P}(A_{i_1}) \dots \mathbb{P}(A_{i_k}).$$

Другими словами, вероятности должны перемножаться для любой пары, любой тройки и так далее, вплоть до всех событий сразу. Проверить только пересечение всех n событий недостаточно.

Определение 8 (Попарная независимость). *События $A_1, \dots, A_n$ называются попарно независимыми, если для любых $i \neq j$*

$$\mathbb{P}(A_i \cap A_j) = \mathbb{P}(A_i)\mathbb{P}(A_j).$$

Независимость в совокупности влечёт попарную независимость, но обратное неверно: проверки всех пар недостаточно. Когда мы говорим просто о независимости нескольких событий, будем иметь в виду независимость в совокупности.

Пример 6. *Снова подбрасываем две правильные монеты независимо друг от друга. К событиям A и B из предыдущего примера добавим событие C — на монетах выпала одна и та же сторона. Вероятность каждого из трёх событий равна $1/2$. Пересечение любой пары состоит из одного исхода "два герба", поэтому*

$$\mathbb{P}(A \cap B) = \mathbb{P}(A \cap C) = \mathbb{P}(B \cap C) = \frac{1}{4}.$$

События попарно независимы. Но их общее пересечение — всё тот же исход "два герба", и

$$\mathbb{P}(A \cap B \cap C) = \frac{1}{4} \neq \frac{1}{8} = \mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(C).$$

Значит, независимости в совокупности нет. Зная, что на обеих монетах выпал герб, мы уже точно знаем, что их стороны совпали.

Независимость и дополнения. Если события независимы в совокупности, любое из них можно заменить его дополнением, и независимость сохранится. Можно заменить одно событие, несколько или все сразу. Иначе говоря, для каждого события мы свободно выбираем, что нас интересует: "произошло" или "не произошло". В полученном наборе каждое исходное событие либо оставляем, либо заменяем его дополнением, но не включаем оба варианта одновременно.

Для двух событий это легко проверить. Событие A разбивается на две несовместные части: $A \cap B$ и $A \cap \overline{B}$. Поэтому, если A и B независимы, то

$$\begin{aligned}\mathbb{P}(A \cap \overline{B}) &= \mathbb{P}(A) - \mathbb{P}(A \cap B) \\ &= \mathbb{P}(A)(1 - \mathbb{P}(B)) \\ &= \mathbb{P}(A)\mathbb{P}(\overline{B}).\end{aligned}$$

То есть A и $\overline{B}$ тоже независимы. Тот же расчёт работает для пересечения любого набора остальных событий, поэтому правило сохраняется и для независимости в совокупности.

Например, для независимых событий A_1, A_2, A_3 вероятность того, что первое и третье произошли, а второе нет, равна

$$\mathbb{P}(A_1 \cap \overline{A}_2 \cap A_3) = \mathbb{P}(A_1)(1 - \mathbb{P}(A_2))\mathbb{P}(A_3).$$

Комбинации независимых событий. Теперь разделим независимые в совокупности события на две группы, не включающие одни и те же исходные события. Внутри каждой группы можно составить любое условие с помощью “и”, “или” и “не”. Полученные два события будут независимы. Например, нас может интересовать, произошли ли все события в первой группе и произошло ли хотя бы одно во второй.

Пусть события $A_1, \dots, A_m, B_1, \dots, B_n$ независимы в совокупности. Тогда любая комбинация событий $A_1, \dots, A_m$ с помощью объединения, пересечения, дополнения, разности или симметрической разности независима от любой такой комбинации событий $B_1, \dots, B_n$. Это не означает, что любые комбинации одних и тех же событий независимы между собой. Здесь важно, что первая комбинация использует только события из первой группы, а вторая — только из второй.

Пример 7. *Подбрасываем четыре правильные монеты независимо друг от друга и делим их на две пары. События A_1, A_2 означают выпадение герба на монетах первой пары, а B_1, B_2 — на монетах второй пары. Пусть в первой паре нас интересует ровно один герб, а во второй — хотя бы один:*

$$E = (A_1 \cap \overline{A}_2) \cup (\overline{A}_1 \cap A_2), \qquad F = B_1 \cup B_2.$$

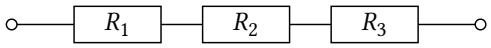
Условие E проверяется только по первой паре монет, а F — только по второй. Поэтому события E и F независимы. В каждой паре четыре равновероятных исхода, причём $\mathbb{P}(E) = 2/4$ и $\mathbb{P}(F) = 3/4$. Значит,

$$\mathbb{P}(E \cap F) = \mathbb{P}(E)\mathbb{P}(F) = \frac{1}{2} \cdot \frac{3}{4} = \frac{3}{8}.$$

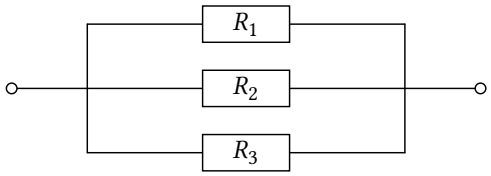
Мы могли бы выбрать другие условия: “оба герба”, “ни одного герба” или любую их комбинацию. Независимость сохранилась бы, пока каждое условие использует только свою пару монет.

Задача 3. Элементы цепи выходят из строя независимо друг от друга с вероятностью 0,1. Найти вероятность того, что цепь из трёх элементов будет пропускать ток при

- последовательном соединении элементов;
- параллельном соединении элементов.



(а) Последовательное соединение



(б) Параллельное соединение

Решение. Обозначим через A_1, A_2 и A_3 события выхода из строя элементов R_1, R_2 и R_3 соответственно. Тогда $\overline{A}_1, \overline{A}_2$ и $\overline{A}_3$ означают, что соответствующие элементы продолжают работать.

При последовательном соединении цепь выйдет из строя, если из строя выйдет хотя бы один элемент. Обозначим это событие через $B = A_1 \cup A_2 \cup A_3$. Тогда событие $\overline{B} = \overline{A}_1 \cap \overline{A}_2 \cap \overline{A}_3$ означает, что цепь пропускает ток. Дополнения независимых в совокупности событий также независимы в совокупности, поэтому

$$\begin{aligned}\mathbb{P}(\overline{B}) &= \mathbb{P}(\overline{A}_1)\mathbb{P}(\overline{A}_2)\mathbb{P}(\overline{A}_3) \\ &= (1 - \mathbb{P}(A_1))(1 - \mathbb{P}(A_2))(1 - \mathbb{P}(A_3)) \\ &= 0{,}9^3 = 0{,}729.\end{aligned}$$

Рассмотрим теперь параллельное соединение. В этом случае цепь перестанет пропускать ток, только если из строя выйдут все элементы сразу, то есть если произойдёт событие $A_1 \cap A_2 \cap A_3$. Из независимости событий следует, что

$$\mathbb{P}(A_1 \cap A_2 \cap A_3) = \mathbb{P}(A_1)\mathbb{P}(A_2)\mathbb{P}(A_3) = 0{,}1^3 = 0{,}001.$$

Следовательно, цепь будет пропускать ток с вероятностью $1 - 0{,}001 = 0{,}999$.

Формула полной вероятности

Определение 9 (Полная группа событий). *Полной группой событий, или гипотез, называют набор событий $H_1, \dots, H_n$, удовлетворяющий двум условиям:*

1. $H_i \cap H_j = \varnothing$ *для любых* $i \neq j$;
2. $\bigcup_{i=1}^{n} H_i = \Omega$.

Другими словами, всегда происходит ровно одно из событий $H_1, \dots, H_n$. Группа может быть и счётной: тогда пишем $n = \infty$.

Иногда вероятность события A трудно вычислить непосредственно, но задача упрощается, если известно, какая из гипотез H_i произошла. В такой ситуации используют формулу полной вероятности:

$$\mathbb{P}(A) = \sum_{i=1}^{n} \mathbb{P}(A \cap H_i) = \sum_{i=1}^{n} \mathbb{P}(A \mid H_i)\mathbb{P}(H_i),$$

где $\{H_i\}_{i=1}^{n}$ — полная группа гипотез и $\mathbb{P}(H_i) > 0$ для каждой из них.[15] В счётном случае $n = \infty$.

[15] Гипотезы нулевой вероятности в сумме пропускают: их пересечение с A тоже имеет нулевую вероятность, а условная вероятность при них нашим определением не задана.

Доказательство. Поскольку гипотезы образуют полную группу, событие A разбивается на попарно несовместные части:

$$A = \bigcup_{i=1}^{n} (A \cap H_i).$$

По счётной аддитивности его вероятность равна сумме вероятностей этих частей — это первое равенство в формуле. Второе получается, если для каждой части воспользоваться равенством

$$\mathbb{P}(A \cap H_i) = \mathbb{P}(A \mid H_i)\mathbb{P}(H_i). \qquad \square$$

То есть сначала вычисляем вероятность A отдельно для каждой гипотезы, а затем складываем результаты с учётом того, насколько вероятна каждая из гипотез.

Задача 4. Из $n \geqslant 2$ экзаменационных билетов студент знает m, где $1 \leqslant m \leqslant n$. Билеты выбирают наудачу без возвращения. Если он зайдёт на экзамен первым, то с вероятностью m/n вытащит “хороший” билет. Какова вероятность вытащить “хороший” билет, если студент зайдёт на экзамен вторым?

Решение. Если $m = n$, студент знает все билеты, поэтому искомая вероятность равна $1 = m/n$. Далее будем считать, что $m < n$.

Вероятность первому студенту вытащить “хороший” билет равна m/n. Для второго студента эта вероятность кажется менее доступной.

Картина упростится, если известно, какой билет вытащил первый студент. Если он взял хороший билет, то вероятность второму студенту вытащить хороший билет равна $(m-1)/(n-1)$. Если первый студент забрал плохой билет, эта вероятность равна $m/(n-1)$.

Запишем это формально:

- $A = \{$второй студент вытащил хороший билет$\}$;
- $H_1 = \{$первый студент взял хороший билет$\}$, причём $\mathbb{P}(A \mid H_1) = (m-1)/(n-1)$;
- $H_2 = \{$первый студент взял плохой билет$\}$, причём $\mathbb{P}(A \mid H_2) = m/(n-1)$.

Кроме того, $\mathbb{P}(H_1) = m/n$, $\mathbb{P}(H_2) = (n-m)/n$, и всегда происходит ровно одно из событий H_1 и H_2. По формуле полной вероятности

$$\begin{aligned}\mathbb{P}(A) &= \mathbb{P}(A \mid H_1)\mathbb{P}(H_1) + \mathbb{P}(A \mid H_2)\mathbb{P}(H_2) \\ &= \frac{m-1}{n-1}\frac{m}{n} + \frac{m}{n-1}\frac{n-m}{n} \\ &= \frac{m^2 - m + mn - m^2}{n(n-1)} \\ &= \frac{m(n-1)}{n(n-1)} = \frac{m}{n}.\end{aligned}$$

Задачи к лекции

Геометрическая вероятность.

Задача 5. Из отрезка $[0, 1]$ равномерно выбирается число. Какова вероятность, что в десятичной записи этого числа вторая цифра после запятой будет двойкой?

План решения. Разбейте отрезок на десять частей по первой цифре после запятой. В части с первой цифрой j подходящие числа образуют промежуток

$$\left[\frac{j}{10} + \frac{2}{100}, \frac{j}{10} + \frac{3}{100}\right), \qquad j = 0, 1, \ldots, 9.$$

Найдите суммарную длину этих десяти промежутков. Выбор десятичной записи у граничных точек не влияет на вероятность: отдельные точки имеют нулевую длину.

Ответ: $1/10$.

Задача 6. В квадрате с вершинами $(0, 0)$, $(0, 1)$, $(1, 0)$, $(1, 1)$ равномерно выбирается точка. Обозначим через X, Y её координаты. Предполагается, что вероятность попадания в область, лежащую целиком внутри квадрата, зависит лишь от площади этой области и пропорциональна ей.

Найти для $0 < t < 1$ вероятности:

1. $\mathbb{P}(X + Y < t)$;
2. $\mathbb{P}(|X - Y| < t)$;
3. $\mathbb{P}(XY < t)$;
4. $\mathbb{P}(\max(X, Y) < t)$;
5. $\mathbb{P}(\min(X, Y) < t)$.

Решение. Разберём первые два пункта. Пространство исходов — единичный квадрат, поэтому вероятность равна площади благоприятной области. Включение или исключение граничных отрезков на ответ не влияет: их площадь равна нулю.

1. Неравенство $X + Y < t$ задаёт область под прямой $Y = t - X$. При $0 < t < 1$ это прямоугольный треугольник с вершинами $(0, 0)$, $(t, 0)$ и $(0, t)$. Оба его катета равны t, поэтому

$$\mathbb{P}(X + Y < t) = \frac{t^2}{2}.$$

2. Неравенство $|X - Y| < t$ равносильно двум условиям: $Y > X - t$ и $Y < X + t$. Между этими прямыми лежит полоса вокруг диагонали квадрата. Проще посчитать площадь её дополнения: это два одинаковых прямоугольных треугольника в левом верхнем и правом нижнем углах. Катеты каждого равны $1 - t$. Значит,

$$\mathbb{P}(|X - Y| < t) = 1 - 2 \cdot \frac{(1-t)^2}{2} = 2t - t^2.$$

Ответы к пунктам 3–5: $t - t\ln t$, t^2 и $2t - t^2$ соответственно.

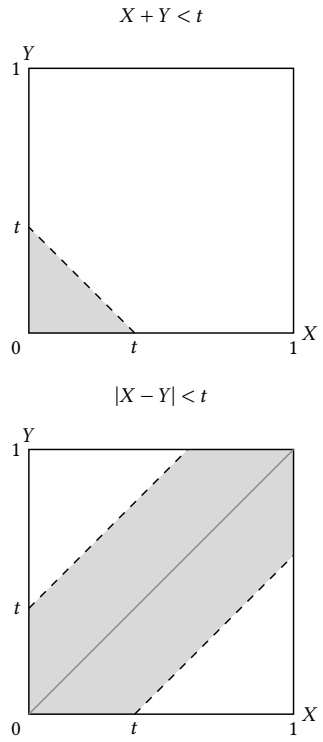


Рис. 5: Благоприятные области для первых двух пунктов. Для рисунков выбрано $t = 2/5$.

Задача 7. Точка равномерно выбирается в треугольнике с вершинами в точках $(0, 0)$, $(2, 0)$ и $(0, 1)$. Найти вероятность того, что

1. абсцисса точки окажется больше $1/2$;

2. ордината точки окажется больше $1/2$.

План решения. Площадь исходного треугольника равна 1. Проведите прямые $X = 1/2$ и $Y = 1/2$. В каждом пункте благоприятная область — треугольник, подобный исходному.

1. Справа от $X = 1/2$ остаётся основание длины $3/2$ вместо 2. Коэффициент подобия равен $3/4$.

2. Выше $Y = 1/2$ остаётся высота $1/2$ вместо 1. Коэффициент подобия равен $1/2$.

Вспомните, как при подобии меняются площади.

Ответы: $9/16$ и $1/4$.

Задача 8. На отрезке единичной длины независимо и равномерно выбираются две точки, которые делят отрезок на три части. Какова вероятность, что из этих частей можно составить треугольник?

Решение. Обозначим координаты точек разреза в порядке их выбора через U и V. По независимости и равномерности выбора пара (U, V) равномерно распределена в единичном квадрате. Не будем заранее упорядочивать точки: отдельно рассмотрим два возможных порядка.

Пусть сначала $U < V$. Тогда длины трёх частей равны U, $V - U$ и $1 - V$. Из трёх положительных отрезков с суммой длин 1 можно составить треугольник тогда и только тогда, когда каждый короче $1/2$: неравенство для стороны a имеет вид $a < 1 - a$. Поэтому нам нужны условия

$$U < \frac{1}{2}, \qquad V - U < \frac{1}{2}, \qquad V > \frac{1}{2}.$$

В половине квадрата $U < V$ они выделяют треугольник с вершинами $(0, 1/2)$, $(1/2, 1/2)$ и $(1/2, 1)$. Его катеты равны $1/2$, а площадь — $1/8$. При $V < U$ получается отражение этого треугольника относительно диагонали $U = V$. Совпадение точек разреза и границы выделенных областей имеют нулевую вероятность. Следовательно,

$$\mathbb{P}(\text{можно составить треугольник}) = \frac{1}{8} + \frac{1}{8} = \frac{1}{4}.$$

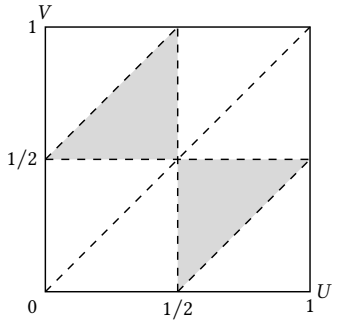


Рис. 6: Каждый из двух порядков точек разреза даёт треугольник площади $1/8$.

Задача 9. *Повышенная сложность.* На отрезке длины l независимо и равномерно выбираются три точки. Пусть X, Y, Z — расстояния до этих точек от левого конца отрезка. Какова вероятность, что из отрезков с длинами X, Y и Z можно составить треугольник?

План решения. Здесь длины сторон — сами X, Y и Z, а не части отрезка между выбранными точками. Пространство исходов — куб $[0, l]^3$ объёма l^3. Удобнее найти объём дополнения: треугольник не получится, если

$$X \geqslant Y + Z, \qquad Y \geqslant X + Z \qquad \text{или} \qquad Z \geqslant X + Y.$$

Нарисуйте первую область и покажите, что это тетраэдр объёма $l^3/6$. Две остальные имеют такой же объём по симметрии. Их пересечения имеют нулевой объём, поэтому объёмы можно сложить. Вычтите найденную долю объёма куба из единицы.

Ответ: $1/2$.

Задача 10. *Повышенная сложность.* В прямоугольнике с вершинами $(0, 0)$, $(0, 1)$, $(2, 0)$, $(2, 1)$ равномерно выбирается точка. Обозначим через X, Y её координаты. Для всех $t \in \mathbb{R}$ найти вероятность $\mathbb{P}(4X - Y < t)$.

Ответ:

$$\mathbb{P}(4X - Y < t) = \begin{cases} 0, & t \leqslant -1, \\ (t+1)^2/16, & -1 < t < 0, \\ (2t+1)/16, & 0 \leqslant t \leqslant 7, \\ 1 - (8-t)^2/16, & 7 < t < 8, \\ 1, & t \geqslant 8. \end{cases}$$

Независимость и условная вероятность.

Задача 11. Стрелок A поражает мишень с вероятностью 0,6, стрелок B — с вероятностью 0,5, а стрелок C — с вероятностью 0,4. Стрелки дали залп по мишени, причём результаты их выстрелов независимы. Найти вероятность того, что

1. ровно две пули попали в цель;
2. стрелок C промахнулся, если известно, что ровно две пули попали в цель.

Решение. Обозначим через A, B и C события попадания соответствующих стрелков. Событие, при котором ровно два стрелка попали в цель, имеет вид

$$\begin{aligned} D = (A \cap B \cap \overline{C}) \cup (A \cap \overline{B} \cap C) \\ \cup (\overline{A} \cap B \cap C). \end{aligned}$$

1. Случаи в объединении попарно несовместны, а результаты выстрелов независимы, поэтому

$$\begin{aligned} \mathbb{P}(D) &= 0{,}6 \cdot 0{,}5 \cdot 0{,}6 + 0{,}6 \cdot 0{,}5 \cdot 0{,}4 \\ &\quad + 0{,}4 \cdot 0{,}5 \cdot 0{,}4 \\ &= 0{,}18 + 0{,}12 + 0{,}08 = 0{,}38. \end{aligned}$$

2. Промах стрелка C задаётся событием $\overline{C}$. Поэтому искомая вероятность равна

$$\begin{aligned} \mathbb{P}(\overline{C} \mid D) &= \frac{\mathbb{P}(\overline{C} \cap D)}{\mathbb{P}(D)} \\ &= \frac{\mathbb{P}(A \cap B \cap \overline{C})}{\mathbb{P}(D)} \\ &= \frac{0{,}6 \cdot 0{,}5 \cdot 0{,}6}{0{,}38} = \frac{9}{19} \approx 0{,}47. \end{aligned}$$

Задача 12. Производят три независимые случайные перестановки букв слова “МАТЕМАТИКА”. Вычислить вероятность того, что

- слово получилось хотя бы один раз;
- слово получилось каждый раз.

Ответы: $1 - (1 - 1/151200)^3$ и $(1/151200)^3$.

Задача 13. Пусть событие A не зависит от самого себя. Доказать, что тогда $\mathbb{P}(A)$ равна 0 или 1.

Решение. Поскольку $A \cap A = A$, из независимости следует

$$\mathbb{P}(A) = \mathbb{P}(A \cap A) = \mathbb{P}(A)^2.$$

Значит, $\mathbb{P}(A)(1 - \mathbb{P}(A)) = 0$, откуда $\mathbb{P}(A) = 0$ или $\mathbb{P}(A) = 1$.

Задача 14. *Повышенная сложность.* События $A_1, \dots, A_n$ независимы, и известны вероятности $p_i = \mathbb{P}(A_i), i = 1, \dots, n$. Найти события, состоящие в том, что

- произошло ровно одно из событий A_i;
- не произошло ни одного из событий A_i;
- произошло хотя бы одно из событий A_i.

Найти их вероятности.

Решение.

1. Чтобы произошло ровно одно из событий A_i, одно из них должно произойти, а все остальные — нет. Для каждого i обозначим соответствующий случай через

   $$E_i = A_i \cap \bigcap_{\substack{j=1 \\ j \neq i}}^{n} \overline{A}_j.$$

   Тогда событие, при котором произошло ровно одно из A_i, имеет вид

   $$E = \bigcup_{i=1}^{n} E_i = \bigcup_{i=1}^{n} \left(A_i \cap \bigcap_{\substack{j=1 \\ j \neq i}}^{n} \overline{A}_j \right).$$

   События E_i попарно несовместны, поэтому

   $$\mathbb{P}(E) = \sum_{i=1}^{n} \mathbb{P}(E_i).$$

   Заменив все события, кроме A_i, их дополнениями, получаем независимые в совокупности события, откуда

   $$\mathbb{P}(E_i) = \mathbb{P}(A_i) \prod_{\substack{j=1 \\ j \neq i}}^{n} \mathbb{P}(\overline{A}_j) = p_i \prod_{\substack{j=1 \\ j \neq i}}^{n} (1 - p_j).$$

   Следовательно,

   $$\mathbb{P}(E) = \sum_{i=1}^{n} \left(p_i \prod_{\substack{j=1 \\ j \neq i}}^{n} (1 - p_j) \right).$$

2. Событие, при котором не произошло ни одного из событий A_i, можно записать как пересечение их дополнений:

   $$F = \bigcap_{i=1}^{n} \overline{A}_i.$$

Поскольку дополнения событий A_i независимы в совокупности,

$$\mathbb{P}(F) = \prod_{i=1}^{n} \mathbb{P}(\overline{A}_i) = \prod_{i=1}^{n} (1 - p_i).$$

3. Событие, при котором произошло хотя бы одно из событий A_i, является дополнением к F:

$$G = \overline{F} = \bigcup_{i=1}^{n} A_i.$$

Поэтому

$$\mathbb{P}(G) = 1 - \mathbb{P}(F) = 1 - \prod_{i=1}^{n} (1 - p_i).$$

Формула полной вероятности.

Задача 15. Из урны, содержащей три белых и два чёрных шара, переложили два вытянутых наудачу шара в урну, содержащую четыре белых и четыре чёрных шара. Затем из второй урны вынули шар. Найти вероятность того, что он белый.

План решения. Разбейте опыт на случаи по числу белых шаров, переложенных из первой урны.

1. Для каждого случая найдите вероятность получить такую пару шаров. Используйте подсчёт сочетаний.
2. Определите состав второй урны в каждом случае и найдите условную вероятность вынуть из неё белый шар.
3. Объедините результаты по формуле полной вероятности.

Ответ: $13/25$.

Практическое задание 1. Моделирование вероятности

Частотная интерпретация вероятности

Теория вероятностей — это математическая дисциплина, которая изучает абстрактные модели, описанные аксиомами, сформулированными Андреем Николаевичем Колмогоровым. С точки зрения математики, если что-то соответствует вероятностным аксиомам, это можно считать вероятностью. Применение этих моделей на практике требует обоснования их связи с реальными экспериментами.

В этом задании мы будем полагаться на частотную (или фреквентистскую) интерпретацию вероятности. Представьте себе эксперимент, в результате которого событие A может либо произойти, либо нет. Нам интересно узнать вероятность того, что событие A произойдёт. Согласно частотной интерпретации, чтобы оценить вероятность A, нужно многократно и независимо повторить этот эксперимент в одинаковых условиях и посчитать долю случаев, в которых событие A произошло:

$$\frac{\text{Количество случаев, когда } A \text{ произошло}}{\text{Общее количество экспериментов}}.$$

При конечном числе экспериментов эта доля даёт приближённую оценку. В пределе это отношение стремится к истинной вероятности $\mathbb{P}(A)$. К счастью, компьютеры позволяют нам многократно повторять один и тот же вероятностный эксперимент, что делает эту задачу выполнимой на практике.

Вычисление числа π

В этом задании мы будем использовать понятие геометрической вероятности, чтобы оценить значение числа π.

Геометрическая вероятность. Геометрическая вероятность — это вероятность того, что равномерно выбранная точка в ограниченной геометрической фигуре (например, квадрате, круге или другом теле) попадёт в заданную область внутри этой фигуры. Эта вероятность определяется как отношение меры (например, площади или объёма) интересующей нас области к мере всей фигуры. Геометрическая вероятность широко применяется в задачах, где требуется моделировать случайные события на основе геометрических свойств объектов.

Бросание точки в квадрат. Чтобы равномерно выбрать точку внутри квадрата, мы будем использовать равномерный генератор случайных чисел. Равномерность здесь означает, что вероятность попадания в область внутри квадрата пропорциональна её площади.

Представьте, что у нас есть квадрат, в котором обе координаты меняются от 0 до 1. Чтобы равномерно выбрать точку внутри этого квадрата, мы можем независимо сгенерировать две координаты x

и y для точки, где x и y — это случайные числа, равномерно распределённые на отрезке $[0; 1]$. Такой способ генерации обеспечит равномерное распределение точек по всему квадрату.

Пример кода на Python для генерации такой точки:

```
import random

x = random.uniform(0, 1)
y = random.uniform(0, 1)
print(f"Random point: ({x}, {y})")
```

В этом коде функция `random.uniform(0, 1)` возвращает случайное число, равномерно распределённое на отрезке $[0; 1]$. Соответственно, точка с координатами (x, y) будет равномерно распределена внутри квадрата.

Псевдослучайные числа и начальное состояние. Откуда компьютер берёт случайные числа? Можно было бы использовать данные из наблюдений за случайными событиями в реальном мире (например, движением мыши пользователя). Однако чаще всего применяют детерминированный алгоритм, который генерирует последовательность чисел, внешне неотличимую от случайной. Её элементы обычно называют псевдослучайными числами.

Поскольку алгоритм детерминирован, каждое начальное состояние задаёт свою последовательность. Для воспроизводимости вычислений начальное значение (*seed*) фиксируют, задавая конкретное число. При использовании модуля `random` это можно сделать так:

```
import random

SEED = 42
random.seed(SEED)
```

В обоих заданиях ниже задайте начальное состояние один раз в начале программы, до генерации случайных чисел. При повторном запуске того же кода с тем же начальным состоянием вы получите ту же последовательность и сможете воспроизвести вычисления.

Общая идея эксперимента. Идея нашего эксперимента состоит в следующем: мы будем многократно случайным образом “бросать” точки в квадрат и моделировать вероятность того, что выбранная точка попадёт в круг, вписанный в этот квадрат. Вероятность того, что случайная точка, выбранная внутри квадрата, попадёт в круг, равна отношению площади круга к площади квадрата. Так как площадь круга пропорциональна числу π, измеряя долю точек, попавших в круг, мы можем оценить значение π.

Процесс можно описать следующим образом:

1. Мы генерируем множество точек внутри квадрата с помощью равномерного распределения.
2. Для каждой точки проверяем, попала ли она внутрь круга.
3. Подсчитываем долю точек, попавших в круг, по сравнению с общим числом точек.
4. Используя это соотношение, приближённо вычисляем значение числа π.

Ваша основная задача — подробно обдумать детали этого алгоритма и реализовать его.

Дополнительно вам необходимо построить график зависимости абсолютной ошибки приближения числа π от количества использованных точек. В качестве ошибки используйте модуль разности между полученной оценкой и значением `math.pi`. Для этого не обязательно генерировать новые точки на каждом шаге, а можно пересчитывать вероятность, приближённое значение π и, соответственно, ошибку приближения после генерации каждой новой точки. Это позволит увидеть, как меняется ошибка с ростом числа использованных точек. На отдельных шагах ошибка может увеличиваться.

Описанный здесь метод для вычисления числа π называется также методом Монте-Карло. Этот метод основан на повторении случайных экспериментов для численной оценки характеристик и вероятностей.

Вычисление вероятности перколяции

Предыдущее задание было слишком искусственным, ведь есть гораздо лучшие способы подсчёта числа π. Поэтому теперь мы попробуем искать вероятности, для которых моделирование особенно полезно.

В данном задании вы исследуете концепцию перколяции, которая находит применение в самых разных областях — от распространения эпидемий до проникновения жидкости в пористые материалы. Перколяция описывает процесс образования связного пути через систему, которая состоит из случайно распределённых узлов или элементов.

Мы будем рассматривать частный случай модели, представляющей собой прямоугольное поле, разделённое на мелкие одинаковые квадраты. Каждый квадратик может быть либо проходимым, либо непроходимым. Каждая клетка проходима с одной и той же заданной вероятностью p, независимо от остальных клеток. Переходить можно только между проходимыми клетками, имеющими общую сторону; переходы по диагонали запрещены.

Основная задача состоит в проведении множества экспериментов, в каждом из которых будет генерироваться новое поле согласно заданной вероятности проходимости. В каждом эксперименте вы должны проверить существование пути, соединяющего верхний и нижний ряды поля и проходящего только через проходимые клетки. Начальная и конечная клетки в этих рядах могут быть любыми. На основе этих данных вы оцените *вероятность перколяции*, то есть вероятность наличия такого пути. От вас требуется построить график, отображающий зависимость вероятности перколяции от вероятности проходимости каждой клетки. Размеры поля, набор значений p и число экспериментов для каждого значения p выберите самостоятельно. Размеры поля должны оставаться одинаковыми для всех точек графика.

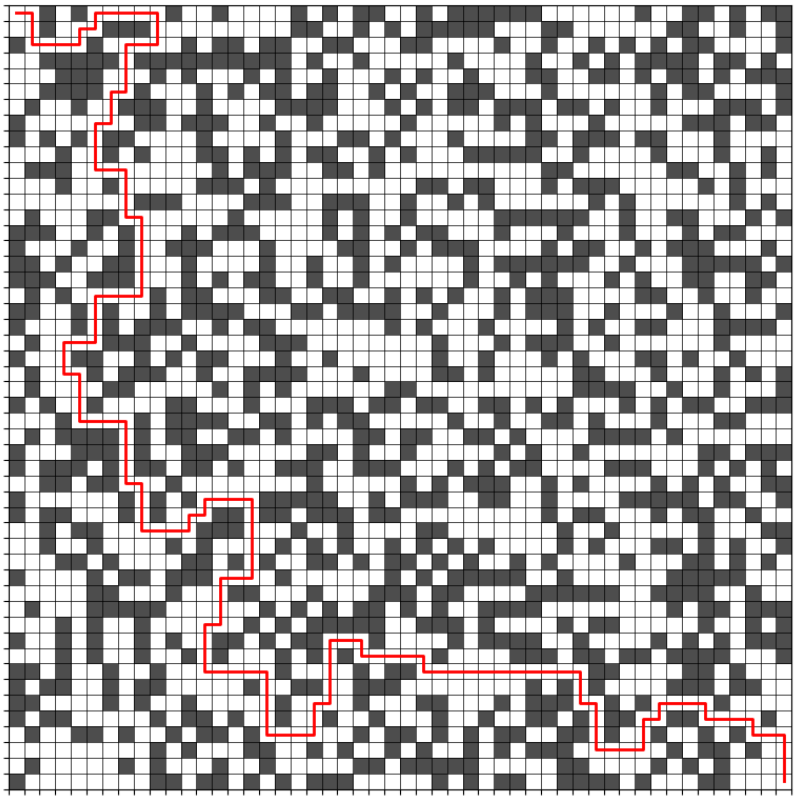


Рис. 7: Иллюстрация задачи о перколяции.

Вопросы для подготовки

Простые вопросы к коллоквиуму

1. Элементарные исходы, пространство элементарных исходов и события. Как они соотносятся друг с другом?
2. Интерпретация объединения двух событий.
3. Интерпретация пересечения двух событий.
4. Интерпретация дополнения события.
5. Интерпретация разности и симметрической разности двух событий.
6. Что такое достоверное событие?
7. Что такое невозможное событие?
8. Классическое определение вероятности. Почему оно требует конечности пространства элементарных исходов и их равновозможности?
9. Принцип сложения и пример его применения.
10. Принцип умножения и пример его применения.
11. Принцип деления и пример его применения.
12. Количество способов выбрать k объектов из n с возвращением и с учётом порядка.
13. Количество размещений: способов выбрать k объектов из n без возвращения, но с учётом порядка.
14. Количество сочетаний: способов выбрать k объектов из n без возвращения и без учёта порядка.
15. Парадокс дней рождений: постановка модели и точная вероятность отсутствия коллизий (без вывода).
16. Парадокс дней рождений: экспоненциальная верхняя оценка вероятности отсутствия коллизий (без вывода).
17. Геометрическое определение вероятности. Условия его применимости.
18. Что такое попарно несовместные события?
19. Аксиомы Колмогорова в принятой в курсе формулировке.
20. Вероятность дополнения события и вероятность объединения двух произвольных событий: формулы.
21. Верхняя оценка вероятности объединения конечного или счётного набора событий.
22. Определение условной вероятности.

23. Выражение вероятности пересечения двух событий через условную вероятность.

24. Определение независимости двух событий.

25. Чем независимость событий отличается от несовместности? Могут ли события положительной вероятности быть одновременно независимыми и несовместными?

26. Определение независимости в совокупности.

27. Определение попарной независимости. Как она связана с независимостью в совокупности?

28. Независимость и дополнения: сформулируйте свойство сохранения независимости.

29. Независимость событий, составленных из двух непересекающихся групп независимых в совокупности событий: формулировка утверждения.

30. Определение полной группы событий (гипотез).

31. Формула полной вероятности и условия её применимости.

32. Частотная интерпретация вероятности. Относительная частота как приближённая оценка вероятности.

33. Что такое псевдослучайные числа и зачем фиксируют начальное состояние генератора?

34. Основная идея метода Монте-Карло для оценки вероятности события.

Обычные вопросы к экзамену

1. Классическое определение вероятности и роль равновозможности элементарных исходов. Объяснение ошибки Д'Аламбера. Основные принципы комбинаторики: сложение, умножение и деление. Примеры их применения.

2. Выбор k объектов из n: какие четыре случая возможны? Формулы для трёх разобранных в лекции случаев и их обоснование.

3. Геометрическая вероятностная модель и её сравнение с классической. Почему вероятность отдельной точки равна нулю и почему это не означает невозможность её выбора? Почему нельзя получить вероятность всей области сложением вероятностей всех её точек?

4. Аксиомы Колмогорова в принятой в курсе формулировке. Доказательство свойств вероятности пустого множества, вероятности дополнения, вероятности объединения двух произвольных событий и монотонности вероятности.

5. Верхняя оценка вероятности объединения конечного и счётного набора событий. Доказательство через представление объединения в виде объединения попарно несовместных событий.

6. Связь независимости двух событий с условной вероятностью. Доказательство сохранения независимости при переходе к дополнениям.

7. Попарная независимость и независимость в совокупности. Связь между ними и разбор контрпримера из лекции.

8. Формула полной вероятности, условия её применимости и вывод.

Страшные вопросы к экзамену

1. Парадокс дней рождений и коллизии в хэш-таблицах. Вывод точной вероятности отсутствия коллизий и вероятности хотя бы одной коллизии. Экспоненциальная верхняя оценка вероятности отсутствия коллизий и её доказательство. Почему заметная вероятность коллизии возникает уже при числе объектов, пропорциональном $\sqrt{n}$, где n — число бакетов? Приближённый расчёт порога для совпадения дней рождения.

Байесовский вывод и основы статистики

Лекция 3. Формула Байеса и обновление вероятностей

Задача о разорении (Gambler's ruin)

Сначала вспомним формулу полной вероятности, так как, если держать её в голове, она сделает понимание основной темы лекции чуть-чуть проще. Вспомним мы её на простом, но известном примере — "Задаче о разорении".

Пусть есть двое игроков, раз за разом подбрасывающих честную монетку, чтобы определить победителя. Результаты бросков независимы. Проигравший раунд отдаёт победителю монетку. В итоге побеждает игрок, разоривший своего соперника.

Будем считать, что всего есть N монет. Обозначим через A_n событие, что первый игрок в итоге победит, если начинает с n монетами, и найдём его вероятность. Очевидно, что $\mathbb{P}(A_0) = 0$ — сразу проиграл, а $\mathbb{P}(A_N) = 1$ — сразу выиграл.

Для рассмотрения случая $0 < n < N$ введём событие H: первый игрок выиграл в первом раунде. Тогда $\mathbb{P}(H) = \mathbb{P}(\overline{H}) = 1/2$. После броска мы "начинаем" игру с $n+1$ монетой при выигрыше и с $n-1$ монетой при проигрыше.

После первого раунда:

$$\mathbb{P}(A_n \mid H) = \mathbb{P}(A_{n+1}),$$
$$\mathbb{P}(A_n \mid \overline{H}) = \mathbb{P}(A_{n-1}).$$

Но тогда по формуле полной вероятности имеем:

$$\begin{aligned}\mathbb{P}(A_n) &= \mathbb{P}(A_n \mid H)\mathbb{P}(H) + \mathbb{P}(A_n \mid \overline{H})\mathbb{P}(\overline{H}) \\ &= \frac{1}{2}\mathbb{P}(A_{n+1}) + \frac{1}{2}\mathbb{P}(A_{n-1}).\end{aligned}$$

Следовательно,

$$\mathbb{P}(A_{n+1}) - \mathbb{P}(A_n) = \mathbb{P}(A_n) - \mathbb{P}(A_{n-1}) =: \Delta,$$

$$\begin{aligned}\mathbb{P}(A_0) &= 0, \\ \mathbb{P}(A_1) &= \Delta, \\ \mathbb{P}(A_2) &= 2\Delta, \\ &\vdots \\ \mathbb{P}(A_N) &= N\Delta = 1.\end{aligned}$$

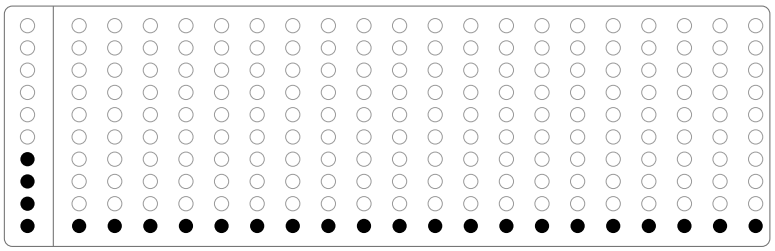
то есть вероятности увеличиваются на одну и ту же константу. Отсюда следует, что $\Delta = 1/N$, а

$$\mathbb{P}(A_n) = n\Delta = \frac{n}{N}.$$

Теорема Байеса

Когда она нужна? Теорема Байеса — это очень простое утверждение о подсчёте вероятностей, которое, тем не менее, позволяет избежать распространённого типа иррациональных суждений.

Пусть 40% библиотекарей — интроверты, при этом среди фермеров интровертов всего 10%. В такой ситуации люди склонны считать, что случайно выбранный интроверт — скорее всего библиотекарь. Ведь среди них доля интровертов больше! В реальности же для ответа нам не хватает критически важной информации — общего количества библиотекарей и фермеров в популяции. Если, например, фермеров в 20 раз больше, чем библиотекарей, то вероятность случайному интроверту быть библиотекарем может быть найдена согласно иллюстрации ниже.



10 библиотекарей 200 фермеров

Рис. 8: В популяции 10 библиотекарей и 200 фермеров. Закрашены интроверты: 4 библиотекаря и 20 фермеров. Каждый кружок соответствует одному человеку.

Среди 24 интровертов 4 библиотекаря, поэтому искомая вероятность равна $4/(4+20) = 4/24 = 1/6$. То есть, несмотря на то, что среди библиотекарей интроверты встречаются чаще, фермеров гораздо больше. И поэтому фермеров-интровертов в итоге больше, чем библиотекарей-интровертов.

Запишем вероятностную постановку. Обозначим через H событие, что человек является библиотекарем, через $\overline{H}$ — что он фермер, а через A — что он интроверт. Умножив долю каждой группы на долю интровертов в ней, получаем доли интровертов от всей популяции. Общее число людей сокращается в числителе и знаменателе:

$$\mathbb{P}(H \mid A) = \frac{\mathbb{P}(A \mid H)\mathbb{P}(H)}{\mathbb{P}(A \mid H)\mathbb{P}(H) + \mathbb{P}(A \mid \overline{H})\mathbb{P}(\overline{H})} = \frac{\frac{2}{5}\cdot\frac{1}{21}}{\frac{2}{5}\cdot\frac{1}{21} + \frac{1}{10}\cdot\frac{20}{21}} = \frac{1}{6}.$$

Доли библиотекарей и фермеров:

$$\mathbb{P}(H) = \frac{10}{210} = \frac{1}{21},$$
$$\mathbb{P}(\overline{H}) = \frac{200}{210} = \frac{20}{21}.$$

Доли интровертов внутри групп:

$$\mathbb{P}(A \mid H) = \frac{4}{10} = \frac{2}{5},$$
$$\mathbb{P}(A \mid \overline{H}) = \frac{20}{200} = \frac{1}{10}.$$

Нас интересует обратная задача: мы уже знаем, что событие A произошло. Какова вероятность, что вместе с ним произошла гипотеза H_j? Ответ даёт формула Байеса.

Теорема (формула Байеса). Пусть $H_1, H_2, \ldots$ — полная группа событий, причём $\mathbb{P}(H_i) > 0$ для всех i. Тогда для любого события $A \subseteq \Omega$ с $\mathbb{P}(A) > 0$ и для любого j верно:

$$\mathbb{P}(H_j \mid A) = \frac{\mathbb{P}(A \mid H_j)\mathbb{P}(H_j)}{\sum\limits_{i=1}^{\infty} \mathbb{P}(A \mid H_i)\mathbb{P}(H_i)}.$$

Для конечной полной группы из m событий сумма берётся от 1 до m.

Доказательство. По определению условной вероятности

$$\mathbb{P}(H_j \mid A) = \frac{\mathbb{P}(A \cap H_j)}{\mathbb{P}(A)}.$$

$\mathbb{P}(H_j)$ — априорная вероятность H_j, до эксперимента.

$\mathbb{P}(H_j \mid A)$ — апостериорная вероятность H_j, после эксперимента, в котором произошло A.

Применяя формулу умножения вероятностей к числителю, а формулу полной вероятности к знаменателю, получаем

$$\frac{\mathbb{P}(A \cap H_j)}{\mathbb{P}(A)} = \frac{\mathbb{P}(A \mid H_j)\mathbb{P}(H_j)}{\sum\limits_{i=1}^{\infty} \mathbb{P}(A \mid H_i)\mathbb{P}(H_i)}.$$

□

Задача 1. Предположим, что 5% всех мужчин и 0,25% всех женщин — дальтоники. Наугад выбранное лицо страдает дальтонизмом. Какова вероятность того, что это мужчина? Считать, что мужчин и женщин одинаковое число.

Ответ: 20/21.

Решение. Чтобы понять, какие события брать за гипотезы, стоит остановиться и подумать — а какие условные вероятности нам даны в этой задаче? Из условий мы знаем вероятность дальтонизма при условии того, что человек — мужчина или женщина. Значит, будет разумным взять следующие гипотезы: H_m — выбранный человек мужчина, H_f — выбранный человек женщина. Нетрудно убедиться, что всегда происходит ровно одно из этих событий.

Соответственно, A — наугад выбранное лицо страдает дальтонизмом. Кроме того, мы знаем все нужные вероятности. В этих обозначениях от нас требуется найти $\mathbb{P}(H_m \mid A)$, для чего можно использовать формулу Байеса:

По условию:

$$\mathbb{P}(H_m) = 0{,}5,$$
$$\mathbb{P}(H_f) = 0{,}5,$$
$$\mathbb{P}(A \mid H_m) = 0{,}05,$$
$$\mathbb{P}(A \mid H_f) = 0{,}0025.$$

$$\mathbb{P}(H_m \mid A) = \frac{\mathbb{P}(A \mid H_m)\mathbb{P}(H_m)}{\mathbb{P}(A \mid H_m)\mathbb{P}(H_m) + \mathbb{P}(A \mid H_f)\mathbb{P}(H_f)} = \frac{0{,}05 \cdot 0{,}5}{0{,}05 \cdot 0{,}5 + 0{,}0025 \cdot 0{,}5} = \frac{500}{525} = \frac{20}{21} \approx 0{,}95.$$

Задача 2. В продажу поступают телевизоры трёх заводов. Продукция первого завода содержит 10% телевизоров со скрытым дефектом, второго — 20%, третьего — 5%. В магазин поступает 25% телевизоров с первого завода, 25% со второго и 50% с третьего.

1. Какова вероятность приобрести исправный телевизор?
2. Если известно, что вы приобрели исправный телевизор, то какова вероятность, что он был произведён на первом заводе?
3. В выбранном телевизоре обнаружили дефект. Какой завод теперь наиболее вероятен? Найдите вероятности всех трёх заводов.

Ответы: 1) 9/10; 2) 1/4; 3) второй завод; вероятности первого, второго и третьего заводов — 1/4, 1/2 и 1/4 соответственно.

Задача 3. *Для самостоятельной работы.* Наудачу равновероятно выбирают число K от 2 до 10 и осуществляют случайную перестановку первых K букв слова “МАТЕМАТИКА”. Остальные буквы остаются на своих местах; все перестановки K позиций равновероятны.

1. Найти вероятность того, что в результате получится слово “МАТЕМАТИКА”.

2. Найти вероятность того, что выбрали две первые буквы, если известно, что слово “МАТЕМАТИКА” получилось.

   Ответы: 1) 332203/4082400; 2) 226800/332203.

Пример обновления априорных представлений. Пусть некоторая “ужасная” болезнь поражает 0,1% населения, и у нас в распоряжении имеется некоторый тест, который распознаёт больного с вероятностью 99%, но также может ошибочно объявить больным здорового человека с вероятностью 1%. То есть тест очень точен, и если нам сказали, что мы больны, то мы на 95% больны, так?

Оказывается, нет! Посчитаем напрямую. Положим: H — мы больны, $\overline{H}$ — мы здоровы, а A — тест сказал, что мы больны. Следовательно, по формуле Байеса

$$\mathbb{P}(H \mid A) = \frac{0{,}99 \cdot 0{,}001}{0{,}99 \cdot 0{,}001 + 0{,}01 \cdot 0{,}999} \approx 9\%.$$

По условию:

$$\mathbb{P}(H) = 0{,}001,$$
$$\mathbb{P}(\overline{H}) = 0{,}999,$$
$$\mathbb{P}(A \mid H) = 0{,}99,$$
$$\mathbb{P}(A \mid \overline{H}) = 0{,}01.$$

Мы получили 9% потому, что больных очень мало. На 100 000 людей лишь 100 больных, при этом из 99 900 здоровых примерно 999 будут ошибочно признаны больными!

Но мы можем пройти тестирование ещё раз. Теорема Байеса же позволяет нам обновлять наши представления о болезни после каждого теста: $\mathbb{P}(H) \mapsto \mathbb{P}(H \mid A)$. [16]

[16] Здесь и далее предполагаем, что результаты повторных тестов условно независимы при фиксированном состоянии человека: отдельно среди больных и отдельно среди здоровых. Характеристики теста при повторениях остаются теми же.

Для отрицательного результата используем $\mathbb{P}(\overline{A} \mid H) = 0{,}01$ и $\mathbb{P}(\overline{A} \mid \overline{H}) = 0{,}99$.

Обозначим текущую вероятность болезни через p. После положительного и отрицательного результатов она соответственно становится равной

$$p_+ = \frac{0{,}99p}{0{,}99p + 0{,}01(1-p)}, \qquad p_- = \frac{0{,}01p}{0{,}01p + 0{,}99(1-p)}.$$

Применим эти формулы последовательно:

Тест	Результат	p до теста	p после теста
I	Положительный	0,001	0,0902
II	Положительный	0,0902	0,9075
III	Отрицательный	0,9075	0,0902
IV	Положительный	0,0902	0,9075
V	Положительный	0,9075	0,9990

Значения в таблице округлены только для записи. При следующем обновлении используются неокруглённые вероятности.

Шансы

Шансы — это другой способ выражения вероятности. Если в классической постановке мы определяли вероятность события A как отношение числа благоприятных исходов к числу всех исходов, $|A|/|\Omega|$, то шансы события A произойти можно объявить как отношение числа благоприятных исходов к числу неблагоприятных, $|A|/|\overline{A}|$. Это определение сохраняется и в общем случае: *шансами события A произойти* мы называем

$$\frac{\mathbb{P}(A)}{\mathbb{P}(\overline{A})} = \frac{\mathbb{P}(A)}{1-\mathbb{P}(A)}.$$

Здесь $p \in [0,1]$, а $\eta \in [0,+\infty]$; вероятности $p = 1$ соответствуют бесконечные шансы.

Зачем они нам нужны? Оказывается, что они упрощают применение теоремы Байеса!

Разделим числитель и знаменатель на число всех исходов:

$$\frac{|A|}{|\overline{A}|} = \frac{|A|/|\Omega|}{|\overline{A}|/|\Omega|} = \frac{\mathbb{P}(A)}{\mathbb{P}(\overline{A})}.$$

В виде диаграммы:

$$\underbrace{p}_{\text{вероятность}} \quad \begin{array}{c} \eta = \dfrac{p}{1-p} \\ \rightleftharpoons \\ p = \dfrac{\eta}{1+\eta} \end{array} \quad \underbrace{\eta}_{\text{шансы}}.$$

Вероятность	Шансы	Словами
0	0	—
$0{,}2 = 1/5$	$1/4$	1 к 4
$0{,}25 = 1/4$	$1/3$	1 к 3
$0{,}5 = 1/2$	1	1 к 1
$0{,}75 = 3/4$	3	3 к 1
$0{,}8 = 4/5$	4	4 к 1
1	$+\infty$	—

Характеристики классификатора

Рассмотрим 1000 людей, среди которых 1% больных и 99% здоровых. Тест опознаёт 90% больных, а 10% не опознаёт. Среди здоровых 9% он ошибочно признаёт больными, а 91% опознаёт как здоровых.

	Тест +	Тест −	Всего
Больны	9 (TP)	1 (FN)	10
Здоровы	89 (FP)	901 (TN)	990
Всего	98	902	1000

Это другой тест: здесь чувствительность равна 90%, а доля ложных срабатываний — 9%. Численности здоровых с каждым результатом округлены: $990 \cdot 0{,}09 = 89{,}1 \approx 89$ и $990 \cdot 0{,}91 = 900{,}9 \approx 901$.

Обозначения в таблице:

TP (true positive) — истинно положительное срабатывание;

FN (false negative) — ложноотрицательное срабатывание;

FP (false positive) — ложноположительное срабатывание;

TN (true negative) — истинно отрицательное срабатывание.

Accuracy (точность) — доля корректных предсказаний. Она равна $\frac{\text{TP+TN}}{\text{TP+FP+TN+FN}}$. У нас точность $(9+901)/1000 = 0{,}91$ — просто отличная! Но если всегда отвечать “здоров”, точность будет 99%! Поэтому одной общей точности недостаточно для оценки теста.

Sensitivity (чувствительность) — доля корректно распознанных больных, $\text{TP}/(\text{TP}+\text{FN})$. У нас чувствительность $9/10 = 0{,}9$ — тоже замечательная!

Specificity (специфичность) — доля корректно распознанных здоровых, $\text{TN}/(\text{TN}+\text{FP})$. У нас специфичность $901/990 \approx 0{,}91$ — даже лучше!

Снова положим: H — мы больны, $\overline{H}$ — мы здоровы, а A — тест сказал, что мы больны.

Тогда $\mathbb{P}(H) = 0{,}01$, $\mathbb{P}(\overline{H}) = 0{,}99$, $\mathbb{P}(A \mid H) = 0{,}9$ и $\mathbb{P}(A \mid \overline{H}) = 0{,}09$, но

$$\mathbb{P}(H \mid A) = \frac{0{,}9 \cdot 0{,}01}{0{,}9 \cdot 0{,}01 + 0{,}09 \cdot 0{,}99} = \frac{10}{109} \approx 9\%.$$

И тест всё равно даёт слабую уверенность!

Заметим напоследок, что $\mathbb{P}(A \mid H)$ — это отношение числа больных, опознанных как больные, к числу больных, то есть чувствительность. А $1 - \mathbb{P}(A \mid \overline{H}) = \mathbb{P}(\overline{A} \mid \overline{H})$ — отношение числа здоровых, опознанных как здоровые, к числу здоровых, то есть специфичность.

По определению условной вероятности:

$$\mathbb{P}(A \mid H) = \frac{\mathbb{P}(A \cap H)}{\mathbb{P}(H)},$$
$$\mathbb{P}(\overline{A} \mid \overline{H}) = \frac{\mathbb{P}(\overline{A} \cap \overline{H})}{\mathbb{P}(\overline{H})}.$$

Задача 4. Изделия некоторого производства удовлетворяют стандарту с вероятностью 0,75. Предлагается упрощённая система испытаний, дающая положительный результат с вероятностью 0,8 для изделий, удовлетворяющих стандарту, а для изделий, которые не удовлетворяют стандарту, с вероятностью 0,4. Положительный результат означает допуск изделия, отрицательный — браковку. Какова вероятность того, что:

1. изделие будет забраковано;
2. изделие, выдержавшее испытание, удовлетворяет стандарту?

Ответы: 1) 3/10; 2) 6/7.

Коэффициент Байеса

Выведем формулу Байеса для шансов, то есть не для $\mathbb{P}(H \mid A)$, а для $\mathbb{P}(H \mid A)/\mathbb{P}(\overline{H} \mid A)$. По формуле Байеса

$$\mathbb{P}(H \mid A) = \frac{\mathbb{P}(A \mid H)\mathbb{P}(H)}{\mathbb{P}(A \mid H)\mathbb{P}(H) + \mathbb{P}(A \mid \overline{H})\mathbb{P}(\overline{H})},$$
$$\mathbb{P}(\overline{H} \mid A) = \frac{\mathbb{P}(A \mid \overline{H})\mathbb{P}(\overline{H})}{\mathbb{P}(A \mid H)\mathbb{P}(H) + \mathbb{P}(A \mid \overline{H})\mathbb{P}(\overline{H})}.$$

Делим первое равенство на второе:

$$\frac{\mathbb{P}(H \mid A)}{\mathbb{P}(\overline{H} \mid A)} = \frac{\mathbb{P}(A \mid H)}{\mathbb{P}(A \mid \overline{H})} \cdot \frac{\mathbb{P}(H)}{\mathbb{P}(\overline{H})}.$$

Апостериорные шансы равны априорным шансам, умноженным на коэффициент Байеса.

Другими словами, обновление шансов гипотезы H по формуле Байеса производится простым умножением на *коэффициент Байеса* $\mathbb{P}(A \mid H)/\mathbb{P}(A \mid \overline{H})$. При этом, по предыдущему разделу, он легко определяется через характеристики классификатора:

$$\frac{\mathbb{P}(A \mid H)}{\mathbb{P}(A \mid \overline{H})} = \frac{\text{чувствительность}}{1 - \text{специфичность}} = \frac{\text{sensitivity}}{1 - \text{specificity}}.$$

Пример. Применим коэффициент Байеса к классификатору из предыдущего раздела. Здесь

Напомним его характеристики:

$$\mathbb{P}(H) = 0{,}01,$$
$$\mathbb{P}(\overline{H}) = 0{,}99,$$
$$\mathbb{P}(A \mid H) = 0{,}9,$$
$$\mathbb{P}(A \mid \overline{H}) = 0{,}09.$$

$$\frac{\mathbb{P}(A \mid H)}{\mathbb{P}(A \mid \overline{H})} = \frac{0{,}9}{1 - 0{,}91} = \frac{0{,}9}{0{,}09} = 10.$$

То есть каждый положительный тест увеличивает наши шансы оказаться больными в 10 раз.

Коэффициент Байеса для отрицательного результата теста равен

$$\frac{\mathbb{P}(\overline{A} \mid H)}{\mathbb{P}(\overline{A} \mid \overline{H})} = \frac{0{,}1}{0{,}91} = \frac{10}{91} \approx 0{,}11.$$

Почему? При отрицательном результате отношение правдоподобий равно (1 − чувствительность)/специфичность.

Применим байесовское обновление, сохраняя предположение об условной независимости повторных тестов. Начальные шансы равны $0{,}01/0{,}99 = 1/99$. После каждого результата умножаем шансы на соответствующий коэффициент, а затем переходим к вероятности по формуле $p = \eta/(1+\eta)$.

Результат теста	Шансы быть больным	Вероятность
—	$\frac{1}{99}$	0,01
Положительный	$\frac{1}{99} \cdot 10 = \frac{10}{99}$	$\frac{10}{109} \approx 0{,}09$
Положительный	$\frac{10}{99} \cdot 10 = \frac{100}{99}$	$\frac{100}{199} \approx 0{,}50$
Положительный	$\frac{100}{99} \cdot 10 = \frac{1000}{99}$	$\frac{1000}{1099} \approx 0{,}91$
Отрицательный	$\frac{1000}{99} \cdot \frac{10}{91} = \frac{10000}{9009}$	$\frac{10000}{19009} \approx 0{,}53$
Положительный	$\frac{10000}{9009} \cdot 10 = \frac{100000}{9009}$	$\frac{100000}{109009} \approx 0{,}92$

Задача 5. По каналу связи может быть передана одна из трёх последовательностей букв: *AAAA*, *BBBB*, *CCCC*, причём делается это с вероятностями 0,3, 0,4 и 0,3 соответственно. Известно, что действие шумов на приёмное устройство уменьшает вероятность правильного приёма каждой из переданных букв до 0,6, а вероятности приёма каждой переданной буквы за две другие равны 0,2 и 0,2. Предполагается, что при заданной переданной последовательности буквы искажаются независимо друг от друга. Найти вероятность того, что была передана последовательность *AAAA*, если на приёмном устройстве получено *ABCA*.

Ответ: $9/16$.

Задача 6. Четыре грани правильной игральной кости A красные и две белые; у правильной кости B две грани красные и четыре белые. Один раз бросается честная монета. Если выпал герб, то всё время бросается только кость A, если решка — только кость B. Броски выбранной кости независимы.

1. Найти вероятность получить красную грань при одном бросании кости.
2. Найти вероятность того, что третье бросание кости даст красную грань, если первые два бросания дали красные грани.
3. Первые n испытаний дали красные грани. Какова вероятность того, что бросалась кость A?

Ответы: 1) $1/2$; 2) $3/5$; 3) $\dfrac{2^n}{2^n+1}$.

Задача 7. Робот проверяет, свободен ли проход. До измерений вероятность наличия препятствия равна $1/5$. Первый датчик обнаруживает препятствие с вероятностью $4/5$, если оно есть, и ошибочно сообщает о нём с вероятностью $1/5$, если его нет. Для второго датчика эти вероятности равны $9/10$ и $1/10$. Положительный результат означает сообщение о препятствии. Во время проверки состояние прохода не меняется; при заданном состоянии все результаты датчиков, включая повторные измерения, независимы.

Первый датчик сообщил о препятствии, а второй — нет. Какова теперь вероятность наличия препятствия?

Ответ: $1/10$.

Что важно запомнить

1. Априорные вероятности важны: одно и то же наблюдение может приводить к разным выводам при разных исходных вероятностях гипотез.
2. Не путайте $\mathbb{P}(A \mid H)$ и $\mathbb{P}(H \mid A)$: первое — вероятность наблюдения при заданной гипотезе, второе — вероятность гипотезы после наблюдения.
3. Если наблюдения условно независимы как при H, так и при $\overline{H}$, их коэффициенты Байеса перемножаются. Чтобы получить апостериорные шансы, умножьте априорные шансы на это произведение.

Лекция 4. Статистика и бутстрэп

До сих пор мы в основном начинали с описания случайного опыта и вычисляли вероятности его исходов. Но на практике часто приходится двигаться в обратном направлении: результаты уже есть, а понять нужно то, как они устроены. Например, сколько времени обычно занимает дорога до университета? Насколько сильно это время различается у разных студентов? И что вообще считать “обычным” временем, если кто-то живёт через дорогу, а кто-то едет с другого конца города?

Начнём с более скромной задачи — научимся описывать имеющиеся данные. Этим занимается *описательная статистика*. Вопрос о том, что по этим данным можно сказать о других студентах или о будущих поездках, потребует ещё одного шага.

Признаки, выборка и статистики

Пример данных. Рассмотрим синтетическую выборку из 500 утренних поездок разных студентов в университет. Одна строка соответствует одной поездке. Десять выбранных для иллюстрации строк приведены ниже. Расстояние измеряется в километрах, время — в целых минутах от двери до двери. Опоздание к началу занятия указано по интервалам: нет, 1–5, 6–15 или более 15 минут.

Поездка	Способ	Расстояние	Пересадки	Время	Опоздание
C001	Пешком	2,5	0	33	нет
C003	Велосипед	6,1	0	25	нет
C004	Метро	17,0	1	50	нет
C010	Автобус	10,0	0	44	1–5
C021	Автобус	16,4	0	97	> 15
C038	Пешком	1,9	0	27	1–5
C041	Автобус	13,5	1	65	6–15
C056	Велосипед	6,0	0	25	1–5
C059	Пешком	2,6	0	33	6–15
C139	Метро	13,6	1	54	6–15

В этой таблице строки — отдельные наблюдения, а столбцы — наблюдаемые *признаки*. При этом они устроены по-разному. Расстояния можно складывать и сравнивать по величине, но со способами передвижения так поступить не получится.

Количественные признаки выражают число или величину. Число пересадок — пример *дискретного* признака: можно сделать ноль, одну или две пересадки, но не полторы. Расстояние и длительность поездки, напротив, лучше моделировать как *непрерывные* величины, способные принимать любые значения из некоторого интервала.

Различие определяется смыслом величины, а не её записью. Время в таблице округлено до целых минут, хотя длительность поездки может принимать и промежуточные значения. И наоборот, дискретный признак не обязан быть целочисленным: если за задание разрешены только оценки 0, 0,5 и 1 балл, набор возможных значений всё равно состоит из отдельных точек.

Качественные признаки указывают категорию. Способ передвижения — *номинальный* признак: у категорий нет естественного порядка. Мы можем расположить их по алфавиту или по популярности, но это будет порядок, выбранный нами для конкретной задачи. Интервалы опоздания дают *порядковый* признак: отсутствие опоздания предшествует опозданию на 1–5 минут, затем идут 6–15 минут и более 15 минут. Порядок известен, а точная длительность опоздания по этой записи уже не восстанавливается.

Порядковые категории можно сравнивать и подсчитывать. Но среднее арифметическое их номеров не имеет автоматически того же смысла, что среднее время. Если закодировать интервалы числами 0, 1, 2, 3, расстояние между кодами будет одинаковым, хотя сами интервалы устроены совсем по-разному. Идентификатор поездки тоже нужен лишь для поиска строки: средний номер поездки ничего не говорит о дороге до университета.

Выберем один числовой признак, например время в пути, и обозначим его наблюдённые значения через $X_1, \dots, X_n$. Этот набор будем называть *выборкой*, а число наблюдений n — её *объёмом*. Для всех поездок в нашем примере $n = 500$. Десять строк выше выбраны

так, чтобы показать разные случаи; все дальнейшие характеристики полного набора считаются по всем 500 строкам.

Описать можно любой набор наблюдений. Для вывода о более широкой совокупности нужно ещё понимать, как его получили. Например, опрос только на парковке даст совсем другое представление о способах передвижения, чем опрос студентов в аудитории.

Число, вычисляемое по выборке по некоторому правилу, называют *статистикой*. Минимальное время, среднее время и доля поездок короче получаса — всё это статистики. Например, последняя получается, если подсчитать подходящие поездки и разделить их число на n. В нашем наборе таких поездок 140, поэтому доля равна $140/500 = 0{,}28$, или 28%.

Здесь полезно различать правило и его результат. Правило вычисления среднего можно применить к любой числовой выборке. Результат будет зависеть от того, какие именно поездки в неё попали. Если собрать другие 500 наблюдений, статистика обычно изменится. Пока мы будем описывать полученную выборку; к изменчивости самих статистик вернёмся после этого.

Как увидеть распределение данных

Таблица удобна, когда нужно найти конкретное наблюдение. Но по пятистам строкам трудно понять, много ли коротких поездок, где сосредоточена основная часть значений и насколько часто встречаются очень долгие поездки. Можно отметить каждое время точкой на числовой оси. Тогда, правда, одинаковые и близкие значения наложатся друг на друга: одна видимая точка может скрывать несколько десятков наблюдений. Если складывать совпавшие точки в столбики, их высота уже покажет, где данных больше. Гистограмма развивает именно эту идею.

Чтобы построить гистограмму, разобьём диапазон значений на интервалы и подсчитаем, сколько наблюдений попало в каждый. Например, для времени в пути можно взять интервалы $[10, 20)$, $[20, 30)$, $[30, 40)$ и так далее. Поездка длительностью ровно 30 минут попадёт в третий интервал; границы нужно выбирать так, чтобы каждое наблюдение учитывалось ровно один раз. Над каждым интервалом строится прямоугольник. При одинаковой ширине интервалов его высоту можно положить равной числу попавших туда наблюдений. Например, в интервале $[20, 30)$ у нас 118 поездок.

Иногда по вертикали удобнее откладывать не количество, а долю наблюдений. А если мы хотим, чтобы именно *площадь* прямоугольника равнялась доле, нужно разделить эту долю ещё и на ширину интервала. При ширине h и числе наблюдений n_j в интервале получаем высоту

$$\frac{n_j}{nh}.$$

Так устроена *нормированная гистограмма*: сумма площадей всех её прямоугольников равна 1. Для нашего интервала высота равна $118/(500 \cdot 10) = 0{,}0236$, а площадь — $0{,}236$. То есть 23,6% поездок длятся от 20 до 30 минут, не включая правую границу. При неодинаковой ширине интервалов такое деление особенно важно: широкий интервал не должен казаться более плотным только потому, что в него помещается больше возможных значений.

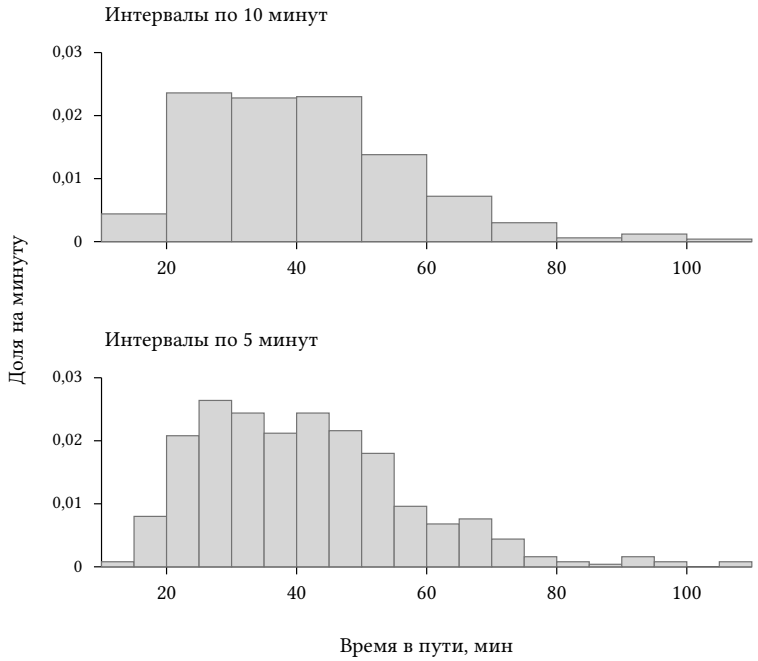


Рис. 9: Одни и те же 500 поездок при ширине интервалов 10 и 5 минут. Площадь каждого прямоугольника равна доле поездок в соответствующем интервале.

Ширина интервалов влияет на вид графика. Слишком широкие интервалы скроют подробности, а слишком узкие разобьют картину на случайные зубцы. На рисунке 9 оба варианта показывают основную массу поездок и длинный правый хвост, но мелкие различия между соседними столбцами выглядят по-разному. Поэтому отдельный пик гистограммы стоит проверять, немного меняя ширину и положение границ.

Для категорий нужен другой график. Подсчитаем число пеших поездок, поездок на велосипеде, автобусе и метро. Получатся 110, 65, 185 и 140 наблюдений соответственно. Их удобно изобразить *столбчатой диаграммой*.



Рис. 10: Число поездок каждого типа. Порядок номинальных категорий можно менять.

У столбчатой диаграммы другой смысл горизонтальной оси: здесь перечислены категории, а не интервалы числовой шкалы. Ширина столбца и расстояние между столбцами не кодируют расстояние между значениями признака. Номинальные категории можно переставить, а интервалы времени — нельзя. Для порядковых категорий, таких как интервалы опоздания, естественный порядок, конечно, стоит сохранить.

Форма распределения тоже несёт информацию. При симметричном колоколообразном распределении значения по обе стороны от центра встречаются примерно одинаково часто. Известный пример такой модели — нормальное распределение. Но у длительности поездок есть нижняя граница, тогда как задержка может сделать отдельную поездку очень долгой. Поэтому справа нередко возникает более длинный *хвост*: говорят о правосторонней асимметрии, или скошенности вправо. Пример модельного распределения с такой формой — логнормальное. Возможен и длинный левый хвост.

В данных могут быть два заметных пика. Например, при объединении студентов, живущих рядом с университетом, и студентов из отдалённых районов получатся две группы времён. Одно число, помещённое между ними, может оказаться далеко от типичного времени обеих групп. Если увеличивать объём такой выборки, два пика сами по себе не исчезнут. Большой объём выборки сам по себе не означает нормальности распределения.

Гладкая кривая, которой иногда заменяют гистограмму, изображает идеализированную модель распределения. При таком описании доли соответствуют площадям под кривой над выбранными интервалами.

Наконец, на общем фоне могут выделяться *выбросы* — отдельные необычно большие или малые значения. Для поездок это может быть ошибка в записи, а может быть настоящая длительная задержка. Разобраться в причине полезнее, чем сразу удалять неудобную строку. То, насколько сильно такие значения влияют на результат, будет одним из главных различий между статистиками.

Что считать средним

Вернёмся к вопросу об обычном времени в пути. Даже после построения графика иногда нужно сообщить одно число: сравнить две группы, оценить общий объём затрат времени или просто кратко описать данные. Статистики, характеризующие положение центра, называют *мерами центральной тенденции*. Центр выборки можно определить по-разному.

Выборочное среднее получается привычным способом: нужно сложить все наблюдения и разделить на их число.

$$\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i.$$

Если заменить все наблюдения на $\overline{X}$, их общая сумма сохранится: $n\overline{X} = \sum_i X_i$. В этом и состоит один из полезных смыслов среднего арифметического: мы как будто поровну распределили общую величину между наблюдениями. Наши 500 поездок суммарно заняли 20440 минут, поэтому среднее время равно 40,88 минуты. Если интересует суммарное время, среднее описывает его очень удобно. Но из этого ещё не следует, что большинство студентов тратит на дорогу примерно 41 минуту.

Черта означает усреднение того, что записано под ней:

$$\overline{X^2} = \frac{1}{n}\sum_{i=1}^{n} X_i^2.$$

Вообще говоря, это не $(\overline{X})^2$. Например, для 1 и 3 получаются 5 и 4 соответственно.

Такая запись применима и к преобразованным наблюдениям. Например,

$$\overline{|X-2|} = \frac{1}{n}\sum_{i=1}^{n} |X_i - 2|.$$

Сначала для каждого наблюдения вычисляют выражение под чертой, а затем усредняют результаты. Так же читается $\overline{\sin X}$ или любое другое выборочное среднее преобразованных значений.

Почему среднее бывает обманчивым? Рассмотрим отдельный маленький пример: пять поездок заняли 20, 25, 30, 35 и 40 минут. Их среднее равно 30 минутам, и это вполне подходящий центр. Теперь пусть последняя поездка из-за задержки заняла 140 минут. Среднее стало равно

$$\frac{20 + 25 + 30 + 35 + 140}{5} = 50.$$

Четыре студента из пяти добрались не дольше чем за 35 минут, но “в среднем” дорога заняла 50 минут. Ошибки в вычислении нет: один студент действительно потратил очень много времени.

Чтобы найти середину по порядку, упорядочим выборку:

$$X_{(1)} \leqslant X_{(2)} \leqslant \cdots \leqslant X_{(n)}.$$

Этот набор называется *вариационным рядом*, а $X_{(k)}$ — k-й *порядковой статистикой*. Круглые скобки в индексе означают место после сортировки. Например, X_1 — первое записанное наблюдение, а $X_{(1)}$ — наименьшее из всех. Совпавшие значения никуда не исчезают: две поездки по 25 минут займут в ряду два места.

Теперь можно выбрать *медиану* — центральное значение вариационного ряда. Если наблюдений нечётное число, середина одна. Если чётное, обычно берут среднее двух центральных значений:

$$\mathrm{Me} = \begin{cases} X_{(k+1)}, & n = 2k + 1, \\ \dfrac{X_{(k)} + X_{(k+1)}}{2}, & n = 2k. \end{cases}$$

Не менее половины наблюдений не превосходят медиану и не менее половины не меньше неё. В нашем примере из пяти поездок медиана равна 30 минутам как до задержки, так и после неё. Для полного набора из 500 поездок медиана равна 39 минутам.

Медиана определяется положением наблюдений в упорядоченном ряду. Если самое большое значение увеличить ещё сильнее, центральные места от этого не сдвинутся. Поэтому медиана *устойчива* к отдельным крайним значениям.

Для порядковых категорий середину по порядку тоже можно найти. Например, можно определить категорию, в которой находится центральное наблюдение по опозданию. Но усреднять два названия категорий при чётном объёме нельзя; в таком случае нужно оговорить правило выбора одной из них.

Среднее и медиана не обязаны совпадать. Длинный правый хвост часто сдвигает среднее вправо относительно медианы, а длинный левый — влево. У симметричной модельной кривой они могут совпасть. Но обратный вывод неверен: совпадение двух чисел ещё не доказывает, что данные симметричны или имеют нормальное распределение. И даже положение среднего относительно медианы не восстанавливает всю форму распределения.



Рис. 11: Три модельные формы распределения. Сплошная вертикальная линия отмечает среднее, штриховая — медиану. При двух пиках оба числа могут оказаться между группами.

На рисунке 11 особенно показателен пример с двумя пиками. Среднее не обязано находиться там, где данных больше всего. Увеличение объёма выборки позволит точнее увидеть эту форму, но не сделает одно среднее удачным описанием обеих групп. Именно поэтому числовые характеристики полезно читать вместе с графиком, а иногда ещё и отдельно для разных групп.

Возможных форм гораздо больше. Например, бета-распределения на отрезке $[0, 1]$ могут быть симметричными, скошенными или иметь больше значений у обоих концов отрезка. Ограниченный диапазон сам по себе не определяет форму.

Задача 1. Два алгоритма управления роботом испытывали на простых и сложных маршрутах. В таблице указано число успешных прохождений из общего числа испытаний.

Условия	Алгоритм A	Алгоритм B
Простые	81 из 90	19 из 20
Сложные	2 из 10	24 из 80

1. Найдите общую долю успешных прохождений для каждого алгоритма. Какой алгоритм лучше по этому показателю?

2. Сравните доли успешных прохождений отдельно на простых и сложных маршрутах. Объясните, почему вывод отличается от первого пункта.

3. Каждый алгоритм проверили на 100 простых и 100 сложных маршрутах. Доли успеха на каждом типе маршрутов остались такими же, как в таблице. Сколько успешных прохождений получилось у каждого алгоритма? Какой алгоритм показал лучший результат?

Мода отвечает на третий вопрос: какое значение встретилось чаще всего? В отличие от среднего и числовой медианы, она определена и для номинальных категорий. Модальный способ передвижения в нашей выборке — автобус: им воспользовались 185 из 500 студентов. Если несколько значений делят первое место по частоте, единственной моды нет.

У времени в пути наиболее частая запись — 42 минуты, она встречается 19 раз. Но время округлено, поэтому этот результат зависит и от точности записи. Для непрерывных измерений без округления точные совпадения могут вообще не встретиться. Тогда о модах часто говорят как о пиках распределения; по гистограмме можно указать модальный интервал, помня о его зависимости от выбранного разбиения.

Когда нужны другие средние

Среднее арифметическое сохраняет сумму. Иногда в задаче нужно сохранить совсем другую величину, и тогда естественно возникает другой способ усреднения. Это удобно увидеть на двух примерах.

Если изменения перемножаются, используется *среднее геометрическое*. Пусть число участников некоторого сообщества за один месяц выросло на 20%, а за следующий уменьшилось на 20%. Среднее арифметическое двух процентов равно нулю, но число участников не вернулось к исходному: оно умножилось на $1{,}2 \cdot 0{,}8 = 0{,}96$. Второе изменение считается уже от другой величины.

Чтобы получить тот же итог с постоянным месячным множителем G, нужно $G^2 = 0{,}96$. Тогда $G = \sqrt{0{,}96} \approx 0{,}9798$, то есть одинаковое уменьшение примерно на 2,02% в месяц даёт тот же итог. Для положительных чисел $X_1, \dots, X_n$ правило имеет вид

$$G = \sqrt[n]{X_1 X_2 \cdots X_n}.$$

Оно сохраняет произведение: $G^n = X_1 \cdots X_n$. В задачах о последовательных изменениях усреднять нужно множители $1 + r_i$, где r_i — доля прироста за период, а не сами проценты. Периоды при таком сравнении должны иметь одинаковую длину.

Если складывается время на равных участках пути, возникает *среднее гармоническое*. Пусть велосипедист проехал два участка по 2 километра со скоростями 12 и 24 километра в час. На первом участке он потратил $2/12$ часа, на втором — $2/24$ часа. Средняя скорость за весь путь равна

$$\frac{2 + 2}{2/12 + 2/24} = 16 \text{ км/ч}.$$

Среднее арифметическое скоростей дало бы 18 км/ч. Почему оно здесь не подходит? На медленном участке велосипедист провёл больше времени, поэтому две скорости не вносят одинаковый вклад в среднюю скорость за всю поездку.

Для положительных значений гармоническое среднее определяется как

$$H = \frac{n}{\sum_{i=1}^{n} 1/X_i}.$$

При равных расстояниях общая длина сокращается, и формула средней скорости принимает именно такой вид. А если ехать с каждой скоростью одинаковое *время*, средняя скорость будет средним арифметическим. Поэтому выбирать среднее нужно по устройству задачи: что складывается, что перемножается и что требуется сохранить.

Задача 2. Робот движется со скоростью 2 м/с на одном участке и со скоростью 6 м/с на другом.

1. Длина каждого участка равна 12 м. Найдите среднюю скорость за весь путь.

2. Теперь робот движется 4 секунды с первой скоростью и 4 секунды со второй. Найдите среднюю скорость за всё время движения.

3. Какое среднее чисел 2 и 6 получилось в каждом случае? Почему результаты различаются?

Как измерить разброс

Представим два набора времён: 29, 30, 31 и 10, 30, 50 минут. У них одинаковы и среднее, и медиана: 30 минут. Но во втором наборе значения сильнее отклоняются от 30 минут. Для описания различий нужны *меры разброса.*

Самая простая мера — размах:

$$R = X_{(n)} - X_{(1)}.$$

Он показывает ширину всего диапазона наблюдений. У двух маленьких наборов выше размах равен 2 и 40 минутам. В полной выборке поездок он равен $109 - 12 = 97$ минутам. Недостаток виден прямо из формулы: всё описание держится только на двух крайних значениях. Если самое долгое время записали неверно, размах изменится, даже если остальные 499 строк совершенно верны.

Попробуем учесть все наблюдения. Вычтем из каждого наблюдения выборочное среднее. Получатся отклонения $X_i - \overline{X}$, положительные для значений выше среднего и отрицательные для значений ниже него. Их среднее всегда равно нулю:

$$\frac{1}{n}\sum_{i=1}^{n}(X_i - \overline{X}) = \overline{X} - \overline{X} = 0.$$

Таким способом разброс не измерить: отклонения в разные стороны взаимно уничтожаются. Чтобы этого не происходило, можно возвести отклонения в квадрат.

Выборочной дисперсией в этом курсе будем называть средний квадрат отклонений от выборочного среднего:

$$S^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - \overline{X})^2.$$

Она неотрицательна и равна нулю только тогда, когда все наблюдения одинаковы. Большие отклонения получают особенно большой вес: отклонение в 20 минут даёт вклад в четыре раза больше, чем отклонение в 10 минут. Из-за этого дисперсия чувствительна к выбросам.

Раскрывая квадрат, получаем

$$S^2 = \overline{X^2} - (\overline{X})^2.$$

Это ещё один способ увидеть, почему средний квадрат и квадрат среднего различаются.

Есть и проблема с единицами измерения. Если время задано в минутах, дисперсия измеряется в квадратных минутах. Для интерпретации удобнее извлечь квадратный корень:

$$S = \sqrt{S^2}.$$

Так получается *выборочное стандартное*, или *среднеквадратичное*, *отклонение*. Оно снова измеряется в минутах и характеризует масштаб отклонений от среднего. Для наших поездок $S^2 = 260{,}2336$ мин^2, а $S \approx 16{,}13$ минуты.

Отклонения отдельных наблюдений от среднего могут превышать S. Чтобы по стандартному отклонению судить о доле наблюдений в интервале $[\overline{X} - S, \overline{X} + S]$, нужны дополнительные сведения о распределении. Например, известные правила для нормального распределения нельзя автоматически переносить на любую гистограмму.

Почему иногда делят на $n - 1$? В программах и учебниках часто встречается другая формула:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^{n} (X_i - \overline{X})^2, \qquad n > 1.$$

Это *исправленная выборочная дисперсия*. Различие связано с задачей, которую мы решаем. Для описания имеющихся отклонений естественно взять их средний квадрат и разделить на n. Но если по выборке оценивают дисперсию распределения, породившего наблюдения, возникает систематическое занижение: центр $\overline{X}$ мы уже подстроили под те же данные.

При независимых наблюдениях из одного распределения с конечной дисперсией замена n на $n - 1$ устраняет это занижение в среднем по многократным повторениям выборки. В этом смысле s^2 называют *несмещённой оценкой* дисперсии. Квадратный корень $s = \sqrt{s^2}$ тоже часто используют, но он уже не является в общем случае несмещённой оценкой стандартного отклонения. Для 500 поездок различие невелико: $S \approx 16{,}13$, а $s \approx 16{,}15$ минуты. Для небольших выборок оно заметнее, поэтому делитель всегда нужно проверять.

Задача 3. В выборке $(2, 6, 6, 6, x, y)$ два наблюдения неизвестны. Её среднее равно 6, а среднеквадратичное отклонение $S = 4$.

1. Найдите все пары (x, y), подходящие под условие. Однозначно ли определяется вариационный ряд?
2. Теперь значение S неизвестно, но среднее по-прежнему равно 6. Найдите наименьшее возможное S и значения x и y, при которых оно достигается.

Задача 4. При проверке двух датчиков получили следующие ошибки измерения расстояния, в сантиметрах:

$$A: \quad (-2, -2, -2, -2, 2, 2, 2, 2);$$
$$B: \quad (-4, 0, 0, 0, 0, 0, 0, 4).$$

1. Найдите среднее, медиану и среднеквадратичное отклонение ошибок для каждого датчика.
2. Измерение считается приемлемым, если абсолютная ошибка не превышает заданный допуск. Сравните доли приемлемых измерений при допуске 1 см, затем при допуске 3 см. Какой датчик выбрать для каждого допуска по этим данным?
3. При каких неотрицательных значениях допуска доли приемлемых измерений у двух датчиков совпадут?
4. Составьте выборку из восьми ошибок со средним 0 и среднеквадратичным отклонением 2 см, в которой доля приемлемых измерений при допуске 1 см отличается от долей у обоих датчиков. Проверьте, что ваша выборка удовлетворяет условиям.

Квантили и устойчивые меры разброса

Медиана делит упорядоченную выборку примерно пополам. Но иногда нужен другой порог. Например, сколько времени хватило хотя бы для 90% наблюдаемых поездок? Среднее на этот вопрос не отвечает. Нужно двигаться по вариационному ряду до тех пор, пока не будет учтена нужная доля наблюдений.

Выборочный квантиль уровня p задаёт такой порог. Для $p \in [0, 1]$ договоримся использовать правило

$$\hat{q}_p = \begin{cases} X_{(1)}, & p = 0, \\ X_{([pn])}, & 0 < p \leqslant 1. \end{cases}$$

Сначала умножаем p на объём выборки, затем округляем результат вверх и берём наблюдение с этим номером. Доля наблюдений со значениями не выше выбранного порога составляет не менее p. При повторяющихся значениях эта доля может оказаться заметно больше p.

При $n = 500$ для уровня 0,9 нужно взять 450-е наблюдение в вариационном ряду. У нас оно равно 62 минутам. Это значит, что не менее 90% поездок в данной выборке заняли не больше 62 минут.

Квантиль уровня 0 — минимум, уровня 1 — максимум. Квантили уровней 1/100, 2/100, ..., 99/100 называют процентилями. Например, 90-й процентиль соответствует $p = 0{,}9$.

Выборочные квантили можно определять по-разному. Некоторые правила используют интерполяцию между соседними наблюдениями. Вычисляя квантили вручную или сравнивая результаты программ, нужно знать принятое соглашение.

В частности, при нечётном n наш квантиль уровня 0,5 совпадает с обычной медианой. При чётном $n = 2k$ он равен $X_{(k)}$, а медиану выше мы определили как среднее $X_{(k)}$ и $X_{(k+1)}$. Например, у времён 20, 25, 30, 50 минут получаются $\hat{q}_{0,5} = 25$ и $\mathrm{Me} = 27{,}5$ минуты. Оба числа связаны с серединой данных, но основаны на разных соглашениях.

Квартили — это квантили уровней 0,25, 0,5 и 0,75:

$$Q_1 = \hat{q}_{0,25}, \qquad Q_2 = \hat{q}_{0,5}, \qquad Q_3 = \hat{q}_{0,75}.$$

Первый и третий квартили ограничивают центральную часть выборки, приблизительно соответствующую средним 50% наблюдений. Точная доля зависит от объёма выборки и совпавших значений. Разность этих квартилей называют *межквартильным размахом*:

$$\mathrm{IQR} = Q_3 - Q_1.$$

В нашей выборке $Q_1 = 28$ и $Q_3 = 50$ минут, поэтому $\mathrm{IQR} = 22$ минуты. Полный размах равен 97 минутам, но центральная часть данных занимает гораздо более узкий диапазон.

Иногда квартили находят как медианы нижней и верхней половин вариационного ряда, исключив общую медиану при нечётном объёме. Это ещё одно распространённое соглашение, которое может дать другой ответ на маленькой выборке. Здесь мы последовательно используем определение через $\lceil pn \rceil$.

Вернёмся к пяти поездкам 20, 25, 30, 35, 40 минут и замене последнего значения на 140. Крайнее наблюдение осталось крайним, поэтому $Q_1 = 25$ и $Q_3 = 35$ в обоих случаях. Межквартильный размах не изменился, хотя полный размах вырос в шесть раз. Теперь можно сопоставить несколько характеристик одного изменения:

Характеристика	До задержки	После
Среднее, мин	30	50
Медиана, мин	30	30
Размах, мин	20	120
S^2, мин^2	50	2050
S, мин	7,07	45,28
IQR, мин	10	10

Задача 5. Для выборки $(15, 9, 7, 11, 5, 11, 13, 9)$ найдите вариационный ряд, среднее, медиану, среднеквадратичное отклонение S, размах и межквартильный размах.

Построим ещё одну устойчивую меру разброса. Для этого сначала найдём медиану исходной выборки, затем вычислим расстояния всех наблюдений до неё и возьмём медиану этих расстояний:

$$\mathrm{MAD} = \mathrm{median}\big(|X_1 - \mathrm{Me}|, \dots, |X_n - \mathrm{Me}|\big).$$

Эту величину называют *медианным абсолютным отклонением*. В отличие от дисперсии, она не возводит отклонения в квадрат, а вместо среднего использует медиану. Для пяти поездок из примера MAD равен 5 минутам и сохраняется после задержки; для полного набора из 500 поездок он равен 11 минутам. Это ещё один способ описать разброс, который мало реагирует на отдельные крайние значения.

Эмпирическое распределение

До сих пор мы описывали выборку с помощью отдельных чисел и графиков. Теперь посмотрим на неё как на небольшую вероятностную модель. Запишем каждое наблюдение на отдельной карточке, перемешаем карточки и наугад вытянем одну из них. У каждой из n карточек вероятность быть выбранной равна $1/n$. Полученное распределение значений называют *эмпирическим распределением* выборки. Слово “эмпирическое” означает, что оно построено по наблюдениям.

Если все наблюдения различны, каждому значению достаётся вероятность $1/n$. Если значение встретилось r раз, его вероятность равна r/n: карточек с ним тоже r. Например, для пяти времён 20, 25, 25, 30, 50 минут эмпирическое распределение имеет вид

Время, мин	20	25	30	50
Вероятность	1/5	2/5	1/5	1/5

Равновероятны именно карточки, а не четыре различных значения. Если оставить от каждого значения по одной карточке, получится уже другое распределение.

Даже для непрерывного признака эмпирическое распределение дискретно: оно сосредоточено на конечном числе наблюдённых значений. Это свойство модели, построенной по выборке, а не утверждение о природе самого признака.

В этой модели вероятность попасть в любой набор значений A совпадает с наблюдённой долей:

$$\widehat{\mathbb{P}}_n(A) = \frac{\#\{i \,:\, X_i \in A\}}{n}.$$

Например, вероятность времени меньше 30 минут равна $3/5$. Среднее эмпирического распределения совпадает с выборочным средним, а его дисперсия — с S^2, в которой делитель равен n. В обоих случаях усредняем по тем же n равновероятным карточкам.

Пока мы только точно переписали имеющиеся данные на языке вероятностей. Если хотим судить о новых поездках, появляется дополнительная идея: использовать эмпирическое распределение как

приближение неизвестного распределения времени в пути. Такое приближение зависит от качества и объёма выборки. Отсутствие в ней поездки длиной 120 минут ещё не означает, что такая поездка невозможна.

Эмпирическая функция распределения

Теперь применим эмпирическое распределение к наборам вида $A = (-\infty, t)$. Их вероятности — уже знакомые нам доли поездок, время которых меньше заданного порога. Можно заранее сделать это сразу для всех порогов. Получится график, по которому удобно отвечать на вопросы “какая доля добирается быстрее чем за полчаса?” и “какая доля тратит не меньше часа?”.

Эмпирической функцией распределения называют функцию

$$F_n^*(t) = \frac{\#\{i \,:\, X_i < t\}}{n} = \frac{1}{n}\sum_{i=1}^{n} I_{\{X_i<t\}}.$$

Она показывает долю наблюдений, *строго меньших* t. Символ # означает число подходящих индексов, а индикатор $I_{\{X_i<t\}}$ равен 1, если условие выполнено, и 0 иначе. Индексы в первой записи нужны для того, чтобы одинаковые значения учитывались столько раз, сколько они встретились. Таким образом, $F_n^*(t) = \widehat{\mathbb{P}}_n((-\infty, t))$: ЭФР описывает эмпирическое распределение через накопленные доли.

Представим, что порог t медленно движется слева направо. Пока он не прошёл ни одного наблюдения, значение функции равно нулю. Проходя очередное наблюдение, мы включаем его в подсчёт, и доля увеличивается на $1/n$. Между наблюдениями подсчитывать нечего, поэтому функция остаётся постоянной. Если одно значение встретилось r раз, после него произойдёт один скачок высотой r/n.

Вернёмся к маленькому примеру: 20, 25, 25, 30, 50 минут. При $t = 25$ учитывается только поездка длительностью 20 минут, поэтому $F_5^*(25) = 1/5$. Как только порог станет больше 25, добавятся сразу две поездки и значение станет равно $3/5$. В точке $t = 30$ оно ещё равно $3/5$, а сразу справа от неё — уже $4/5$.

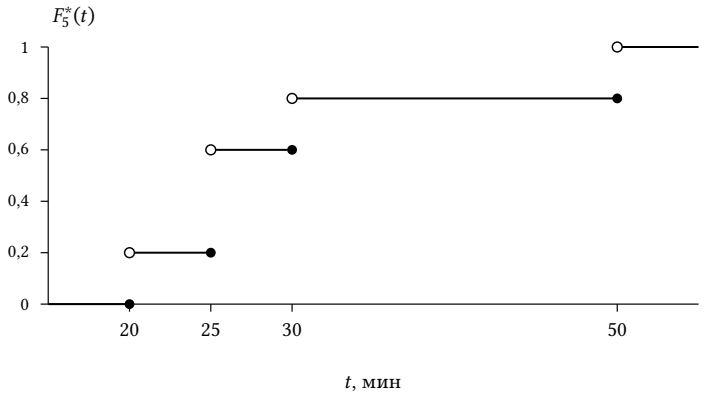


Рис. 12: ЭФР выборки 20, 25, 25, 30, 50. Закрашенная точка показывает значение функции в месте скачка. Верхняя точка выколота: новое наблюдение учитывается только после того, как порог его прошёл.

Часто ЭФР определяют через $X_i \leqslant t$. Тогда она непрерывна справа: в точке скачка берётся верхний уровень. Между наблюдениями обе версии совпадают. В этом курсе используем $X_i < t$.

Из построения сразу видны основные свойства ЭФР. Она не убывает и принимает значения от 0 до 1. При $t \leqslant X_{(1)}$ она равна 0, а при $t > X_{(n)}$ равна 1. Из-за строгого неравенства в определении в точке скачка сохраняется нижний уровень: функция *непрерывна слева*. Для её построения не нужно выбирать интервалы гистограммы. Каждое наблюдение вносит свою долю, а положения скачков сохраняют все разные значения выборки. При большом числе наблюдений мелкие ступени могут быть почти не видны, но функция от этого не перестаёт быть ступенчатой.

Как пользоваться этим графиком? Для полных данных о поездках

$$F^*_{500}(30) = \frac{140}{500} = 0{,}28, \qquad F^*_{500}(60) = \frac{438}{500} = 0{,}876.$$

Значит, 28% поездок заняли меньше получаса, а 87,6% — меньше часа. Разность этих значений равна 0,596: именно 59,6% поездок попали в интервал $[30, 60)$. В общем виде

$$\frac{\#\{i : a \leqslant X_i < b\}}{n} = F^*_n(b) - F^*_n(a), \qquad a < b.$$

Из всех наблюдений, меньших b, мы исключили те, которые меньше a. Левая граница поэтому включается, а правая — нет.

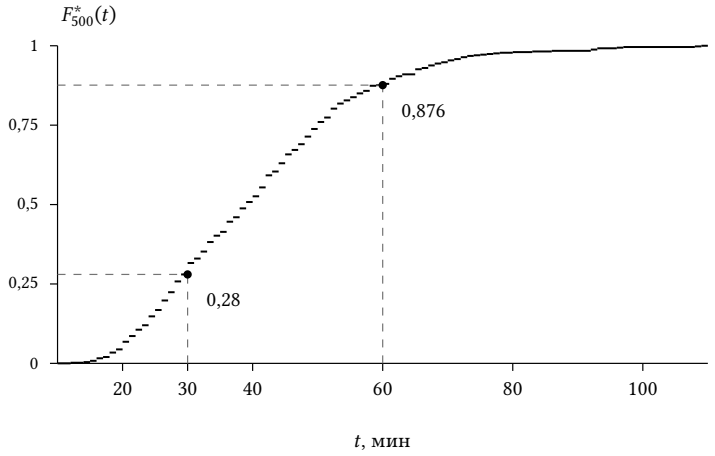


Рис. 13: ЭФР времени в пути для всех 500 поездок. Разность высот при 30 и 60 минутах даёт долю наблюдений в интервале $[30, 60)$.

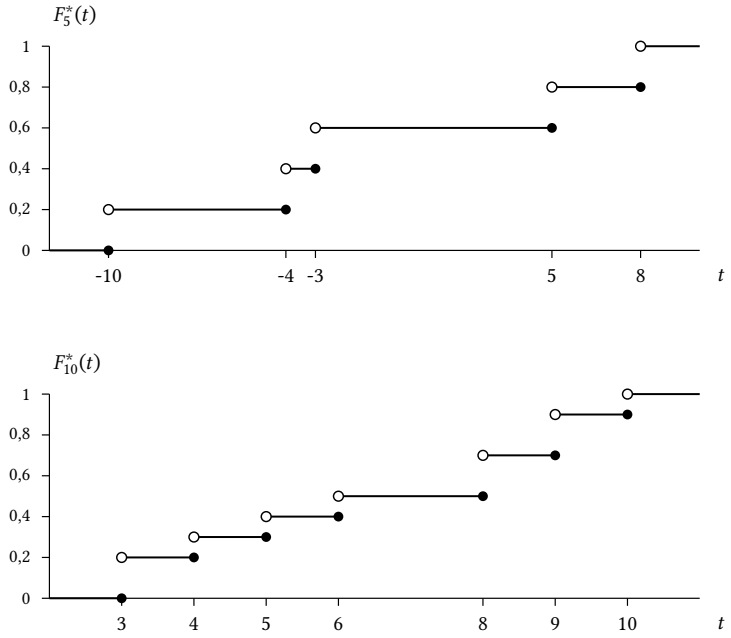
Дополнение $1 - F^*_n(t)$ показывает долю значений, *не меньших* t. Например, не меньше часа занимают 12,4% поездок. Если нужен порог “не больше”, значения, в точности равные порогу, нужно добавить. В нашей выборке 254 поездки короче 40 минут, а 263 поездки длятся не больше 40 минут: ещё девять имеют длительность ровно 40 минут. При округлённых данных такая разница вполне заметна.

Квантили позволяют читать тот же набор данных в обратном направлении: мы задаём долю и ищем соответствующий порог. Из-за ступеней далеко не каждому уровню p соответствует точное равенство $F^*_n(t) = p$. Поэтому и понадобилось отдельное правило через порядковую статистику. Нужно найти первое наблюдаемое значение, для которого накопленная доля после учёта *всех* его повторений будет не меньше p. На графике с нашим строгим неравенством это верхний уровень скачка.

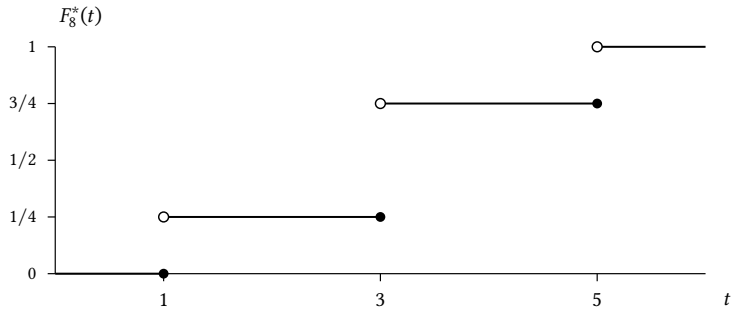
Задача 6. Для следующих выборок нарисуйте графики эмпирических функций распределения:

1. $(-3, 5, -4, -10, 8)$;
2. $(3, 6, 9, 3, 10, 5, 8, 9, 8, 4)$.

Решение. Эмпирические функции распределения изображены ниже: сверху — для первой выборки, снизу — для второй.



Задача 7. На рисунке показана эмпирическая функция распределения выборки из восьми наблюдений.



1. Восстановите вариационный ряд выборки.
2. Какая доля наблюдений строго меньше 3? Какая доля не превосходит 3?
3. Сколько различных последовательностей из восьми наблюдений соответствует этой функции?

ЭФР в рейтингах: скорость печати

Сервис проверки скорости печати может показывать распределение результатов и сообщать, какая доля участников печатает медленнее вас. По горизонтали отложена скорость, а по вертикали накопленного графика — доля результатов ниже неё. Это и есть тот же принцип построения ЭФР.

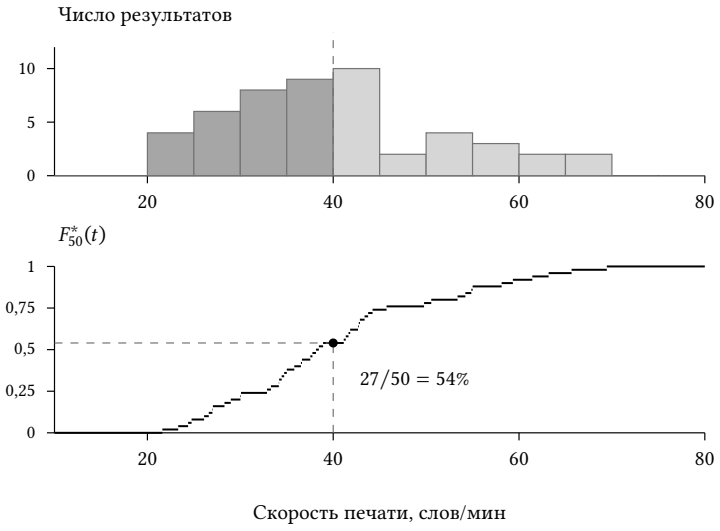


Рис. 14: Учебный пример с 50 результатами скорости печати. Сверху — гистограмма, снизу — ЭФР тех же данных. Порог 40 слов в минуту отделяет 27 меньших результатов.

На рисунке 14 27 из 50 результатов строго меньше 40 слов в минуту. Поэтому $F_{50}^*(40) = 27/50 = 0{,}54$: такой результат выше 54% результатов в этой выборке. Это накопленная доля результатов ниже выбранной скорости, а не доля людей, печатающих ровно с этой скоростью.

Гистограмма и накопленная кривая отвечают на разные вопросы. Высокий столбец показывает, что в небольшом интервале скоростей много наблюдений. Крутой участок ЭФР говорит о том же: при

небольшом увеличении порога добавляется большая доля данных. А пологий участок соответствует интервалу, в котором результатов мало. Поэтому у гистограммы может быть пик и затем спад, но ЭФР всё равно продолжит расти или останется постоянной. Если обе кривые нанесены на один рисунок, нужно смотреть на подписи осей: высота гистограммы и накопленный процент имеют разный смысл.

При совпадении результатов доля строго меньших значений отличается от доли не превосходящих. Величина $1 - F_n^*(t)$ включает всех, кто показал результат не хуже t, включая совпадения. Поэтому фраза “входит в лучшие 10%” требует соглашения о том, как учитывать одинаковые результаты.

Рейтинг зависит и от того, какие результаты попали в сравнение: все попытки на сайте, последние попытки или, например, лучшие результаты каждого участника. Эти наборы дадут разные распределения.

Все вычисленные характеристики относятся к конкретным наблюдениям. Например, среднее 40,88 минуты получено по нашим 500 поездкам. Насколько оно изменилось бы при другом наборе поездок? Вопрос о разбросе самой статистики приводит к бутстрэпу.

Бутстрэп: повторные выборки из имеющихся данных

Представим, что мы могли бы много раз заново собирать по 500 поездок в тех же условиях и каждый раз вычислять среднее. Получились бы разные числа. Их распределение показывало бы, насколько чувствительно среднее к случайному составу выборки. Но обычно у нас есть только один набор наблюдений, а распределение, из которого они получены, неизвестно.

Идея бутстрэпа состоит в том, чтобы заменить неизвестное распределение эмпирическим и повторить сбор выборки уже из этой доступной модели. Будем рассматривать простейший случай: исходные наблюдения независимы и имеют одно распределение. Тогда новую выборку моделируем как n независимых извлечений из эмпирического распределения исходных данных. Каждый раз выбираем одну из n карточек с вероятностью $1/n$, записываем её значение и возвращаем карточку обратно. Полученный набор того же объёма называют *бутстрэп-выборкой*.

Например, из уже знакомой выборки

$$20,\ 25,\ 25,\ 30,\ 50$$

могли получиться повторные выборки

$$25,\ 20,\ 25,\ 25,\ 50 \quad \text{со средним } 29,$$
$$50,\ 50,\ 30,\ 20,\ 25 \quad \text{со средним } 35.$$

В первой не встретилось время 30 минут, а во второй дважды встретилось время 50 минут. Это нормальная часть процедуры: некоторые наблюдения повторяются, другие не выбираются ни разу. При

этом вероятность получить 25 на каждом отдельном шаге остаётся равной 2/5.

Зачем нужно возвращение? Если выбрать все n карточек без возвращения, мы просто переставим исходные наблюдения. Среднее, медиана и дисперсия останутся прежними, и оценить их изменчивость таким способом не получится. Возвращение позволяет менять число повторений каждого наблюдения, сохраняя общий объём выборки.

Обозначим интересующую нас статистику через $T = T(X_1, \dots, X_n)$. Повторим описанную процедуру B раз и в каждой новой выборке вычислим ту же статистику:

$$T_b^* = T(X_{b,1}^*, \dots, X_{b,n}^*), \qquad b = 1, \dots, B.$$

Теперь у нас есть B значений статистики. По ним можно построить гистограмму или ЭФР и вычислить характеристики разброса. Так мы численно приближаем *бутстрэп-распределение статистики* — её распределение при повторных выборках из фиксированного эмпирического распределения. Если исходная выборка достаточно хорошо передаёт свойства изучаемого распределения, бутстрэп может приближать изменчивость статистики при новом сборе данных.

Если статистика использует несколько столбцов, выбирать нужно целые строки. Например, для связи расстояния со временем сохраняем оба значения одной поездки вместе. Независимый выбор значений из каждого столбца разрушил бы эту связь.

Что показывает бутстрэп-распределение

Вернёмся к полному набору из 500 поездок. Для вычислительного примера применим к нему описанную схему: построим $B = 5000$ выборок по $n = 500$ наблюдений и в каждой найдём среднее время. На рисунке ниже каждое учтённое значение — среднее по целой повторной выборке.

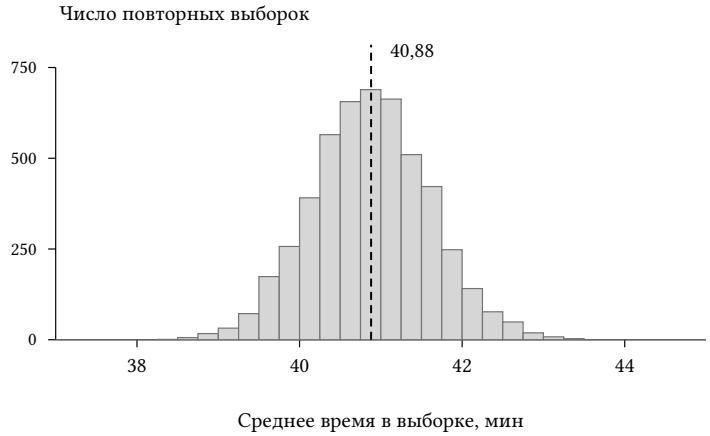


Рис. 15: Средние времена в 5000 бутстрэп-выборках объёма 500. Ширина интервала гистограммы — четверть минуты. Пунктир отмечает исходное среднее 40,88 минуты.

Среднее полученных средних равно примерно 40,875 минуты, а их стандартное отклонение — 0,723 минуты. Это гораздо меньше стандартного отклонения отдельных времён, равного 16,13 минуты.

Противоречия здесь нет: длительности отдельных поездок сильно различаются, а среднее по 500 поездкам меняется заметно слабее. Эти два разброса отвечают на разные вопросы: насколько непохожи поездки и насколько изменчиво их среднее.

Стандартной ошибкой статистики называют стандартное отклонение её распределения при повторном сборе выборок. Бутстрэп позволяет оценить эту величину по разбросу вычисленных T_b^*:

$$\overline{T}^* = \frac{1}{B}\sum_{b=1}^{B} T_b^*,$$

$$\widehat{\mathrm{SE}}_{\mathrm{boot}}(T) = \sqrt{\frac{1}{B-1}\sum_{b=1}^{B}(T_b^* - \overline{T}^*)^2}.$$

В нашем примере оценка стандартной ошибки среднего составляет около 0,72 минуты, или 43 секунд. Это оценка масштаба случайных колебаний, а не обещание, что ошибка конкретного среднего обязательно меньше 43 секунд.

Среднее удобно для первого примера, но тот же алгоритм позволяет изучать изменчивость медианы, доли поездок короче получаса или MAD. Достаточно изменить правило вычисления T в каждой повторной выборке.

У чисел n и B разные роли. Число n показывает, сколько наблюдений мы действительно получили. Число B задаёт, сколько раз компьютер повторил вычислительный опыт. Увеличение B делает гистограмму устойчивее и уменьшает случайную погрешность самой симуляции. Оно не превращает 500 поездок в тысячи новых наблюдений и не устраняет неопределённость из-за ограниченного объёма данных.

При этом повторные выборки должны учитывать устройство исходных данных. Если в таблице много поездок одних и тех же студентов, их нельзя автоматически считать независимыми: может потребоваться повторный выбор студентов вместе с их поездками. Если число наблюдений в каждой группе заранее фиксировано, можно делать повторный выбор внутри групп, сохраняя их объёмы. В нашем примере строки выбираются из всей таблицы, поэтому число поездок каждого типа в повторных выборках может меняться. Бутстрэп также не исправит смещение исходного опроса и не добавит не наблюдавшиеся в нём случаи.

Для среднего разброс в бутстрэп-модели можно найти и без симуляции: он равен $S/\sqrt{n}$. Здесь это $16{,}13/\sqrt{500} \approx 0{,}721$ минуты. Результат симуляции близок к этому числу. Для других статистик столь простого выражения может не быть.

Задача 8. Дана выборка $X = (2, 5, 8)$. Рассмотрим все упорядоченные бутстрэп-выборки размера 3, получаемые с возвращением из X.

1. Найдите возможные значения среднего бутстрэп-выборки и число выборок, которым соответствует каждое значение. Сколько всего бутстрэп-выборок?
2. Постройте эмпирическую функцию распределения полученных средних, учитывая повторы.
3. Наудачу равновероятно выбирают одну бутстрэп-выборку. Какова вероятность, что её среднее лежит от 4 до 6 включительно? Теперь равновероятно выбирают одно из различных значений среднего. Какой будет та же вероятность? Объясните результат сравнения.
4. Найдите среднеквадратичное отклонение полученных средних, учитывая повторы. Сравните его со среднеквадратичным отклонением исходной выборки. Почему они различаются и что характеризует каждое из них?

Что такое доверительный интервал?

Стандартная ошибка описывает масштаб изменчивости оценки. Другой способ сообщить о её неопределённости — указать интервал. *Доверительный интервал (ДИ)* — это диапазон значений, построенный по выборочным данным для оценки неизвестного параметра генеральной совокупности. Таким параметром может быть, например, среднее время в пути во всей изучаемой совокупности поездок.

Уровень доверия, например 95%, характеризует правило построения интервала. Если много раз получать новые выборки того же объёма в тех же условиях и каждый раз строить интервал по этому правилу, то у корректного метода около 95% таких интервалов будут содержать истинное значение параметра. Сам параметр в этой модели фиксирован; от выборки к выборке меняются границы интервала. После получения данных конкретный интервал либо содержит параметр, либо не содержит его. Поэтому уровень 95% не означает вероятность того, что фиксированный параметр лежит именно в уже вычисленном интервале.

Как получить доверительный интервал с помощью бутстрэпа

Возьмём уже полученные бутстрэп-значения $T_1^*, \dots, T_B^*$. Для получения приближённого ДИ уровня 95% можно выбросить примерно по 2,5% самых маленьких и самых больших значений, а в качестве ДИ взять наименьший интервал, содержащий все оставшиеся значения.

Это построение называют *перцентильным бутстрэп-интервалом*. Точное правило для границ удобно записать через квантили:

$$\left[\hat{q}^*_{0{,}025},\ \hat{q}^*_{0{,}975}\right].$$

Здесь $\hat{q}^*_p$ — квантиль уровня p по значениям статистики $T_1^*, \dots, T_B^*$, а не по исходным наблюдениям $X_1, \dots, X_n$. Если упорядочить эти

значения как $T^*_{(1)} \leqslant \ldots \leqslant T^*_{(B)}$, то по принятому в лекции соглашению

$$\hat{q}^*_p = T^*_{(\lceil pB \rceil)}, \qquad 0 < p \leqslant 1.$$

Поэтому доли отброшенных значений на конечной выборке лишь приблизительно равны 2,5%; при совпадающих значениях границ внутри интервала может остаться и больше 95% результатов. Аналогично можно построить приближённый ДИ любого заданного уровня $1 - \varepsilon$:

$$\left[\hat{q}^*_{\varepsilon/2}, \hat{q}^*_{1-\varepsilon/2}\right], \qquad 0 < \varepsilon < 1.$$

Для нашего примера с поездками используем те же 5000 бутстрэп-средних. Границами служат 125-е и 4875-е значения в упорядоченном ряду:

$$\left[39{,}494;\ 42{,}330\right] \text{ мин.}$$

Округлив, получаем приблизительный 95% доверительный интервал для среднего времени в пути от 39,49 до 42,33 минуты. Он характеризует неопределённость оценки среднего в рассматриваемой модели поездок. Не следует ожидать, что в эти узкие границы попадут 95% отдельных поездок: распределение их длительностей гораздо шире.

Почему интервал назван приближённым? То, что мы оставили центральные 95% бутстрэп-значений, само по себе не гарантирует 95% покрытия истинного параметра при новом сборе данных. Точность зависит от исходной выборки, изучаемой статистики и того, насколько хорошо бутстрэп передаёт её изменчивость. Например, при малой выборке или заметном смещении оценки фактическое покрытие может существенно отличаться от заданного. Увеличение числа повторений B уточняет вычисленные квантили, но не устраняет эту проблему приближения.

Таким образом, эмпирическое распределение связывает две задачи. Сначала мы описываем уже полученные данные, в частности с помощью ЭФР. Затем используем то же распределение для повторного моделирования выборок и приближённо оцениваем изменчивость статистик, в том числе с помощью стандартных ошибок и доверительных интервалов.

Практическое задание 2. Байесовский классификатор

В этом задании вы будете создавать наивный байесовский классификатор. Нашей целью будет написать функцию, принимающую email (как строку) в качестве параметра и классифицирующую его как *спам* или *не спам*. В её основе будет лежать модель, которая *обучается* на наборе образцов.

Подготовка email-ов. Обработка текста зависит от конкретной задачи. Для построения байесовского классификатора мы будем обращаться с письмами просто как с наборами слов в нижнем регистре. То есть каждый текст должен быть переведён во множество слов (порядок слов не имеет значения) так, чтобы:

1. Любые знаки пунктуации были просто проигнорированы.
2. Все слова были переведены в нижний регистр.
3. Разумеется, дублирующиеся слова учитывались только один раз.

Например, письмо с текстом “Купите наш товар!” представляется как множество: {купите, наш, товар}.

Правило принятия решения. Для принятия решения нам потребуется научиться вычислять следующие величины:

$$\mathbb{P}(\text{спам} \mid \{\text{купите, наш, товар}\}),$$
$$\mathbb{P}(\text{не спам} \mid \{\text{купите, наш, товар}\}).$$

Здесь под $\mathbb{P}(\text{спам} \mid \{\text{купите, наш, товар}\})$ мы понимаем вероятность события “письмо является спамом”, если событие “в письме встречаются слова купите, наш, товар” выполняется. Такой способ записи событий (словами в фигурных скобках) является неформальным, но удобным для изложения.

Сумма этих вероятностей равна 1 (убедитесь, что понимаете почему), и мы будем предсказывать спам, если

$$\mathbb{P}(\text{спам} \mid \{\text{купите, наш, товар}\}) > 0{,}5,$$

и не спам при меньшем значении. В случае ничьей вы можете сделать произвольный выбор.

Но как их вычислять? Вычислить эти значения нам поможет *теорема Байеса*:

$$\begin{aligned}\mathbb{P}(\text{спам} \mid W) &= \frac{\mathbb{P}(W \mid \text{спам})\mathbb{P}(\text{спам})}{\mathbb{P}(W)} \\ &= \frac{\mathbb{P}(W \mid \text{спам})\mathbb{P}(\text{спам})}{\mathbb{P}(W \mid \text{спам})\mathbb{P}(\text{спам}) \\ &\quad + \mathbb{P}(W \mid \text{не спам})\mathbb{P}(\text{не спам})}.\end{aligned}$$

Для компактной записи здесь обозначим через W событие {купите, наш, товар}.

Формула выглядит сложнее, но входящие в неё вероятности проще вычислить. Так, вероятность спама можно оценить отношением количества спам-писем к количеству всех писем:

$$\mathbb{P}(\text{спам}) = \frac{\#\text{ спам-писем}}{\#\text{ всех писем}}.$$

И наоборот:

$$\mathbb{P}(\text{не спам}) = \frac{\#\text{ обычных писем}}{\#\text{ всех писем}}.$$

Можно попробовать аналогично вычислять и следующие вероятности:

$$\mathbb{P}(W \mid \text{спам}) = \frac{\#\text{ спам-писем со словами из } W}{\#\text{ спам-писем}},$$

но в случае реальных писем вероятность того, что все слова некоторого письма встретятся в каком-то другом письме, может оказаться слишком мала, поэтому такое определение оказывается неудачным.

Условная независимость слов. Чтобы вычислять вероятность появления набора слов, используется *наивное предположение* об их *условной независимости*. Это означает, что, если известен класс письма Y, слова в нём считаются независимыми друг от друга. Формально: события $A_1, \ldots, A_n$ называются условно независимыми при условии B, если

$$\mathbb{P}(A_1 \cap \cdots \cap A_n \mid B) = \prod_{k=1}^{n} \mathbb{P}(A_k \mid B).$$

Применяя это предположение к нашей задаче, получаем, что для любого класса Y:

$$\mathbb{P}(\{w_1, w_2, \ldots, w_n\} \mid Y) \approx \prod_{k=1}^{n} \mathbb{P}(w_k \mid Y).$$

Например, для набора {купите, наш, товар} имеем:

$$\begin{aligned}\mathbb{P}(W \mid \text{спам}) &= \mathbb{P}(\text{купите} \mid \text{спам}) \\ &\quad \cdot \mathbb{P}(\text{наш} \mid \text{спам})\mathbb{P}(\text{товар} \mid \text{спам}).\end{aligned}$$

Таким образом, вместо маловероятного события совместного появления всех слов мы оперируем произведением более простых вероятностей для отдельных слов.

Сглаживание Лапласа. Но так как может оказаться даже, что отдельное слово больше нигде не встречалось, следует пойти на шаг дальше и применить так называемое *сглаживание Лапласа*, при котором для каждого слова мы считаем, что к корпусу[17] добавлены два искусственных письма: одно со словом, другое без него. То есть финальная формула для вычисления такой вероятности выглядит так:

$$\mathbb{P}(\text{купите} \mid \text{спам}) = \frac{\#\text{ спам-писем со словом “купите”} + 1}{\#\text{ спам-писем} + 2}.$$

[17] Корпус — это совокупность всех текстов или писем, собранных для обучения и анализа модели.

Как избегать погрешностей. Пусть исследуемое письмо состоит из n слов $w_1, w_2, \ldots, w_n$. Тогда, согласно нашему определению, вероятность того, что это письмо является спамом, равна:

В этой формуле и далее $W = \{w_1, w_2, \ldots, w_n\}$.

$$\mathbb{P}(\text{спам} \mid W) = \frac{\mathbb{P}(\text{спам}) \prod_{k=1}^{n} \mathbb{P}(w_k \mid \text{спам})}{\mathbb{P}(\text{спам}) \prod_{k=1}^{n} \mathbb{P}(w_k \mid \text{спам}) + \mathbb{P}(\text{не спам}) \prod_{k=1}^{n} \mathbb{P}(w_k \mid \text{не спам})}.$$

Но в результате произведения вероятностей мы можем получить очень маленькие числа в числителе и знаменателе, что приведёт нас к неправильному ответу. Так как числитель входит в знаменатель, достаточно проверить неравенство (убедитесь, что понимаете почему):

$$\mathbb{P}(\text{спам}) \prod_{k=1}^{n} \mathbb{P}(w_k \mid \text{спам}) > \mathbb{P}(\text{не спам}) \prod_{k=1}^{n} \mathbb{P}(w_k \mid \text{не спам}).$$

После этого потери точности в результате перемножения вероятностей можно избежать, просто взяв логарифм:

$$\log \mathbb{P}(\text{спам}) + \sum_{k=1}^{n} \log \mathbb{P}(w_k \mid \text{спам}) > \log \mathbb{P}(\text{не спам}) + \sum_{k=1}^{n} \log \mathbb{P}(w_k \mid \text{не спам}).$$

Почему 80/20 — это эвристика. Разделение датасета на обучающую и тестовую части в пропорции 80/20 — распространённая практическая эвристика, а не теоретическое правило. Наша цель здесь — оставить достаточно данных для оценки параметров и при этом иметь независимую выборку для честной оценки качества. На маленьких наборах лучше использовать перекрёстную проверку (*k-fold CV*), например $k = 5$ или $k = 10$: данные делятся на k равных частей, обучение проводится k раз, каждый раз откладывая свою часть для теста, а метрика усредняется.

Где брать письма для обучения и проверки классификатора. В качестве возможных источников для обучающего набора писем предлагаются базы данных Enron Spam или PU Corpora, но вы можете использовать любой другой источник для обучающего набора писем. В крайнем случае письма можно сгенерировать самостоятельно.

Наборы данных для задания. Можно выбрать один из следующих источников:

- **Enron-Spam** — обычные письма из корпуса Enron и спам. Для начала удобно взять один из предварительно обработанных наборов, например Enron1.
- **SpamAssassin Public Corpus** — небольшой набор настоящих писем. Начните с архивов `easy_ham` и `spam` от 28 февраля 2003 года: обычные письма и спам уже разделены. В письмах сохранены почтовые заголовки.
- **Ling-Spam** — обычные письма из списка рассылки и спам; ещё один вариант для работы с текстами писем.
- **PU Corpora** — дополнительный вариант. Тексты представлены в закодированном виде, поэтому обработку данных нужно адаптировать к формату корпуса.

Ссылки на Enron-Spam, Ling-Spam и PU Corpora ведут в каталог AUEB. В разделе *Datasets* нажмите *Download* у нужного набора.

Рекомендуется использовать 80% писем для обучения модели (для вычисления описанных выше вероятностей) и проверять её работу на оставшихся 20%. Для оценки качества удобно начать с простой метрики точности:

$$\text{точность} = \frac{\#\text{ верно классифицированных писем}}{\#\text{ всех писем}}.$$

Однако одной точности недостаточно, так как она не показывает, какие ошибки чаще допускает модель. Поэтому дополнительно вычисляют *чувствительность* (sensitivity, полнота) и *специфичность* (specificity):

$$\text{чувствительность} = \frac{\#\text{ спамовых писем, верно классифицированных как спам}}{\#\text{ всех спамовых писем}},$$

$$\text{специфичность} = \frac{\#\text{ обычных писем, верно классифицированных как не спам}}{\#\text{ всех обычных писем}}.$$

Чувствительность показывает, насколько хорошо классификатор распознаёт спам, а специфичность — насколько надёжно он не помечает обычные письма как спам.

Вопросы для подготовки

Простые вопросы к коллоквиуму

Лекция 3. Формула Байеса и обновление вероятностей.

1. Формула Байеса для полной группы гипотез и условия её применимости.
2. Априорная и апостериорная вероятности. Какую роль играет априорная вероятность при обновлении?
3. Чем отличаются вероятности $\mathbb{P}(A \mid H)$ и $\mathbb{P}(H \mid A)$?
4. Шансы события. Как перейти от вероятности к шансам и обратно?
5. Матрица ошибок: True Positive, False Positive, True Negative, False Negative. Что означают эти четыре исхода классификации?
6. Точность (accuracy): определение и формула. Почему одной точности недостаточно для оценки классификатора?
7. Чувствительность (sensitivity): определение, формула и интерпретация через условную вероятность.
8. Специфичность (specificity): определение, формула и интерпретация через условную вероятность.
9. Коэффициент Байеса: определение и связь между априорными и апостериорными шансами.
10. Связь коэффициента Байеса с чувствительностью и специфичностью для положительного и отрицательного результатов теста.
11. Последовательное обновление вероятностей. При каком условии коэффициенты Байеса для отдельных наблюдений можно перемножать?

Лекция 4. Статистика и бутстрэп.

12. Типы данных: количественные и качественные. Дискретные и непрерывные количественные данные. Номинальные и порядковые качественные данные.
13. Выборка и вариационный ряд.
14. Выборочное среднее: формула и смысл.
15. Среднее геометрическое: формула и условия применения.
16. Среднее гармоническое: формула и условия применения.
17. Медиана выборки при нечётном и чётном числе наблюдений.
18. Выборочная дисперсия: формула и смысл.
19. Выборочное стандартное отклонение: связь с дисперсией и единицы измерения.
20. Размах выборки.
21. Эмпирическая функция распределения: определение, построение графика.
22. Выборочные квантили и квартили: смысл и вычисление по принятому в курсе определению.
23. Межквартильный размах: определение и смысл.
24. Идея бутстрэпа. Как получить бутстрэп-выборку из исходной выборки и зачем используется выбор с возвращением?
25. Бутстрэп-распределение статистики на примере выборочного среднего. Как его получают и что оно показывает?

Обычные вопросы к экзамену

1. Теорема Байеса и её доказательство. Пример применения.
2. Опишите подробно (с вычислениями) пример использования теоремы Байеса для обновления априорных представлений о болезни.
3. Коэффициент Байеса и его вывод. Пример применения.
4. Как с помощью бутстрапа строится доверительный интервал по данной выборке.

Страшные вопросы к экзамену

1. Задача о разорении в честной игре. У двух игроков суммарно N монет; после каждого независимого броска честной монеты проигравший передаёт победителю одну монету. Игра заканчивается при разорении одного из игроков. Найдите вероятность победы первого игрока, если первоначально у него n монет. Выведите рекуррентное соотношение с помощью формулы полной вероятности, укажите граничные условия и получите решение.

Дискретные случайные величины

Лекция 5. Дискретные случайные величины

Схема Бернулли

Определение 1. *Испытание Бернулли — это действие с двумя возможными исходами: "успех" или "неудача". Вероятность успеха обозначают через $p \in [0,1]$, а вероятность неудачи — через $q := 1 - p$.*

Названия "успех" и "неудача" не несут эмоционального смысла. Например, успехом можно назвать появление бракованной детали.

Бросок монеты, при котором успехом считается выпадение решки, даёт $p = 1/2$. При броске правильной двадцатигранной кости можно считать успехом выпадение 20; тогда $p = 1/20$. При броске двух правильных игральных костей успехом может быть совпадение выпавших очков; тогда $p = 1/6$.

Схема Бернулли описывает серию независимых друг от друга испытаний Бернулли с одной и той же вероятностью успеха p. Серия может быть конечной или бесконечной.

Свойство 1. *Вероятность того, что в схеме Бернулли первый успех произойдёт на k-м испытании, равна $q^{k-1}p$, где $k = 1, 2, \ldots$.*

Доказательство. Введём события $A_i = \{i\text{-е испытание успешно}\}$ и $B_k = \{\text{первый успех на } k\text{-м испытании}\}$. Тогда

$$B_k = \overline{A}_1 \cap \cdots \cap \overline{A}_{k-1} \cap A_k.$$

Из независимости испытаний получаем

$$\mathbb{P}(B_k) = \underbrace{q \cdot q \cdots q}_{k-1 \text{ раз}} p = q^{k-1} p. \qquad \square$$

Свойство 2 (Формула Бернулли). *Вероятность того, что в n испытаниях схемы Бернулли произойдёт ровно k успехов, равна*

$$C_n^k p^k q^{n-k}, \qquad k = 0, 1, \ldots, n.$$

Доказательство. Зафиксируем, какие именно k испытаний окончились успехом. Например, первые k испытаний успешны, а остальные — нет:

$$A_1 \cap \cdots \cap A_k \cap \overline{A}_{k+1} \cap \cdots \cap \overline{A}_n.$$

Вероятность такой последовательности равна $p^k q^{n-k}$. Любая другая последовательность с k успехами имеет ту же вероятность. Все эти события попарно несовместны, а выбрать места для k успехов среди n испытаний можно C_n^k способами. Поэтому искомая вероятность равна $C_n^k p^k q^{n-k}$. $\square$

Задача 1. В игре без ничьих против равносильного противника что более вероятно: выиграть один раз из четырёх или два раза из четырёх матчей? Какова вероятность выиграть по крайней мере три из пяти матчей? Результаты матчей считаются независимыми.

Решение. Будем считать успехом победу, а неудачей — поражение. Так как противник равносилен, $p = q = 1/2$. При $n = 4$ формула Бернулли даёт

$$\mathbb{P}(\text{одна победа}) = C_4^1 2^{-4} = \frac{2}{8}, \qquad \mathbb{P}(\text{две победы}) = C_4^2 2^{-4} = \frac{3}{8}.$$

Выиграть два раза из четырёх более вероятно. Для второго вопроса складываем вероятности трёх несовместных событий: ровно три, четыре или пять побед. Получаем

$$(C_5^3 + C_5^4 + C_5^5)2^{-5} = \frac{10 + 5 + 1}{32} = \frac{1}{2}.$$

Случайная величина и её распределение

Определение 2. *Случайная величина — это функция из пространства элементарных исходов в пространство вещественных чисел: $\xi : \Omega \to \mathbb{R}$. Случайная величина называется дискретной, если она может принимать лишь конечное или счётное количество значений.*

Согласно этому определению мы просто сопоставляем каждому возможному исходу эксперимента некоторое число, тем самым получая *случайное число.*

Основной характеристикой случайной величины является её *распределение*, описывающее, какие именно значения она принимает и с какими вероятностями. Для дискретной случайной величины распределение полностью задаётся набором различных значений $a_1, a_2, \ldots$ и вероятностями

$$p_k = \mathbb{P}(\xi = a_k), \qquad p_k \geqslant 0, \qquad \sum_k p_k = 1.$$

Примеры. В игре на разорение успех даёт $+1$, а неудача -1:

x	-1	1
$\mathbb{P}(\xi = x)$	q	p

Количество очков на правильной игральной кости принимает значения $1, \ldots, 6$ с одинаковыми вероятностями:

x	1	2	3	4	5	6
$\mathbb{P}(\xi = x)$	$1/6$	$1/6$	$1/6$	$1/6$	$1/6$	$1/6$

Распределение Бернулли B_p описывает число успехов в одном испытании:

x	0	1
$\mathbb{P}(\xi = x)$	$1 - p$	p

$p \in [0, 1]$.

Геометрическое распределение G_p описывает номер первого успеха в схеме Бернулли:

$$\mathbb{P}(\xi = k) = p(1 - p)^{k-1}, \qquad k = 1, 2, \ldots, \quad 0 < p \leqslant 1.$$

Здесь геометрическая величина считает испытания до первого успеха, включая успешное испытание. При $p = 0$ успех никогда не наступает, поэтому это значение параметра исключено.

Биномиальное распределение $B_{n,p}$ описывает число успехов в n испытаниях схемы Бернулли:

$$\mathbb{P}(\xi = k) = C_n^k p^k (1-p)^{n-k}, \qquad k = 0, 1, \ldots, n.$$

Здесь $n \in \mathbb{N}$, $p \in [0, 1]$. При $p = 0$ число успехов равно нулю, а при $p = 1 - n$.

Преобразования случайных величин

Чтобы найти распределение $g(\xi)$, применим функцию g ко всем значениям из таблицы распределения ξ, а затем объединим совпадающие значения, сложив их вероятности.

Задача 2. Пусть случайная величина ξ соответствует количеству очков, выпавших на правильной игральной кости. Найти распределения $\max(0, 2\xi - 5)$ и $|\xi - 3| - 2$.

Решение. Перебрав значения $\{1, 2, 3, 4, 5, 6\}$ величины ξ и подставив их в формулу $\eta := \max(0, 2\xi - 5)$, получаем значения $\{0, 1, 3, 5, 7\}$. При этом

$$\mathbb{P}(\eta = 0) = \mathbb{P}(\xi = 1) + \mathbb{P}(\xi = 2) = \frac{1}{3}.$$

Остальные значения получаются каждое из одного значения ξ. Весь процесс можно записать в таблице:

ξ	1	2	3	4	5	6
$\max(0, 2\xi - 5)$	0	0	1	3	5	7
$\lvert\xi - 3\rvert - 2$	0	−1	−2	−1	0	1

После объединения одинаковых значений получаем

y	0	1	3	5	7
$\mathbb{P}(\eta = y)$	1/3	1/6	1/6	1/6	1/6

и для $\zeta := |\xi - 3| - 2$

z	−2	−1	0	1
$\mathbb{P}(\zeta = z)$	1/6	1/3	1/3	1/6

Ещё примеры. Пусть X принимает значения 1 и −1 с вероятностями $1/4$ и $3/4$ соответственно. Найдите распределения $(X + 1)/2$ и X^2. Если же X принимает значения 0, 1, 2 с вероятностями 0,1, 0,2, 0,7, найдите распределение $X^2 - 2X + 3$.

Решение. В первом случае $(X + 1)/2$ принимает значения 0 и 1 с вероятностями $3/4$ и $1/4$ соответственно, а $X^2 = 1$ с вероятностью единица. Во втором случае $X^2 - 2X + 3$ принимает значение 2 с вероятностью 0,2 и значение 3 с вероятностью $0{,}1 + 0{,}7 = 0{,}8$.

Математическое ожидание

Математическое ожидание — это среднее значение случайной величины. Оно показывает, какое число получается в среднем при многократном повторении эксперимента. Например, для правильной игральной кости это $(1 + 2 + 3 + 4 + 5 + 6)/6 = 3{,}5$.

Для счётного набора значений конечное математическое ожидание определено, если $\sum_k |a_k| \mathbb{P}(\xi = a_k) < \infty$. В свойствах ниже предполагается существование конечных ожиданий.

Определение 3. *Пусть дискретная случайная величина ξ принимает различные значения $a_1, a_2, \ldots$. Её математическим ожиданием называют взвешенную сумму значений*

$$\mathbb{E}\xi = \sum_k a_k \mathbb{P}(\xi = a_k).$$

Связь с выборочным средним. Для данных $X_1, \ldots, X_n$ обозначим различные значения через $a_1, \ldots, a_m$, а число появлений значения a_k через n_k. Эмпирическое распределение задаётся таблицей

x	a_1	a_2	$\cdots$	a_m
$\mathbb{P}$	n_1/n	n_2/n	$\cdots$	n_m/n

Например, для данных $2, 1, 3, 2, 2, 1, 4, 2$ получаем

x	1	2	3	4
$\mathbb{P}$	$2/8$	$4/8$	$1/8$	$1/8$

Среднее по эмпирическому распределению равно выборочному среднему:

$$\sum_{k=1}^{m} a_k \frac{n_k}{n} = \frac{1}{n} \sum_{i=1}^{n} X_i = \overline{X}_n.$$

Задача 3. Найти математические ожидания случайных величин, имеющих распределение Бернулли, биномиальное и геометрическое распределения.

Решение. Для распределения Бернулли решение получается непосредственно:

$$\mathbb{E}\xi = 0 \cdot (1-p) + 1 \cdot p = p.$$

Для биномиального распределения заметим сначала, что

$$kC_n^k = \frac{n!}{(k-1)!(n-k)!} = nC_{n-1}^{k-1}.$$

Поэтому

$$\begin{aligned}
\mathbb{E}\xi &= \sum_{k=1}^{n} kC_n^k p^k (1-p)^{n-k} \\
&= np \sum_{k=1}^{n} C_{n-1}^{k-1} p^{k-1} (1-p)^{n-k} \\
&= np \sum_{m=0}^{n-1} C_{n-1}^{m} p^m (1-p)^{n-1-m} = np.
\end{aligned}$$

Последняя сумма равна $(p + (1-p))^{n-1} = 1$ по биному Ньютона.

Для геометрического распределения положим $q = 1 - p$. Представим k как сумму k единиц и изменим порядок суммирования неотрицательных слагаемых:

$$\begin{aligned}\mathbb{E}\xi &= p\sum_{k=1}^{\infty} kq^{k-1} = p\sum_{k=1}^{\infty}\sum_{m=1}^{k} q^{k-1} \\ &= p\sum_{m=1}^{\infty}\sum_{k=m}^{\infty} q^{k-1} \\ &= p\sum_{m=1}^{\infty} q^{m-1}\sum_{l=0}^{\infty} q^{l} \\ &= \sum_{m=1}^{\infty} q^{m-1} = \frac{1}{p}.\end{aligned}$$

Функция распределения

Определение 4. *Функцией распределения случайной величины ξ называют функцию*

$$F_\xi(t) := \mathbb{P}(\xi < t).$$

Это ещё один способ записать ту же информацию, которую до этого мы записывали в таблицу:

$$F_\xi(t) = \sum_{k\colon a_k<t} \mathbb{P}(\xi = a_k).$$

Для эмпирического распределения получаем знакомую ЭФР:

$$\widehat{F}_n(t) = \sum_{k\colon a_k<t} \frac{n_k}{n} = \frac{1}{n}\sum_{i=1}^{n} \mathbf{1}\{X_i < t\}.$$

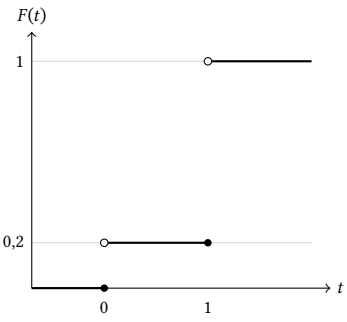
Как и в лекции 4, используется строгое неравенство $\xi < t$. Поэтому значение функции в точке скачка относится к нижней ступени: функция непрерывна слева.

Задача 4. Постройте график функции распределения для распределения Бернулли $B_{0,8}$.

Решение. Отметьте на оси абсцисс возможные значения случайной величины. Между ними функция постоянна, а скачки равны вероятностям соответствующих значений. Так как сумма вероятностей равна единице, функция стремится к единице при $t \to +\infty$. Для распределения с конечным числом значений она достигает единицы после наибольшего из них.

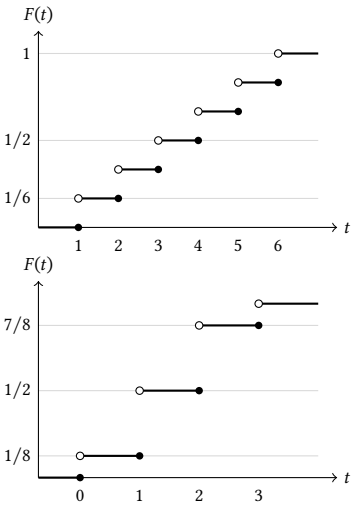
Здесь получаем

$$F_\xi(t) = \begin{cases} 0, & t \leqslant 0, \\ 0{,}2, & 0 < t \leqslant 1, \\ 1, & t > 1. \end{cases}$$



Задача 5. Постройте графики функций распределения количества очков после броска одной правильной игральной кости и биномиального распределения $B_{3,\,0,5}$.

Решение. Для количества очков на кости получаем



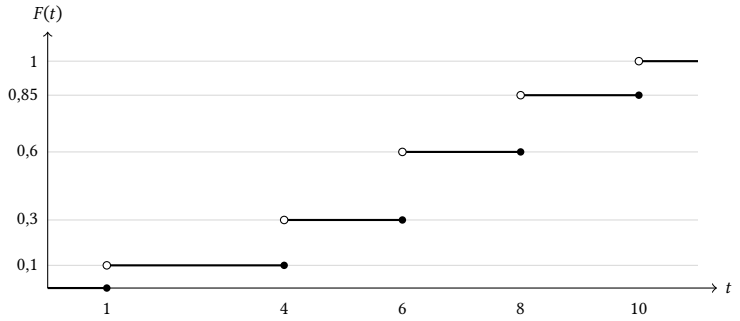
$$F(t) = \begin{cases} 0, & t \leqslant 1, \\ k/6, & k < t \leqslant k+1, \quad k = 1, \ldots, 5, \\ 1, & t > 6. \end{cases}$$

Для биномиального распределения вероятности значений 0, 1, 2, 3 равны 1/8, 3/8, 3/8, 1/8. Поэтому

$$F(t) = \begin{cases} 0, & t \leqslant 0, \\ 1/8, & 0 < t \leqslant 1, \\ 1/2, & 1 < t \leqslant 2, \\ 7/8, & 2 < t \leqslant 3, \\ 1, & t > 3. \end{cases}$$

На обоих графиках нижний конец скачка закрашен, а верхний выколот, поскольку $F(t) = \mathbb{P}(\xi < t)$.

Задача 6. Восстановите распределение по графику его функции распределения.



Решение. Функция на графике имеет скачки в точках $\{1, 4, 6, 8, 10\}$; это даёт набор значений распределения. Чтобы найти вероятности, посмотрим на величины скачков:

x	1	4	6	8	10
$\mathbb{P}(\xi = x)$	0,1	0,2	0,3	0,25	0,15

Совместное распределение и независимость

В предыдущих задачах мы занимались преобразованиями отдельных случайных величин. Но и в практических, и в теоретических задачах полезно комбинировать несколько разных случайных величин.

Определение 5. *Совместное распределение дискретных случайных величин $\xi_1, \ldots, \xi_n$ задаёт вероятность каждого набора их значений:*

$$p_{i_1,\ldots,i_n} = \mathbb{P}(\xi_1 = a_{i_1}^{(1)}, \ldots, \xi_n = a_{i_n}^{(n)}).$$

Все эти вероятности неотрицательны, а их сумма равна единице.

Для двух величин совместное распределение удобно задавать таблицей:

$\xi \backslash \eta$	b_1	b_2	$\cdots$	b_m
a_1	p_{11}	p_{12}	$\cdots$	p_{1m}
a_2	p_{21}	p_{22}	$\cdots$	p_{2m}
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$
a_n	p_{n1}	p_{n2}	$\cdots$	p_{nm}

Суммирование по строкам и столбцам даёт отдельные (*маргинальные*) распределения:

$$\mathbb{P}(\xi = a_i) = \sum_j p_{ij}, \qquad \mathbb{P}(\eta = b_j) = \sum_i p_{ij}.$$

Определение 6. *Дискретные случайные величины $\xi_1, \ldots, \xi_n$ независимы, если для любых их значений*

$$\mathbb{P}(\xi_1 = a_1, \ldots, \xi_n = a_n) = \prod_{k=1}^{n} \mathbb{P}(\xi_k = a_k).$$

Для двух величин это означает, что при любых i и j

$$p_{ij} = \mathbb{P}(\xi = a_i)\mathbb{P}(\eta = b_j).$$

Эквивалентно, для любых множеств $A_1, \ldots, A_n$ события $\{\xi_1 \in A_1\}, \ldots, \{\xi_n \in A_n\}$ независимы в совокупности.

Примеры с игральными костями. Для очков на двух независимых правильных костях каждая ячейка таблицы совместного распределения имеет вероятность $1/36$. Если же ξ — очки одной кости, а $\eta = \xi$, то ненулевые вероятности $1/6$ стоят только на главной диагонали. При $\eta = 7 - \xi$ они стоят на противоположной диагонали:

$\xi \backslash \eta$	1	2	3	4	5	6
1	1/6	0	0	0	0	0
2	0	1/6	0	0	0	0
3	0	0	1/6	0	0	0
4	0	0	0	1/6	0	0
5	0	0	0	0	1/6	0
6	0	0	0	0	0	1/6

$\xi \backslash \eta$	1	2	3	4	5	6
1	0	0	0	0	0	1/6
2	0	0	0	0	1/6	0
3	0	0	0	1/6	0	0
4	0	0	1/6	0	0	0
5	0	1/6	0	0	0	0
6	1/6	0	0	0	0	0

Во всех трёх случаях отдельные распределения одинаковы, а совместные распределения различаются.

Ещё один пример: минимум и максимум очков на двух независимых правильных костях. Эти величины зависимы: минимум не может превзойти максимум. Их совместное распределение имеет вид

min \ max	1	2	3	4	5	6
1	1/36	1/18	1/18	1/18	1/18	1/18
2	0	1/36	1/18	1/18	1/18	1/18
3	0	0	1/36	1/18	1/18	1/18
4	0	0	0	1/36	1/18	1/18
5	0	0	0	0	1/36	1/18
6	0	0	0	0	0	1/36

Почему таблица имеет именно такой вид?

Решение. При минимуме i и максимуме j, где $i < j$, подходят два исхода: (i, j) и (j, i). Их суммарная вероятность равна $2/36 = 1/18$. При $i = j$ подходит только исход (i, i) с вероятностью $1/36$, а при $i > j$ подходящих исходов нет.

Задача 7. Найти распределение суммы очков на двух независимых правильных игральных костях.

Решение. Обозначим количество очков на первой и второй кости через ξ и η. Возможные значения суммы — $2, 3, \ldots, 12$. Для каждого из них перебираем все подходящие пары, например:

$$\begin{aligned}\mathbb{P}(\xi + \eta = 4) = \mathbb{P}(\xi = 1, \eta = 3) \\ + \mathbb{P}(\xi = 2, \eta = 2) \\ + \mathbb{P}(\xi = 3, \eta = 1) = \frac{3}{36}.\end{aligned}$$

Разные пары значений взаимно исключают друг друга, поэтому их вероятности можно складывать. Это соответствует суммированию по диагоналям таблицы, идущим вверх и направо. В итоге получаем

s	2	3	4	5	6	7	8	9	10	11	12
$\mathbb{P}(\xi + \eta = s)$	1/36	2/36	3/36	4/36	5/36	6/36	5/36	4/36	3/36	2/36	1/36

Задача 8. Пусть случайные величины ξ и η имеют совместное распределение, заданное таблицей. Найти отдельно распределения ξ и η. Являются ли они независимыми?

$\xi \backslash \eta$	0	1	2
-1	0,3	0,4	0
1	0	0,1	0,2

Решение. Достаточно просуммировать вероятности всех пар, в которых величина принимает нужное значение. Например, $\mathbb{P}(\eta = 1) = 0{,}4 + 0{,}1 = 0{,}5$. Суммы строк и столбцов дают

x	-1	1
$\mathbb{P}(\xi = x)$	0,7	0,3

y	0	1	2
$\mathbb{P}(\eta = y)$	0,3	0,5	0,2

Если бы ξ и η были независимы, вероятность пары $(-1, 1)$ равнялась бы $0{,}7 \cdot 0{,}5 = 0{,}35$, что противоречит исходной таблице. Поэтому величины зависимы. При независимости таблица имела бы вид

$\xi \backslash \eta$	0	1	2
-1	0,21	0,35	0,14
1	0,09	0,15	0,06

Задача 9. Найти отдельные распределения ξ и η по таблице совместного распределения. Являются ли величины независимыми?

$\xi \backslash \eta$	-1	0	7
0	0,1	0,25	0,3
2	0,1	0,15	0,1

Решение. Суммирование строк даёт вероятности 0,65 и 0,35 для значений $\xi = 0$ и $\xi = 2$. Суммирование столбцов даёт вероятности 0,2, 0,4, 0,4 для значений $\eta = -1, 0, 7$ соответственно. Величины зависимы, поскольку

$$\mathbb{P}(\xi = 0, \eta = -1) = 0{,}1 \neq 0{,}65 \cdot 0{,}2 = 0{,}13.$$

Ещё пример. Для совместного распределения

$X \backslash Y$	-1	0	1
-1	0,2	0,1	0
1	0,4	0	0,3

найдите отдельные распределения X и Y, а также распределения $X + Y$ и $X - Y$. Как выглядела бы таблица для независимых величин с теми же отдельными распределениями?

Решение. Суммы строк и столбцов дают отдельные распределения:

x	-1	1
$\mathbb{P}(X = x)$	0,3	0,7

y	-1	0	1
$\mathbb{P}(Y = y)$	0,6	0,1	0,3

Для суммы и разности получаем

s	-2	-1	0	2
$\mathbb{P}(X + Y = s)$	0,2	0,1	0,4	0,3

d	-1	0	2
$\mathbb{P}(X - Y = d)$	0,1	0,5	0,4

При независимости вероятности пар равнялись бы произведениям соответствующих вероятностей отдельных значений:

$X \backslash Y$	-1	0	1
-1	0,18	0,03	0,09
1	0,42	0,07	0,21

Задача 10. Доказать, что сумма n независимых бернуллиевских случайных величин $\xi_1, \dots, \xi_n$ с распределением B_p имеет биномиальное распределение $B_{n,p}$.

Сумма считает число успехов в n испытаниях Бернулли, поэтому утверждение следует из формулы Бернулли. Докажем его также по индукции.

План решения. Сложите две или три бернуллиевские величины вручную. Заметьте, что $B_p = B_{1,p}$. Затем для независимых $\xi \sim B_p$ и $\eta \sim B_{n,p}$ найдите $\mathbb{P}(\xi + \eta = k)$, разделив случаи $\xi = 0$ и $\xi = 1$.

Решение. При $n = 1$ утверждение верно: оба распределения принимают значения 0 и 1 с вероятностями $1-p$ и p. Пусть $\eta := \xi_1 + \dots + \xi_n \sim B_{n,p}$. Положим $q = 1 - p$. В граничных случаях

$$\mathbb{P}(\eta + \xi_{n+1} = 0) = q^{n+1}, \qquad \mathbb{P}(\eta + \xi_{n+1} = n+1) = p^{n+1}.$$

Для $1 \leqslant k \leqslant n$ имеем

$$\begin{aligned}\mathbb{P}(\eta + \xi_{n+1} = k) &= q\mathbb{P}(\eta = k) + p\mathbb{P}(\eta = k-1) \\ &= qC_n^k p^k q^{n-k} + pC_n^{k-1} p^{k-1} q^{n-k+1} \\ &= (C_n^k + C_n^{k-1}) p^k q^{n+1-k} \\ &= C_{n+1}^k p^k q^{n+1-k}.\end{aligned}$$

Это распределение $B_{n+1,p}$.

Свойства математического ожидания

Константы также можно рассматривать как случайные величины, принимающие единственное значение с вероятностью единица.

Задача 11. Пусть случайная величина ξ — константа, то есть $\xi \equiv c$. Найти её математическое ожидание.

Ответ: c.

Задача 12. Пусть ξ и η — дискретные случайные величины с конечными математическими ожиданиями. Доказать, что $\mathbb{E}(\xi + \eta) = \mathbb{E}\xi + \mathbb{E}\eta$.

Решение. Пусть ξ принимает значения a_i, а η — значения b_j. Обозначим $p_{ij} = \mathbb{P}(\xi = a_i, \eta = b_j)$. Тогда

$$\begin{aligned}\mathbb{E}(\xi + \eta) &= \sum_i \sum_j (a_i + b_j) p_{ij} \\ &= \sum_i a_i \sum_j p_{ij} + \sum_j b_j \sum_i p_{ij} \\ &= \sum_i a_i \mathbb{P}(\xi = a_i) + \sum_j b_j \sum_i p_{ij} \\ &= \mathbb{E}\xi + \mathbb{E}\eta.\end{aligned}$$

Непосредственно из определения $\mathbb{E}(c\xi) = c\mathbb{E}\xi$. Вместе эти свойства дают *линейность* математического ожидания:

$$\mathbb{E}(a\xi + b\eta) = a\mathbb{E}\xi + b\mathbb{E}\eta.$$

Для линейности независимость не нужна. Представив биномиальную величину как сумму n бернуллиевских, снова получаем $\mathbb{E}\xi = np$.

Задача 13. Пусть ξ и η — независимые дискретные случайные величины с конечными математическими ожиданиями. Доказать, что $\mathbb{E}(\xi\eta) = (\mathbb{E}\xi)(\mathbb{E}\eta)$.

Решение. Используем независимость и обозначения предыдущего решения:

$$\begin{aligned}\mathbb{E}(\xi\eta) &= \sum_i \sum_j a_i b_j \mathbb{P}(\xi = a_i, \eta = b_j) \\ &= \sum_i \sum_j a_i b_j \mathbb{P}(\xi = a_i)\mathbb{P}(\eta = b_j) \\ &= \left(\sum_i a_i \mathbb{P}(\xi = a_i)\right)\left(\sum_j b_j \mathbb{P}(\eta = b_j)\right) \\ &= (\mathbb{E}\xi)(\mathbb{E}\eta).\end{aligned}$$

Задача 14. Пусть $\xi \geqslant 0$ — дискретная случайная величина, принимающая только неотрицательные значения. Докажите, что $\mathbb{E}\xi \geqslant 0$.

Решение. Все значения a_i неотрицательны, поэтому

$$\mathbb{E}\xi = \sum_i a_i \mathbb{P}(\xi = a_i) \geqslant 0 \ :$$

каждое слагаемое суммы неотрицательно.

Задача 15. Пусть ξ и η — дискретные случайные величины с конечными математическими ожиданиями и $\xi \geqslant \eta$. Доказать, что $\mathbb{E}\xi \geqslant \mathbb{E}\eta$.

Решение. Положим $\zeta := \xi - \eta \geqslant 0$. Тогда $\mathbb{E}\xi - \mathbb{E}\eta = \mathbb{E}\zeta \geqslant 0$, откуда $\mathbb{E}\xi \geqslant \mathbb{E}\eta$.

Задачи к лекции

Задача 16. Пусть случайная величина ξ соответствует количеству очков, выпавших на правильной игральной кости. Найти распределения $\xi^3 - 8\xi^2 + 19\xi - 10$ и $|\xi - 2| + |\xi - 5|$.

Решение. Величина $\eta := \xi^3 - 8\xi^2 + 19\xi - 10$ принимает значение 2, если ξ равна 1, 3 или 4. Значения 2, 5, 6 переходят в 4, 10, 32 соответственно. В итоге

y	2	4	10	32
$\mathbb{P}(\eta = y)$	$1/2$	$1/6$	$1/6$	$1/6$

Величина $\eta' := |\xi - 2| + |\xi - 5|$ принимает значение 3 при $\xi \in \{2, 3, 4, 5\}$ и 5 при $\xi \in \{1, 6\}$. Поэтому $\mathbb{P}(\eta' = 3) = 2/3$, $\mathbb{P}(\eta' = 5) = 1/3$.

Задача 17. Десять любителей подлёдного лова рыбы независимо друг от друга равномерно размещаются на льду озера, имеющего форму круга радиуса 1 км. Какова вероятность того, что не менее пяти рыбаков расположатся на расстоянии более 200 м от берега?

Решение. Рыбакам поставим в соответствие испытания Бернулли, а успехом будем считать расположение достаточно далеко от берега. Вероятность успеха равна

$$p = \frac{\pi(1000-200)^2}{\pi \cdot 1000^2} = 0{,}8^2 = 0{,}64.$$

Искомое событие есть объединение несовместных событий: далеко от берега расположились ровно 5, 6, ..., 10 рыбаков. Поэтому его вероятность равна

$$\sum_{k=5}^{10} C_{10}^k \, 0{,}64^k \, 0{,}36^{10-k}.$$

Задача 18. Найти вероятность того, что k-й по порядку успех в серии последовательных испытаний Бернулли произойдёт на l-м испытании, где $1 \leqslant k \leqslant l$.

Решение. Искомое событие — пересечение двух событий: A — за первые $l-1$ испытаний произошёл ровно $k-1$ успех; B — l-е испытание окончилось успехом. По формуле Бернулли

$$\mathbb{P}(A) = C_{l-1}^{k-1} p^{k-1}(1-p)^{l-k}, \qquad \mathbb{P}(B) = p.$$

Используя независимость испытаний, получаем

$$\mathbb{P}(A \cap B) = C_{l-1}^{k-1} p^k (1-p)^{l-k}.$$

Задача 19. Найти вероятность того, что в n испытаниях схемы Бернулли с вероятностью успеха p появятся $m+l$ успехов, причём последние l испытаний окончатся успехом. Здесь $0 \leqslant l \leqslant n$ и $0 \leqslant m \leqslant n-l$.

Решение. Искомое событие есть пересечение независимых событий: A — за первые $n-l$ испытаний произошло ровно m успехов; B — все последние l испытаний успешны. Поэтому

$$\mathbb{P}(A \cap B) = C_{n-l}^m p^m (1-p)^{n-l-m} p^l = C_{n-l}^m p^{m+l} (1-p)^{n-l-m}.$$

Задача 20. В круг вписан квадрат. Найти вероятность того, что из десяти точек, независимо брошенных наудачу в круг, четыре попадут в квадрат, три — в нижний сегмент, и по одной — в оставшиеся три сегмента.

Решение. Диагональ вписанного квадрата равна диаметру окружности $2R$, поэтому сторона квадрата равна $\sqrt{2}R$. Вероятности попадания в квадрат и в каждый сегмент равны

$$p_{\text{кв}} = \frac{2R^2}{\pi R^2} = \frac{2}{\pi}, \qquad p_{\text{сег}} = \frac{1-p_{\text{кв}}}{4} = \frac{\pi-2}{4\pi}.$$

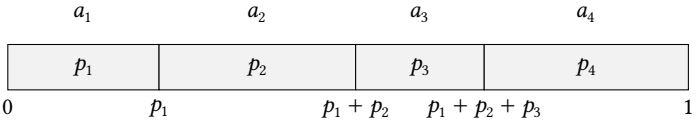
Зафиксируем порядок: первые четыре точки попали в квадрат, следующие три — в нижний сегмент, а последние три — в левый, верхний и правый сегменты соответственно. Вероятность такого расположения равна $p_{\text{кв}}^4 p_{\text{сег}}^6$. Любой другой подходящий порядок имеет ту же вероятность. Всего таких порядков $10!/(4!3!1!1!1!)$, и соответствующие события попарно несовместны. Поэтому ответ равен

$$\frac{10!}{4!3!}\left(\frac{2}{\pi}\right)^4\left(\frac{\pi-2}{4\pi}\right)^6.$$

Лекция 6. Моделирование и приближение Пуассона

Генерирование дискретных случайных величин

Пусть нам нужно сгенерировать дискретную случайную величину ξ со значениями $a_1, a_2, \ldots$ и вероятностями $p_k := \mathbb{P}(\xi = a_k)$. Разобьём отрезок $[0,1]$ на части длины p_k. Возьмём случайно выбранную точку этого отрезка в смысле геометрического определения вероятности. Сгенерированным значением будет a_k, соответствующее части, в которую попала точка.



Обозначим накопленные суммы вероятностей через

$$s_0 = 0, \qquad s_k = p_1 + \cdots + p_k.$$

Если равномерно выбранная точка U попала в $[s_{k-1}, s_k)$, положим $\xi = a_k$. Вероятность этого события равна длине промежутка, то есть p_k. Эта схема применима, в частности, к распределениям Бернулли, биномиальному и геометрическому распределениям.

Попадание в любую фиксированную границу имеет вероятность нуль. Значение при $U = 1$ можно задать произвольно.

Распределение Пуассона

Распределение Пуассона используется для подсчёта количества успехов в случаях, когда испытаний много, а вероятность успеха мала. Примеры таких счётчиков: количество телефонных звонков в колл-центр, несчастных случаев на определённом участке дороги, опечаток в тексте, посещений веб-сайта за секунду.

Определение 1. *Случайная величина ξ имеет распределение Пуассона Π_λ с параметром $\lambda > 0$, если она принимает значения $0, 1, 2, \ldots$ с вероятностями*

$$\mathbb{P}(\xi = k) = \frac{\lambda^k}{k!}e^{-\lambda}, \qquad k = 0, 1, 2, \ldots.$$

Сумма этих вероятностей действительно равна единице:

$$\sum_{k=0}^{\infty}\frac{\lambda^k}{k!}e^{-\lambda} = e^{-\lambda}\sum_{k=0}^{\infty}\frac{\lambda^k}{k!} = e^{-\lambda}e^{\lambda} = 1.$$

Задача 1. Найти математическое ожидание случайной величины, имеющей распределение Пуассона Π_λ.

Решение. По определению математического ожидания

$$\begin{aligned}\mathbb{E}\xi &= \sum_{k=0}^{\infty} k\frac{\lambda^k}{k!}e^{-\lambda} \\ &= \lambda\sum_{k=1}^{\infty}\frac{\lambda^{k-1}}{(k-1)!}e^{-\lambda} \\ &= \lambda\sum_{m=0}^{\infty}\frac{\lambda^m}{m!}e^{-\lambda} = \lambda.\end{aligned}$$

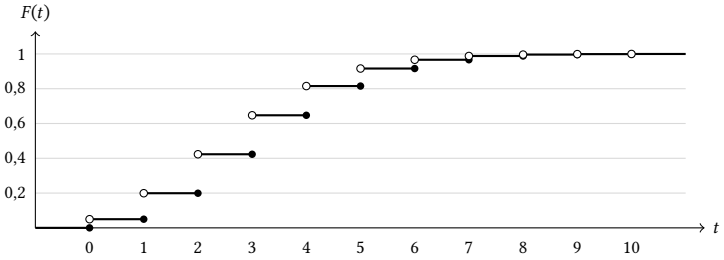
Последняя сумма равна единице, поскольку это сумма всех вероятностей распределения Пуассона.

Задача 2. Постройте график функции распределения для распределения Пуассона Π_3.

Решение. Отмечаем на оси абсцисс значения $0, 1, 2, \ldots$. В точке k функция имеет скачок величины $3^k e^{-3}/k!$. Как и раньше, $F_\xi(t) = \mathbb{P}(\xi < t)$, поэтому

$$F_\xi(t) = \sum_{\substack{k\geqslant 0\\ k<t}}\frac{3^k}{k!}e^{-3}.$$

График стремится к единице, но не достигает её ни при каком конечном t.



Сумма независимых пуассоновских величин

Свойство 1. *Пусть ξ и η — независимые случайные величины с распределениями Π_{λ_1} и Π_{λ_2}. Тогда $\xi+\eta$ имеет распределение $\Pi_{\lambda_1+\lambda_2}$.*

Доказательство. Событие $\{\xi+\eta = n\}$ разбивается на несовместные события $\{\xi = k, \eta = n-k\}$, где $k = 0, \ldots, n$. Из независимости получаем

$$\begin{aligned}\mathbb{P}(\xi+\eta=n) &= \sum_{k=0}^{n}\mathbb{P}(\xi=k)\mathbb{P}(\eta=n-k) \\ &= \sum_{k=0}^{n}\frac{\lambda_1^k}{k!}e^{-\lambda_1}\frac{\lambda_2^{n-k}}{(n-k)!}e^{-\lambda_2} \\ &= \frac{e^{-\lambda_1-\lambda_2}}{n!}\sum_{k=0}^{n}C_n^k\lambda_1^k\lambda_2^{n-k} \\ &= \frac{(\lambda_1+\lambda_2)^n}{n!}e^{-\lambda_1-\lambda_2}.\end{aligned}$$

Последнее равенство — бином Ньютона. □

Теорема о приближении Пуассона

Приближение Пуассона говорит о том, что если вероятность успеха p в схеме Бернулли достаточно мала, то вместо биномиального распределения можно использовать распределение Пуассона с параметром $\lambda = np$.

Свойство 2 (Приближение Пуассона). *Пусть $n \in \mathbb{N}$, $0 < p \leqslant 1$ и $\lambda = np$. Если $\xi \sim B_{n,p}$ и $\eta \sim \Pi_\lambda$, то для любого множества $A \subseteq \{0, 1, 2, \ldots\}$*

$$\bigl|\mathbb{P}(\xi \in A) - \mathbb{P}(\eta \in A)\bigr| \leqslant np^2.$$

В частности, при фиксированном $\lambda > 0$ и $p_n = \lambda/n$ для достаточно больших n имеем $np_n^2 = \lambda^2/n \to 0$. Поэтому для каждого фиксированного $k = 0, 1, 2, \ldots$

$$C_n^k p_n^k (1 - p_n)^{n-k} \longrightarrow \frac{\lambda^k}{k!} e^{-\lambda}.$$

Первый шаг: сравнение на одном пространстве. Для любых двух случайных величин X и Z, построенных на одном пространстве исходов, верно неравенство

$$\bigl|\mathbb{P}(X \in A) - \mathbb{P}(Z \in A)\bigr| \leqslant \mathbb{P}(X \neq Z).$$

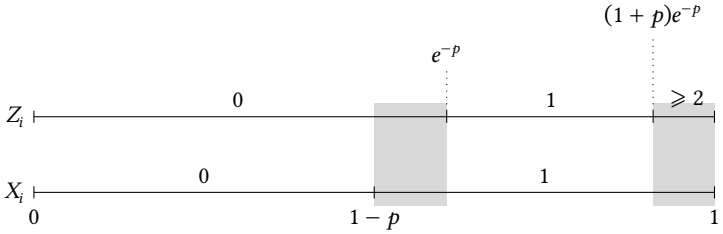
Действительно, разобьём каждое событие на случаи $X = Z$ и $X \neq Z$. На событии $X = Z$ условия $X \in A$ и $Z \in A$ совпадают. Поэтому

$$\begin{aligned}\mathbb{P}(X \in A) - \mathbb{P}(Z \in A) = \mathbb{P}(X \in A, X \neq Z)\\ - \mathbb{P}(Z \in A, X \neq Z).\end{aligned}$$

Обе вероятности справа лежат между нулём и $\mathbb{P}(X \neq Z)$, значит модуль их разности не превосходит $\mathbb{P}(X \neq Z)$.

Второй шаг: согласованное построение. Нас интересуют только распределения ξ и η, поэтому мы можем построить их удобным для нас способом. Возьмём независимые равномерно выбранные точки $U_1, \ldots, U_n$ отрезка $[0, 1]$. По каждой точке U_i одновременно сгенерируем $X_i \sim B_p$ и $Z_i \sim \Pi_p$. Для X_i отведём значению 0 промежуток $[0, 1-p)$, а значению 1 — $[1-p, 1]$. Для Z_i отведём значениям $0, 1, 2, \ldots$ последовательные промежутки длины e^{-p}, pe^{-p}, $p^2e^{-p}/2!$, ….

Величины $X_1, \ldots, X_n$ независимы между собой, как и $Z_1, \ldots, Z_n$. Но X_i и Z_i используют одну точку U_i и не обязаны быть независимыми.



Серым отмечены промежутки, где $X_i \neq Z_i$.

Так как $1 - p \leqslant e^{-p}$, значения X_i и Z_i различаются на промежутках $[1-p, e^{-p})$ и $[(1+p)e^{-p}, 1]$. Сумма длин этих промежутков равна

$$\begin{aligned}\mathbb{P}(X_i \neq Z_i) &= \bigl(e^{-p} - (1-p)\bigr) + \bigl(1 - e^{-p} - pe^{-p}\bigr) \\ &= p(1 - e^{-p}) \leqslant p^2.\end{aligned}$$

Последнее неравенство снова следует из $1 - p \leqslant e^{-p}$.

Третий шаг: сложение. Положим

$$\xi := X_1 + \cdots + X_n, \qquad \eta := Z_1 + \cdots + Z_n.$$

Тогда $\xi \sim B_{n,p}$, а $\eta \sim \Pi_{np}$ по свойству суммы независимых пуассоновских величин. Если все пары слагаемых совпадают, совпадают и суммы. Следовательно,

$$\{\xi \neq \eta\} \subseteq \bigcup_{i=1}^{n} \{X_i \neq Z_i\},$$

и потому

$$\begin{aligned}\bigl|\mathbb{P}(\xi \in A) - \mathbb{P}(\eta \in A)\bigr| &\leqslant \mathbb{P}(\xi \neq \eta) \\ &\leqslant \sum_{i=1}^{n} \mathbb{P}(X_i \neq Z_i) \leqslant np^2.\end{aligned}$$

Теорема доказана.

Оценка погрешности. Для биномиального распределения справедлива также более сильная оценка, которую приведём без доказательства:

$$\bigl|\mathbb{P}(\xi \in A) - \mathbb{P}(\eta \in A)\bigr| \leqslant \min(p, np^2).$$

Именно она используется в следующих задачах. Приближение сохраняет эту погрешность для любого утверждения о количестве успехов, а не только для события $\{\xi = k\}$:

$$\mathbb{P}(\xi \in A) \approx \sum_{k \in A} \frac{(np)^k}{k!} e^{-np}.$$

Задачи к лекции

Задача 3. При производстве матрицы каждый из $2 \cdot 10^7$ пикселей может быть повреждён с вероятностью 10^{-7} независимо от других. Какова вероятность того, что будет повреждено более трёх пикселей?

Решение. Испытание — проверка одного пикселя, успех — его повреждение. Здесь $n = 2 \cdot 10^7$, $p = 10^{-7}$, $\lambda = np = 2$. Погрешность приближения не превосходит $\min(p, np^2) = 10^{-7}$. Если ξ — количество повреждённых пикселей, то

$$\begin{aligned} \mathbb{P}(\xi > 3) &= 1 - \mathbb{P}(\xi \leqslant 3) \\ &\approx 1 - e^{-2} \sum_{k=0}^{3} \frac{2^k}{k!} \\ &= 1 - e^{-2}\left(1 + 2 + \frac{4}{2} + \frac{8}{6}\right) \\ &= 1 - \frac{19}{3} e^{-2} \approx 0{,}143. \end{aligned}$$

Полученная вероятность значительно больше погрешности 10^{-7}.

Задача 4. Вероятность угадывания шести номеров в спортлото (шесть из сорока девяти) равна $7{,}2 \cdot 10^{-8}$. При подсчёте оказались заполненными 5 млн карточек. Какова вероятность, что никто не угадал все шесть номеров? Какое наименьшее количество карточек нужно заполнить, чтобы с вероятностью не менее 0,9 хотя бы одна выиграла? Карточки заполняются независимо и наудачу.

Решение. Каждая карточка соответствует отдельному независимому испытанию. Успех — угадывание всех шести номеров, $p = 7{,}2 \cdot 10^{-8}$. При $n = 5 \cdot 10^6$ получаем $\lambda = np = 0{,}36$, а погрешность не превосходит

$$np^2 = 5 \cdot 10^6 \cdot (7{,}2 \cdot 10^{-8})^2 = 2{,}592 \cdot 10^{-8}.$$

Поэтому вероятность отсутствия выигрышных карточек равна

$$\mathbb{P}(\xi = 0) \approx e^{-0{,}36} \approx 0{,}698.$$

Для второго вопроса считаем n неизвестной переменной. Нам нужно, чтобы вероятность отсутствия выигрыша была не больше 0,1. В приближении Пуассона это даёт

$$e^{-np} \leqslant 0{,}1, \qquad np \geqslant \ln 10, \qquad n \geqslant \frac{\ln 10}{7{,}2 \cdot 10^{-8}} \approx 3{,}198 \cdot 10^7.$$

Приближённый ответ — около 32 млн карточек. Для точного наименьшего целого числа используем $(1-p)^n \leqslant 0{,}1$:

$$n_{\min} = \left\lceil \frac{\ln 0{,}1}{\ln(1-p)} \right\rceil = 31\,980\,348.$$

Это значение вычислено для указанного в условии p.

Задача 5. Вероятность выпуска сверла повышенной хрупкости (брака) равна 0,02. Свёрла укладываются в коробки по 100 штук. Чему равна вероятность того, что в коробке не окажется бракованных свёрл? Какое наименьшее количество свёрл нужно класть в коробку, чтобы с вероятностью не меньшей 0,9 в ней было не менее 100 исправных? Качество разных свёрл считается независимым.

Решение. Испытанию соответствует одно сверло, а успеху — выпуск бракованного сверла; $p = 0{,}02$. При $n = 100$ параметр $\lambda = np = 2$, а погрешность не превосходит $\min(p, np^2) = 0{,}02$. По приближению Пуассона вероятность отсутствия брака равна

$$\mathbb{P}(\xi = 0) \approx e^{-2} \approx 0{,}135.$$

Чтобы ответить на второй вопрос, будем постепенно увеличивать n. В коробке из n свёрл допустимо не более $n - 100$ бракованных. При $\lambda = 0{,}02n$ получаем

$$\mathbb{P}(\xi \leqslant n - 100) \approx e^{-\lambda} \sum_{k=0}^{n-100} \frac{\lambda^k}{k!}.$$

n	λ	Допустимый брак	Вероятность
101	2,02	1	0,401
102	2,04	2	0,666
103	2,06	3	0,846
104	2,08	4	0,940

С учётом погрешности 0,02 при $n = 103$ вероятность ещё меньше 0,9, а при $n = 104$ уже больше 0,9. Вероятность иметь не менее 100 исправных свёрл возрастает с добавлением свёрл, поэтому наименьшее число — 104.

Задача 6. Сколько в среднем изюминок должны содержать калорийные булочки, чтобы с вероятностью не менее 0,99 в булочке была хотя бы одна изюминка?

План решения. Рассматривайте булочку как множество маленьких кусков размером с изюминку. Вспомните математическое ожидание пуассоновской случайной величины: с ним связано среднее количество изюминок.

Решение. Разобьём булочку на большое количество маленьких кусков, в каждом из которых может поместиться не более одной изюминки. В модели независимого редкого попадания изюминки в каждый кусок эти кусочки будут испытаниями Бернулли, а успехом — наличие изюминки. Вероятность успеха из условия неизвестна, но найти нужно среднее количество изюминок, то есть $np = \lambda$. В пуассоновской модели $\mathbb{E}\xi = \lambda$ и

$$\mathbb{P}(\xi \geqslant 1) = 1 - e^{-\lambda}.$$

Остаётся решить неравенство $1 - e^{-\lambda} \geqslant 0{,}99$:

$$\lambda \geqslant \ln 100 \approx 4{,}605.$$

Таким образом, в этой модели достаточно в среднем примерно 4,61 изюминки на булочку.

Практическое задание 3. Бутстрэп

Повсюду будем предполагать, что у нас есть некоторая выборка $X_1, \dots, X_n$. Определение доверительного интервала и алгоритм построения перцентильного бутстрэп-интервала приведены в лекции 4.

Медианное абсолютное отклонение

Медианное абсолютное отклонение (MAD) — это мера разброса данных $X_1, \dots, X_n$, которая менее чувствительна к выбросам по сравнению со стандартным отклонением. Она определяется как медиана абсолютных отклонений наблюдений от общей медианы выборки:

$$\begin{aligned} \text{MAD} &= \text{median}\left(\{|X_i - \text{median}(X_1, \dots, X_n)|\}_{i=1}^n\right) \\ &= \text{median}\left(\{|X_i - \hat{\mu}_n|\}_{i=1}^n\right). \end{aligned}$$

Однако аналитическое получение доверительных интервалов для MAD может быть сложной задачей. В таких случаях на помощь приходит бутстрэп — метод, позволяющий оценивать характеристики статистических распределений без сложных выкладок. Как и в лекции 4, здесь предполагается, что исходные наблюдения независимы и имеют одно распределение.

Формулировка задания

Используя метод бутстрэпа, оцените приближённый 95% доверительный интервал для MAD по заданной выборке. Саму выборку вы можете получить, например, с помощью такого кода:

```
import numpy as np

X = np.random.exponential(scale=1.0, size=10000)
```

Хотя за вами остаётся право использовать и какой-нибудь другой метод. Кроме этого, также используйте метод бутстрэпа для оценки приближённого 95% доверительного интервала для выборочной дисперсии по той же самой выборке. Сравните полученные доверительные интервалы и сделайте выводы. При сравнении учитывайте, что MAD измеряется в единицах исходных данных, а дисперсия — в их квадрате. Поэтому ширины этих интервалов нельзя сравнивать напрямую.

Вопросы для подготовки

Простые вопросы к коллоквиуму

1. Формула вероятности получения k успехов в n испытаниях Бернулли.
2. Формула вероятности того, что первый успех произойдёт в k-м испытании.
3. Математическое ожидание дискретной случайной величины.
4. Распределение Бернулли: ряд / таблица распределения.
5. Биномиальное распределение: ряд / таблица распределения.
6. Геометрическое распределение: ряд / таблица распределения.
7. Распределение Пуассона: ряд / таблица распределения.
8. Теорема о приближении Пуассона: формулировка.
9. Какое распределение имеет сумма конечного числа независимых бернуллиевских случайных величин с одним и тем же параметром p?
10. Какое распределение имеет сумма конечного числа независимых пуассоновских случайных величин?
11. Что такое схема Бернулли? Как с ней связаны распределения Бернулли, биномиальное и геометрическое? Когда для числа успехов используется приближение Пуассона?
12. Как задаётся совместное распределение двух дискретных случайных величин?
13. Генерация дискретных распределений на основе равномерно выбранной точки на отрезке $[0; 1]$.
14. Разница между случайной величиной и распределением. Привести примеры обоих и показать, как они связаны друг с другом.

15. Функция распределения дискретной случайной величины: определение и построение графика.

16. Как восстановить распределение дискретной случайной величины по графику её функции распределения?

17. Как получить распределения отдельных случайных величин из таблицы их совместного распределения?

18. Определение независимости дискретных случайных величин. Как проверить независимость двух величин по таблице совместного распределения?

19. Математические ожидания распределений Бернулли, биномиального, геометрического и Пуассона: формулы.

20. Линейность математического ожидания: формулировка.

21. Математическое ожидание произведения независимых дискретных случайных величин: формулировка свойства.

22. Что можно сказать о математическом ожидании неотрицательной случайной величины?

23. Монотонность математического ожидания: формулировка.

Обычные вопросы к экзамену

1. Что такое случайная величина? Дискретные случайные величины и их преобразования (примеры преобразований одной и нескольких случайных величин).
2. Схема Бернулли. Формула k успехов из n испытаний и её доказательство.
3. Схема Бернулли. Формула вероятности первому успеху произойти на k-м испытании и её вывод.
4. Линейность математического ожидания и её доказательство.
5. Математическое ожидание произведения независимых дискретных случайных величин. Формулировка и доказательство.
6. Распределение суммы независимых пуассоновских случайных величин. Формулировка и доказательство.

Страшные вопросы к экзамену

1. Теорема о приближении Пуассона. Формулировка и доказательство оценки погрешности np^2.